دانشگاه آزاد اسلامی واحد کرج

کارشناسی مهندسی کامپیوتر | پروژه‌ی نرم‌افزار

گزارش پژوهشی مرحله‌ی ۱۷

مرز رویداد با فرصت و هزینه‌ی بازیابی ثابت

ممیزی علمی، مرور مرز دانش و اجرای آزمایش کنترل‌شده

پژوهشگر: یوسف ابوالفتحی روزبهانی

استاد راهنمای دانشگاهی: استاد امیر نوری ولنده

راهنمای آموزشی علوم اعصاب شناختی: دکتر آرش فکری

FARDIAT | فردیت، مجتمع فوق تخصصی مغز و شناخت



۲۱ اکتبر ۲۰۲۶

گزارش پیشرفت برای بازبینی؛ انتشار عمومی پس از تایید پژوهشگر

github.com/yousofab/event-memory-retrieval

چکیده

پرسش پژوهش این است که آیا راهنمای مرزهای حافظه، با ثابت بودن فرصت‌های انتخاب متن، به بازیابی خود نوبت شاهد کمک می‌کند. ۳۷ منبع اولیه و مراحل ۱ تا ۱۶ ممیزی شدند. به دلیل وجود پیشینه‌ی مستقیم برای حافظه‌ی رویدادی، سهم منتخب یک پروتکل کنترل‌شده است. شاخص BM25 نوبتی، هشت لنگر، مجموعه‌ی پنجره‌های مجاز، طول هر پنجره و هزینه‌ی واقعی برای روش مرکزی، نویسنده‌ی ثابت و ۲۰ کنترل تصادفی یکسان نگه داشته شد. ۵۹۹ پرسش LoCoMo و ۲۴۴ پرسش QMSum در سه بودجه، ۵۵۶۳۸ ردیف خروجی تولید کردند. در ۱۰۲۴ واژه، اختلاف میانگین گفت‌وگویی نویسنده با میانگین تصادفی در LoCoMo برابر ۰٫۸۴ واحد درصد بود؛ بازه‌ی بوت‌استرپ خوشه‌ای توصیفی ۰٫۰۷ تا ۱٫۵۲ بود. این مقدار به آستانه‌ی کاربردیِ از پیش ثبت‌شده‌ی دو واحد درصد نرسید. اختلاف با مرکزی ۰٫۳۵ واحد درصد و بازه‌ی آن شامل صفر بود. در QMSum اختلاف با تصادفی منفی ۰٫۰۹ واحد درصد بود. نتیجه، برتری پایدار مرزبند را پشتیبانی نمی‌کند؛ ارزش اصلی در کنترل مخدوش‌کننده‌ها، محدود کردن ادعا و بازتولیدپذیری است. داده‌ها قبلا دیده شده‌اند؛ این مطالعه تاییدی مستقل نیست.

کلیدواژه‌ها: حافظه‌ی عامل؛ مرزبندی رویداد؛ بازیابی شاهد؛ فرصت انتخاب؛ هزینه‌ی برابر؛ ارزیابی بازتولیدپذیر.

۱. اهمیت، ضرورت و کاربرد

اگر دو روش مقدار متن یا فرصت انتخاب متفاوت داشته باشند، اختلاف عملکرد ممکن است از همین تفاوت بیاید. ثابت بودن فرمول BM25 با ثابت بودن نمایه و رتبه‌ی آن یکسان نیست. در مرحله‌ی ۱۶، نویسنده به جلسه‌ی شاهد بیشتری رسید، اما تعداد قطعات انتخابی برابر نبود و شاهد داخل جلسه معلوم نبود. اصلاح این نقص برای نتیجه‌گیری علمی و انتخاب حافظه‌ی کم‌هزینه ضروری است.

کاربرد مستقیم، ارزیاب قابل ممیزی برای مقایسه‌ی حافظه‌های متنی است: پژوهشگر می‌تواند ببیند آیا هزینه و فرصت واقعا برابرند، شاهد کامل آمده است یا فقط جلسه‌ی آن، و نتیجه در بازاجرای مستقل تکرار می‌شود یا نه. کاربرد احتمالی در طراحی دستیار مکالمه است؛ این مرحله خودِ دستیار پاسخ‌گو را ارزیابی نکرده است.

۲. پیشینه و ادعای تازگی

CompassMem [R05]، HingeMem [R11]، ES-Mem [R10]، SeCom [R09] و SEEM [R06] پیشینه‌ی مستقیم قطعه‌بندی موضوع/رویداد و حافظه‌ی ساخت‌یافته‌اند. ReFind [R16] گسترش متن پیرامون نوبت خام را بررسی کرده است. Fidelity Before Structure [R15] اهمیت متن بدون اتلاف و کنترل متغیرها را نشان می‌دهد. MemTrace [R36] انتساب خطای حافظه را در سطح عملیات بررسی می‌کند؛ آن کار تشخیص پسینی با پاسخ مرجع است، در حالی که انتخاب متن ما برچسب یا پاسخ مرجع نمی‌بیند.

بنابراین نوآوری الگوریتمی قطعی ادعا نمی‌شود. سهم بالقوه، قرارداد جفت‌شده‌ی خاص برای ثابت نگه داشتن هم‌زمان شاخص، لنگر، مجموعه‌ی نامزد و اندازه‌ی خروجی است. نبود نمونه‌ی کاملا یکسان در مرور محدود ما، اثبات تقدم جهانی نیست. اطلس، جدول هشت منبع پایه، شش خوشه‌ی ادبیات و ده جهت پژوهشی در پیوست‌های کدبنیان ارائه شده‌اند.

در علوم شناختی، مرزها به هدف، مکان، زمینه، پیش‌بینی و عدم قطعیت وابسته‌اند [R26–R29،R33]. نویسنده‌ی ما نویی واژگانی را می‌سنجد؛ آن را هم‌ارز ادراک اپیزودیک یا معنا در بحث سرل نمی‌دانیم. مطالعه‌ی ماشینی حاضر هیچ نتیجه‌ای درباره‌ی فهم ذاتی مدل به دست نمی‌دهد.

۳. طرح و قرارداد آزمایش

پروتکل و پیکربندی در commit محلی ۲۹۳۲۲۹۸، پیش از محاسبه‌ی خروجی مرحله‌ی ۱۷ ثبت شدند. کد و کنترل‌های اولیه در efde7cf ثبت شد. این سابقه ثبت عمومی زمان‌دار نیست. امتیازهای انتخاب ایده پس از اولین اجرا به‌صورت مستند تنظیم شده‌اند و شاهد انتخاب پیشینی محسوب نمی‌شوند.

متغیر مستقل، قانون انتخاب پنجره از مجموعه‌ی مشترک است. BM25 با k1=1.2 و b=0.75 روی متن اصلی تمام نقش‌ها ساخته می‌شود. هشت نوبت نخست، لنگرها را تعیین می‌کنند. در هر جلسه، میان لنگرها ناحیه‌های غیرهم‌پوشان ساخته می‌شود و بودجه نوبتی میان آن‌ها تقسیم می‌شود. همه‌ی پنجره‌های پیوسته با عرض تعیین‌شده و شامل لنگر نامزدند. پنجره‌ی مرکزی فاصله‌ی مرکز را کمینه می‌کند؛ نویسنده و تصادفی، هم‌پوشانی با اپیزود حامل لنگر را بیشینه و سپس همان قاعده‌ی مرکزی را اعمال می‌کنند.

نویسنده‌ی مرحله‌ی ۸ ثابت است: حداقل ۶۴، سقف ۱۶۰ واژه، آستانه‌ی ۰٫۸۵ و تاریخچه‌ی سه نوبت. کنترل‌های تصادفی، شمار قطعات ساخته‌شده‌ی هر جلسه را برابر نگه می‌دارند و از فضای پارتیشن معتبر به‌صورت یکنواخت نمونه می‌گیرند. طول تک‌اپیزود داخلی برابر نیست؛ طول پنجره‌ی خروجی در تک‌پرسش دقیقا برابر است. کنترل‌ها گذشته‌نگرند؛ نویسنده قطعه‌های بسته را با آینده تغییر نمی‌دهد؛ پرسش بعد از تاریخچه مطرح می‌شود.

۴. داده، سنجه و عدم قطعیت

جدول ۱. داده و سنجه‌ی ارزیابی

داده	واحد/حجم	شاهد	سنجه‌ی اصلی در این مرحله
LoCoMo	۷ گفت‌وگو، ۵۹۹ پرسش ثابت	شناسه‌ی نوبت شاهد	همه‌ی واژه‌های تمام نوبت‌های شاهد؛ میانگین مساوی گفت‌وگو
QMSum	۳۵ جلسه، ۲۴۴ پرسش اختصاصی	اجتماع بازه‌های مرتبطِ شامل دو انتها	کسر نوبت‌های مرتبطِ کامل؛ میانگین مساوی جلسه

بودجه، شمار واژه‌ی حاصل از عبارت منظم است، نه توکن مدل. نوبت نیمه‌بازیابی‌شده کامل محسوب نمی‌شود. برچسب موضوع، پاسخ، memory flag، timestamp و نقش افزوده وارد شاخص یا انتخاب نمی‌شوند. پنج پرسش QMSum دارای ۹ مورد نوبت خالی در اجتماع شاهدند؛ طبق طرح، فقط نوبت‌های خالی از مخرج خارج شده‌اند و پرسش‌ها باقی‌اند. همه‌ی ۵۹۹ پرسش LoCoMo شاهد غیرخالی دارند.

برآورد اصلی، اختلاف نویسنده با میانگین ۲۰ تصادفی در ۱۰۲۴ واژه است. ابتدا میانگین بذرها در هر پرسش و سپس میانگین پرسش در هر گفت‌وگو محاسبه می‌شود. بوت‌استرپ جفت‌شده با ۲۰۰۰ تکرار و بذر ۱۷، هفت گفت‌وگو را بازنمونه‌گیری می‌کند. QMSum ده خانواده‌ی منبع را بازنمونه‌گیری می‌کند و تمام جلسه‌های خانواده را حفظ می‌کند. این واحدها استقلال همه‌ی افراد یا موضوعات را تضمین نمی‌کنند. بذر و پرسش نمونه‌ی مستقل تلقی نشده‌اند؛ مقدار p تاییدی گزارش نمی‌شود.

۵. نتایج اصلی

جدول ۲. نتیجه‌ی اصلی در ۱۰۲۴ واژه

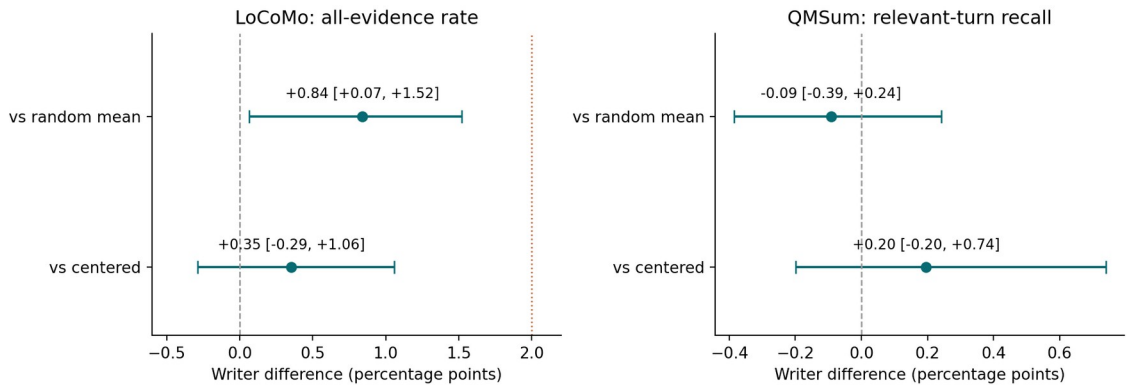
داده و سنجه	مرکزی	نویسنده	میانگین ۲۰ تصادفی
LoCoMo؛ تعداد پوشش کامل	۴۴۲ از ۵۹۹	۴۴۳ از ۵۹۹	۴۳۸٫۴۵ از ۵۹۹
LoCoMo؛ میانگین مساوی گفت‌وگو	۷۳٫۸۴٪	۷۴٫۱۹٪	۷۳٫۳۶٪
QMSum؛ میانگین یادآوری نوبت مرتبط	۳۲٫۳۳٪	۳۲٫۵۳٪	۳۲٫۶۲٪

عدد کسری تصادفی میانگین شمار موفقیت ۲۰ اجراست، نه شمار یک اجرای منفرد. درصدهای LoCoMo میانگین مساوی گفت‌وگو هستند و لزوما برابر تقسیم شمار کل بر ۵۹۹ نیستند. ۵۵۶۳۸ ردیف، تکرار شرایط روی ۸۴۳ پرسش است و حجم نمونه‌ی مستقل محسوب نمی‌شود.

جدول ۳. اختلاف‌های جفت‌شده و عدم قطعیت

مقایسه در ۱۰۲۴ واژه	اختلاف، واحد درصد	بازه‌ی توصیفی ۹۵٪
LoCoMo؛ نویسنده منهای تصادفی	+۰٫۸۴	+۰٫۰۷ تا +۱٫۵۲
LoCoMo؛ نویسنده منهای مرکزی	+۰٫۳۵	−۰٫۲۹ تا +۱٫۰۶
QMSum؛ نویسنده منهای تصادفی	−۰٫۰۹	−۰٫۳۹ تا +۰٫۲۴
QMSum؛ نویسنده منهای مرکزی	+۰٫۲۰	−۰٫۲۰ تا +۰٫۷۴

آستانه‌ی کاربردی، اثر حداقل دو واحد درصد همراه با بازه‌ی بالای صفر و نبود افت نقطه‌ای در برابر مرکزی بود. شرط اندازه‌ی اثر برقرار نشد. بازه‌ی بالای صفر برای مقایسه‌ی نخست مجوز ادعای برتری کاربردی یا تعمیم مستقل نیست.



شکل ۱؛ اختلاف‌ها و بازه‌های توصیفی.

۶. حساسیت و تحلیل شکست

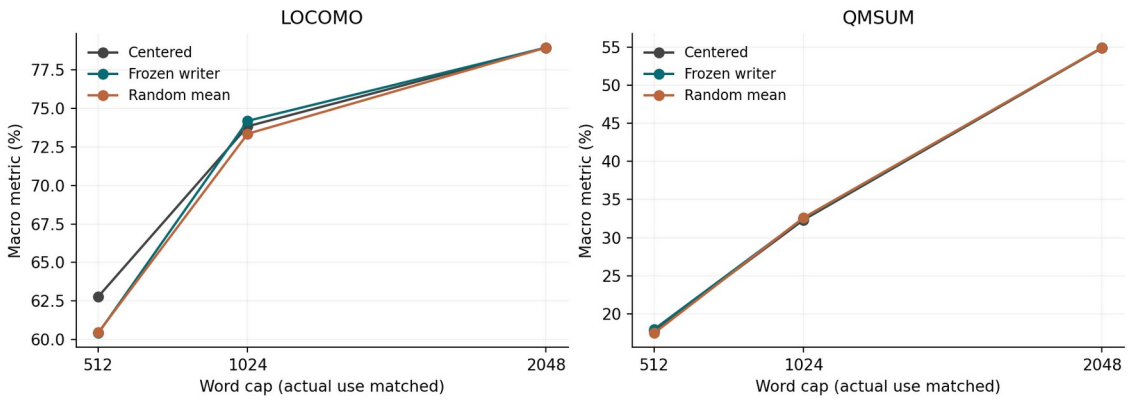
جدول ۴. حساسیت به بودجه

بودجه	LoCoMo مرکزی/نویسنده؛ شمار کامل	QMSum مرکزی/نویسنده؛ میانگین یادآوری
۵۱۲	۳۷۳ / ۳۵۹	۱۷٫۷۷٪ / ۱۸٫۰۰٪
۱۰۲۴	۴۴۲ / ۴۴۳	۳۲٫۳۳٪ / ۳۲٫۵۳٪
۲۰۴۸	۴۷۲ / ۴۷۲	۵۴٫۸۷٪ / ۵۴٫۸۸٪

در سقف ۵۱۲، نویسنده ۱۴ موفقیت کمتر از مرکزی دارد. در ۲۰۴۸، شمار کامل LoCoMo در همه‌ی روش‌ها ۴۷۲ است؛ این تساوی به معنی یکسان بودن متن تمام پنجره‌ها نیست. در سقف ۱۰۲۴ همه‌ی روش‌ها دقیقا ۱۰۲۴ واژه مصرف می‌کنند. در ۲۰۴۸، ظرفیت ناحیه‌های مشترک برای ۲۴ پرسش LoCoMo و شش پرسش QMSum کمتر از سقف است؛ مصرف واقعی همچنان در تمام روش‌ها دقیقا یکسان است.

در LoCoMo اصلی، ۴۴۱ پرسش در هر دو روش مرکزی/نویسنده موفق، ۱۵۵ در هر دو ناموفق، دو فقط با نویسنده و یک فقط با مرکزی موفق‌اند. پنجره‌ها در ۴۸۹ پرسش تغییر کرده‌اند؛ تغییر متن لزوما نتیجه‌ی معیار را تغییر نمی‌دهد. همه‌ی جلسه‌های شاهد فقط در ۴۹۳ پرسش در مجموعه‌ی جلسه‌های قابل دسترس‌اند؛ بنابراین ۱۰۶ پرسش با تغییر پنجره‌ی درون همین جلسه‌ها قابل نجات نیستند. از ۴۹۳ پرسش باقی‌مانده نیز نویسنده در ۵۰ مورد همه‌ی نوبت‌ها را کامل نیاورده است. این تشخیص پسینی محدودیت لنگر و تخصیص را از هم جدا می‌کند، اما ثابت نمی‌کند کدام مرز انسانی باید انتخاب می‌شد.

در زیرگروه چندنوبتی، نویسنده ۲۹ از ۹۰ و مرکزی ۲۸ از ۹۰ موفق‌اند؛ در چندجلسه‌ای، ۱۱ از ۶۵ در برابر ۱۰ از ۶۵. این زیرگروه‌ها توصیفی‌اند و برای ساخت ادعای تازه انتخاب نشده‌اند. خروجی همه‌ی زیرگروه‌ها و بذرها محفوظ است.



شکل ۲؛ حساسیت به بودجه.

۷. بازتحلیل تاریخی مرحله‌ی ۱۶

بازنمونه‌گیری پسینی در سطح ۱۰ شخصیت، با حفظ سه دوره‌ی هر شخصیت، اختلاف نقطه‌ای قبلی را عوض نمی‌کند. در آزمایش اصلی تاریخی، اختلاف ۳٫۰۷ واحد درصد و بازه‌ی توصیفی جدید ۱٫۲۹ تا ۴٫۹۲ است. در حساسیت تاریخیِ تعداد انتخاب برابر، اختلاف ۱٫۵۶ واحد درصد و بازه‌ی منفی ۰٫۱۵ تا مثبت ۳٫۲۴ است. بازه‌ی دوم شامل صفر می‌شود. این تحلیل روی خروجی‌های قبلی اجرا شده، نتایج تاریخی را بازنویسی نکرده و آزمایش جدید Memora نیست. تفاوت این اعداد با مرحله‌ی ۱۷ را نمی‌توان صرفا به حذف مخدوش‌کننده نسبت داد؛ داده، واحد شاهد و سیاست انتخاب نیز متفاوت‌اند.

۸. هزینه، کنترل کیفیت و بازتولید

هسته‌ی اجرا Python استاندارد، CPU و بدون API است. اجرای اصلاح‌شده ۲۲٫۷۰ ثانیه و بازاجرا ۲۲٫۵۲ ثانیه زمان دیواری داشت؛ اوج حافظه‌ی فرایند نخست حدود ۳۷۵٫۶۲ MiB بود. این زمان شامل بارگذاری/کنترل محلی و امتیازدهی است، نه دانلود، جست‌وجوی ادبیات یا ساخت گزارش؛ معیار کارایی روی همه‌ی رایانه‌ها نیست. هزینه‌ی API صفر است، نه هزینه‌ی کل پژوهش.

در هفت گفت‌وگوی LoCoMo، ۴۲۱۴ نوبت غیرخالی، ۹۶۸۰۶ واژه و ۱۲۰۹ قطعه‌ی نویسنده ساخته شد؛ در QMSum، ۲۰۷۰۱ نوبت غیرخالی، ۳۰۲۶۳۹ واژه و ۳۳۲۸ قطعه. هر کنترل تصادفی همان شمار پارتیشن نوبتی در هر جلسه را دارد. در هشت جفت تاریخچه–بذر LoCoMo و سه جفت QMSum، یک پارتیشن بدون واژه‌ی قابل شمارش است؛ شمار بازه‌های غیرخالی یک واحد کمتر می‌شود. تساوی شمار پارتیشن با تساوی بازه‌ی غیرخالی یکی نیست؛ پنجره، هزینه و فرصت خروجی همچنان دقیقا برابرند. خروجی در هر پرسش هشت پنجره است؛ تعداد جلسه‌ی خروجی در LoCoMo میانگین ۶٫۳۱ و در QMSum یک است. هشت پنجره لزوما هشت اپیزود نیستند.

اعتبارسنج ۲۵۲۹ گروه پرسش–بودجه را برای تساوی دقیق هزینه، عرض پنجره، تعداد انتخاب، تعداد جلسه و fingerprint فرصت بررسی کرد. بازاجرا فایل فشرده‌ی ردیف‌ها را بایت‌به‌بایت تکرار کرد. ۵۲ آزمون جمع‌آوری شد: ۵۱ موفق و یک آزمون تاریخی مرحله‌ی ۱۴ به علت نبود داده‌ی رسمی Memora در مسیر آزمون اجرا نشد؛ همه‌ی آزمون‌های مرحله‌ی ۱۷ اجرا شدند.

در ممیزی پس از نخستین اجرا، یک خطای سنجه‌ی فرعی جلسه‌ای و دو فرض نادرست اعتبارسنج درباره‌ی پر شدن سقف و نوبت خالی QMSum اصلاح شد. مقابله‌ی همه‌ی ردیف‌ها نشان داد فقط all_gold_sessions در ۶۹۹۶ ردیف تغییر کرده و انتخاب متن، هزینه و معیارهای نوبتی ثابت مانده‌اند. شرح و سند عددی اصلاح در پیوست موجود است؛ نتیجه‌ی قابل ارائه از اجرای اصلاح‌شده است.

۹. محدودیت، تصمیم و مسیر ادامه

اثر سنجیده‌شده به یک نویسنده‌ی واژگانی، هشت لنگر و این قانون انتخاب وابسته است. طول اپیزودهای داخلی برابر نشده است. برچسب LoCoMo ممکن است ناقص باشد و QMSum شاهد کمینه‌ی پاسخ نیست. هفت گفت‌وگو توان تعمیم محدودی دارند. داده‌ها بارها استفاده شده‌اند و تصحیح چندمقایسه‌ای برای نتیجه‌ی تاییدی مطرح نشده است. پاسخ مولد، استفاده‌ی صحیح از شاهد، فراموشی معتبر و ادراک انسانی سنجیده نشده‌اند.

قوی‌ترین سهم قابل دفاع اکنون «پروتکل انتساب و ممیزی اثر مرز» است. این چرخه دلیلی برای پیچیده‌تر کردن فوری حافظه با گراف یا مدل پرهزینه به دست نداد. برای تحویل کارشناسی، تثبیت ارزیاب، فصل روش/نتایج، راهنمای اجرا و دفاع از نتیجه‌ی منفی کافی و کم‌ریسک‌تر است؛ پذیرش دانشگاهی با استاد است. مسیر پژوهشی بعدی می‌تواند ثبت عمومی پروتکل، داده‌ی تازه با شاهد ریزدانه، و یک بازیاب دوم محلی باشد. انتخاب داده و بودجه باید پیش از دیدن نتیجه ثبت شود. افزایش بذرهای همین داده جای استقلال را نمی‌گیرد.

گزارش حاضر فصل پیشرفت پژوهش و بسته‌ی مرحله‌ی ۱۷ است؛ پایان‌نامه‌ی نهایی دانشگاه پس از تطبیق قالب و الزامات استاد تهیه می‌شود. انتشار عمومی این بسته مطابق دستور پژوهشگر تا تایید نهایی متوقف است.

۱۰. سپاسگزاری

از استاد امیر نوری ولنده، راهنمای دانشگاهی پروژه، برای هدایت علمی و پشتیبانی از ایده‌های نو سپاسگزارم. از دکتر آرش فکری، استاد من در علوم اعصاب شناختی و بنیان‌گذار FARDIAT، مجتمع فوق تخصصی مغز و شناخت، برای آموزش‌ها و بررسی و تایید پروپوزال سپاسگزارم. این آموزش‌ها خاستگاه شناختی پرسش پژوهش را شکل داده‌اند.

راهنمای بسته و بازتولید

تمام نتیجه‌ها در فایل‌های عددی قابل بررسی‌اند. کد اصلی فقط Python استاندارد و CPU می‌خواهد. متن خام داده، قلم و مقاله‌های دانلودشده در بسته نیستند. برای حفظ سابقه، خروجی بازاجرا در مسیر تازه نوشته می‌شود.

اجرای اصلی — scripts/run_phase17_fixed_anchors.py

کنترل برابری و اعداد — scripts/validate_phase17.py

تحلیل مکمل و شکل‌ها — scripts/analyze_phase17.py

خروجی تفصیلی — results/phase17_rows.json.gz

خلاصه و عدم قطعیت — results/phase17_summary.json

گواه بازاجرا و آزمون‌ها — results/phase17_validation.json

اطلس ۳۷ منبع و شناسنامه — docs/phase17_literature_atlas.md

ممیزی مراحل ۱ تا ۱۶ — docs/phase17_state_ledger.md

ده ایده و نقد سه گزینه — docs/phase17_candidates.md

تحلیل شکاف و پیشینه — docs/phase17_frontier_synthesis.md

راهنمای کامل اجرا — docs/phase17_reproduce.md

فرمان‌های اجرای اصلی

```
python scripts/fetch_data.py
python scripts/fetch_phase10_data.py --download
python -m unittest discover -s tests -v
python scripts/run_phase17_fixed_anchors.py --output-dir /tmp/phase17-review-run
python scripts/validate_phase17.py --directory /tmp/phase17-review-run
```

شاخه‌ی آماده: research/phase17-fixed-anchor-evidence. متن PR و بسته‌ی تغییرات آماده‌اند. هیچ push، PR عمومی یا release در این چرخه انجام نشده است.

منابع و شناسنامه‌ی انتشار

شناسه‌های R01 تا R37 با اطلس همراه یکسان‌اند. ارجاع‌ها به سبک عددی تنظیم شده‌اند؛ اطلاعات کامل نویسندگان، دامنه‌ی مطالعه، کد، رتبه‌ی مجله و هش منبع در اطلس ماشینی محفوظ است. دسترسی: ۲۱ اکتبر ۲۰۲۶.

[R01] Adyasha Maharana, Dong-Ho Lee, Sergey Tulyakov, Mohit Bansal, Francesco Barbieri, Yuwei Fang. Evaluating Very Long-Term Conversational Memory of LLM Agents.
ACL 2024؛ داوری‌شده؛ چکیده، روش یا بخش‌های مرتبط متن اصلی.
https://doi.org/10.18653/v1/2024.acl-long.747

[R02] Di Wu, Hongwei Wang, Wenhao Yu, Yuwei Zhang, Kai-Wei Chang, Dong Yu. LongMemEval: Benchmarking Chat Assistants on Long-Term Interactive Memory.
ICLR 2025؛ داوری‌شده؛ چکیده، روش یا بخش‌های مرتبط متن اصلی.
https://proceedings.iclr.cc/paper_files/paper/2025/hash/d813d324dbf0598bbdc9c8e79740ed01-Abstract-Conference.html

[R03] Ming Zhong, Da Yin, Tao Yu, et al. QMSum: A New Benchmark for Query-based Multi-domain Meeting Summarization.
NAACL 2021؛ داوری‌شده؛ چکیده، روش یا بخش‌های مرتبط متن اصلی.
https://doi.org/10.18653/v1/2021.naacl-main.472

[R04] Md Nayem Uddin, Kumar Shubham, Eduardo Blanco, Chitta Baral, Gengyu Wang. From Recall to Forgetting: Benchmarking Long-Term Memory for Personalized Agents.
Findings ACL 2026؛ داوری‌شده؛ چکیده، روش یا بخش‌های مرتبط متن اصلی.
https://doi.org/10.18653/v1/2026.findings-acl.1337

[R05] Yuyang Hu, Jiongnan Liu, Jiejun Tan, Yutao Zhu, Zhicheng Dou. Memory Matters More: Event-Centric Memory as a Logic Map for Agent Searching and Reasoning.
Findings ACL 2026؛ داوری‌شده؛ چکیده، روش یا بخش‌های مرتبط متن اصلی.
https://doi.org/10.18653/v1/2026.findings-acl.1123

[R06] Zhengxuan Lu, Dongfang Li, Yukun Shi, Beilun Wang, Longyue Wang, Baotian Hu. Structured Episodic Event Memory.
ACL 2026؛ داوری‌شده؛ چکیده، روش یا بخش‌های مرتبط متن اصلی.
https://doi.org/10.18653/v1/2026.acl-long.277

[R07] Pratyay Banerjee, Masud Moshtaghi, Shivashankar Subramanian, Amita Misra, Ankit Chadha. APEX-MEM: Agentic Semi-Structured Memory with Temporal Reasoning for Long-Term Conversational AI.
ACL 2026؛ داوری‌شده؛ چکیده، روش یا بخش‌های مرتبط متن اصلی.
https://doi.org/10.18653/v1/2026.acl-long.749

[R08] Yifei Li, Weidong Guo, Lingling Zhang, et al. Locomo-Plus: Beyond-Factual Cognitive Memory Evaluation Framework for LLM Agents.
ACL 2026؛ داوری‌شده؛ چکیده، روش یا بخش‌های مرتبط متن اصلی.
https://doi.org/10.18653/v1/2026.acl-long.1150

منابع و شناسنامه‌ی انتشار؛ ادامه

[R09] Zhuoshi Pan, Qianhui Wu, Huiqiang Jiang, et al. SeCom: On Memory Construction and Retrieval for Personalized Conversational Agents.

ICLR 2025؛ داوری‌شده؛ چکیده، روش یا بخش‌های مرتبط متن اصلی.

https://proceedings.iclr.cc/paper_files/paper/2025/hash/e56f394bbd4f0ec81393d767caa5a31b-Abstract-Conference.html

[R10] Huhai Zou, Tianhao Sun, Chuanjiang He, et al. ES-Mem: Event Segmentation-Based Memory for Long-Term Dialogue Agents.

arXiv 2026؛ پیش‌چاپ، محل داوری تایید نشد؛ فراداده و چکیده؛ داوری کامل روش انجام نشده.

https://arxiv.org/abs/2601.07582

[R11] Yijie Zhong, Yunfan Gao, Haofen Wang. HingeMem: Boundary Guided Long-Term Memory with Query Adaptive Retrieval for Scalable Dialogues.

The Web Conference 2026؛ داوری‌شده؛ فراداده و چکیده؛ داوری کامل روش انجام نشده.

https://doi.org/10.1145/3774904.3792089

[R12] Kai Li, Xuanqing Yu, Ziyi Ni, et al. TiMem: Temporal-Hierarchical Memory Consolidation for Long-Horizon Conversational Agents.

Findings ACL 2026؛ داوری‌شده؛ فراداده و چکیده؛ داوری کامل روش انجام نشده.

https://doi.org/10.18653/v1/2026.findings-acl.1091

[R13] Shuqi Cao, Jingyi He, Fei Tan. HiGMem: A Hierarchical and LLM-Guided Memory System for Long-Term Conversational Agents.

Findings ACL 2026؛ داوری‌شده؛ فراداده و چکیده؛ داوری کامل روش انجام نشده.

https://doi.org/10.18653/v1/2026.findings-acl.1690

[R14] Derong Xu, Yi Wen, Pengyue Jia, et al. From Single to Multi-Granularity: Toward Long-Term Memory Association and Selection of Conversational Agents.

arXiv 2025؛ پیش‌چاپ، محل داوری تایید نشد؛ فراداده و چکیده؛ داوری کامل روش انجام نشده.

https://arxiv.org/abs/2505.19549

[R15] Tao An. Fidelity Before Structure: Verbatim Chunks Beat Lossy Artifact Extraction in Long-Conversation LLM Memory.

arXiv؛ نخست ۲۰۲۵، نسخه‌ی ۴ در ژوئیه‌ی ۲۰۲۶؛ پیش‌چاپ؛ چکیده، روش یا بخش‌های مرتبط متن اصلی.

https://arxiv.org/abs/2601.00821

[R16] Ruizhe Li, Licheng Zhang, Benfeng Xu, Mingxuan Du, Zheren Fu, Weidong Chen. When Your Agent Opens the Chat App: Agent-Controlled Search over Raw Chat Logs Rivals Structured Memory.

arXiv 2026؛ پیش‌چاپ؛ چکیده، روش یا بخش‌های مرتبط متن اصلی.

https://arxiv.org/abs/2608.12888

منابع و شناسنامه‌ی انتشار؛ ادامه

[R17] Dongfang Li, Zixuan Liu, Junmai Wang, et al. LycheeMemory V2: Efficient Long-Term Memory for LLM Agents via Semantic Segment-Level Consolidation.

arXiv؛ نسخه‌ی ۲ در ۱۴ اکتبر ۲۰۲۶؛ پیش‌چاپ؛ فراداده و چکیده؛ داوری کامل روش انجام نشده.

https://arxiv.org/abs/2608.12990

[R18] Peijun Qing, Fobo Shi, Soroush Vosoughi. UTILMEM: Benchmarking Evidence Utilization in Long-Term Conversational Memory.

arXiv 2026؛ پیش‌چاپ؛ چکیده، روش یا بخش‌های مرتبط متن اصلی.

https://arxiv.org/abs/2608.30508

[R19] Yongjie Zhou, Shuai Wang, Bevan Koopman, Guido Zuccon. Beyond Chunk-Then-Embed: A Comprehensive Taxonomy and Evaluation of Document Chunking Strategies for Information Retrieval.

arXiv 2026؛ پیش‌چاپ؛ چکیده، روش یا بخش‌های مرتبط متن اصلی.

https://arxiv.org/abs/2602.16974

[R20] Michael Günther, Isabelle Mohr, Daniel James Williams, Bo Wang, Han Xiao. Late Chunking: Contextual Chunk Embeddings Using Long-Context Embedding Models.

arXiv؛ نخست ۲۰۲۴، نسخه‌ی ۳ در ۲۰۲۵؛ پیش‌چاپ؛ فراداده و چکیده؛ داوری کامل روش انجام نشده.

https://arxiv.org/abs/2409.04701

[R21] Andre Vicente Duarte, João DS Marques, Miguel Graça, Miguel Freire, Lei Li, Arlindo L. Oliveira. LumberChunker: Long-Form Narrative Document Segmentation.

Findings EMNLP 2024؛ داوری‌شده؛ فراداده و چکیده؛ داوری کامل روش انجام نشده.

https://doi.org/10.18653/v1/2024.findings-emnlp.377

[R22] Tong Chen, Hongwei Wang, Sihao Chen, et al. Dense X Retrieval: What Retrieval Granularity Should We Use?.

EMNLP 2024؛ داوری‌شده؛ فراداده و چکیده؛ داوری کامل روش انجام نشده.

https://doi.org/10.18653/v1/2024.emnlp-main.845

[R23] Parth Sarthi, Salman Abdullah, Aditi Tuli, Shubh Khanna, Anna Goldie, Christopher D. Manning. RAPTOR: Recursive Abstractive Processing for Tree-Organized Retrieval.

ICLR 2024؛ داوری‌شده؛ فراداده و چکیده؛ داوری کامل روش انجام نشده.

https://proceedings.iclr.cc/paper_files/paper/2024/hash/8a2acd174940dbca361a6398a4f9df91-Abstract-Conference.html

[R24] Bernal Jiménez Gutiérrez, Yiheng Shu, Yu Gu, Michihiro Yasunaga, Yu Su. HippoRAG: Neurobiologically Inspired Long-Term Memory for Large Language Models.

NeurIPS 2024؛ داوری‌شده؛ فراداده و چکیده؛ داوری کامل روش انجام نشده.

https://doi.org/10.52202/079017-1902

منابع و شناسنامه‌ی انتشار؛ ادامه

[R25] Wujiang Xu, Zujie Liang, Kai Mei, Hang Gao, Juntao Tan, Yongfeng Zhang. A-MEM: Agentic Memory for LLM Agents.
NeurIPS 2025؛ داوری‌شده؛ فراداده و چکیده؛ داوری کامل روش انجام نشده.
https://doi.org/10.52202/085713-0593

[R26] Tan T. Nguyen, Joset A. Etzel, Matthew A. Bezdek, Jeffrey M. Zacks. Multiple event segmentation mechanisms in the human brain.
eLife 14:RP107955؛ نسخه‌ی نهایی ۷ ژوئیه‌ی ۲۰۲۶؛ چکیده، روش یا بخش‌های مرتبط متن اصلی.
https://doi.org/10.7554/eLife.107955.3

[R27] Yue Li, Mikael Johansson, Andrey R. Nikolaev. Hierarchical event segmentation of episodic memory in virtual reality.
npj Science of Learning 10:25؛ ۲۰۲۵؛ داوری‌شده؛ چکیده، روش یا بخش‌های مرتبط متن اصلی.
https://doi.org/10.1038/s41539-025-00321-6

[R28] Ryan A. Panela, Alexander J. Barnett, Morgan D. Barense, Björn Herrmann. Event segmentation applications in large language model enabled automated recall assessments.
Communications Psychology 3:184؛ ۲۰۲۵؛ داوری‌شده؛ چکیده، روش یا بخش‌های مرتبط متن اصلی.
https://doi.org/10.1038/s44271-025-00359-7

[R29] Doruntinë Zogaj, Regine Bader, Axel Mecklinger. How the brain segments experience: ERP evidence of event boundaries enhancing memory formation in narratives.
Cognitive, Affective, & Behavioral Neuroscience؛ ۲۰۲۶؛ داوری‌شده؛ فراداده و چکیده؛ داوری کامل روش انجام نشده.
https://doi.org/10.3758/s13415-026-01399-0

[R30] Ryan Prescott Adams, David J. C. MacKay. Bayesian Online Changepoint Detection.
arXiv 2007؛ پیش‌چاپ بنیانی؛ فراداده و چکیده؛ داوری کامل روش انجام نشده.
https://arxiv.org/abs/0710.3742

[R31] Marti A. Hearst. Text Tiling: Segmenting Text into Multi-paragraph Subtopic Passages.
Computational Linguistics 23(1)؛ ۱۹۹۷؛ داوری‌شده؛ فراداده و چکیده؛ داوری کامل روش انجام نشده.
https://aclanthology.org/J97-1003/

[R32] Yuanzhe Hu, Yu Wang, Julian McAuley. Evaluating Memory in LLM Agents via Incremental Multi-Turn Interactions.
ICLR 2026؛ داوری‌شده؛ نسخه‌ی اولیه ۲۰۲۵؛ فراداده و چکیده؛ داوری کامل روش انجام نشده.
https://proceedings.iclr.cc/paper_files/paper/2026/hash/fd1eff9dd295df50a41f2521942fa31d-Abstract-Conference.html

منابع و شناسنامه‌ی انتشار؛ ادامه

[R33] Jeffrey M. Zacks, Nicole K. Speer, Khena M. Swallow, Todd S. Braver, Jeremy R. Reynolds. Event perception: A mind-brain perspective.

Psychological Bulletin 133(2)؛ ۲۰۰۷؛ مقاله‌ی مروری داوری‌شده؛ فراداده و چکیده؛ داوری کامل روش انجام نشده.

https://doi.org/10.1037/0033-2909.133.2.273

[R34] Zihao Lu, Zhihang Yuan, Litu Ou, Lei Shi. Propose, Verify, Commit: Evidence-Grounded Memory for Long-Horizon Multi-Actor Conversations.

arXiv؛ نسخه‌ی ۲ در ۱۳ اکتبر ۲۰۲۶؛ پیش‌چاپ؛ چکیده، روش یا بخش‌های مرتبط متن اصلی.

https://arxiv.org/abs/2609.23465

[R35] Pengfeng Song, Yunkai Zhuang, Liye Shi. TEM: Temporal State Tracking Memory for Large Language Model Agents.

arXiv؛ ۱۵ اکتبر ۲۰۲۶؛ پیش‌چاپ؛ فراداده و چکیده؛ داوری کامل روش انجام نشده.

https://arxiv.org/abs/2610.21900

[R36] Xinle Deng, Ruobin Zhong, Hujin Peng, et al. MemTrace: Tracing and Attributing Errors in Large Language Model Memory Systems.

arXiv؛ نسخه‌ی ۴ در ۸ اکتبر ۲۰۲۶؛ پیش‌چاپ؛ چکیده، روش یا بخش‌های مرتبط متن اصلی.

https://arxiv.org/abs/2605.28732

[R37] Jizhan Fang, Xinle Deng, Haoming Xu, et al. LightMem: Lightweight and Efficient Memory-Augmented Generation.

ICLR 2026؛ داوری‌شده؛ فراداده و چکیده؛ داوری کامل روش انجام نشده.

https://proceedings.iclr.cc/paper_files/paper/2026/hash/a05b72653ec5b473732129829ae04195-Abstract-Conference.html