دانشگاه آزاد اسلامی واحد کرج

درس پروژه‌ی کارشناسی مهندسی کامپیوتر

ارزیابی کنترل‌شده‌ی قطعه‌بندی و تحلیل تشخیصی بازیابی شاهد در حافظه‌ی گفت‌وگویی

پیش‌نویس یکپارچه‌ی پایان‌نامه

پژوهشگر یوسف ابوالفتحی روزبهانی

استاد راهنمای دانشگاهی استاد امیر نوری

راهنمای آموزشی علوم اعصاب شناختی دکتر آرش فکری

فردیت FARDIAT مجتمع فوق تخصصی مغز و شناخت

۲۷ اکتبر ۲۰۲۶

github.com/yousofab/event-memory-retrieval

چکیده

حافظه‌ی گفت‌وگویی باید از تاریخچه‌ی طولانی، شاهد مرتبط با پرسش را زیر بودجه‌ی محدود بازیابی کند. تغییر قطعه‌بندی می‌تواند هم‌زمان تعداد واحدها، طول اسناد، آمار رتبه‌بندی و فرصت انتخاب را تغییر دهد و تفسیر اثر معماری را دشوار کند. هدف این پژوهش، ارزیابی کنترل‌شده‌ی راهنمای مرز و تشخیص محدودیت بازیابی شاهد در قرارداد محاسباتی مشخص است. مسیر تجربی تا مرحله‌ی ۱۹ با کد و داده‌ی نسخه‌دار و خروجی قابل بازتولید انجام شده است.

چارچوب محوری، نمایه‌ی BM25 نوبتی، لنگرها، پنجره‌های مجاز و هزینه‌ی واقعی را میان انتخابگرها مشترک می‌کند. ممیز آفلاین سپس شرط لازم و کافی پوشش کامل و کمترین بودجه را در همان هندسه تعیین می‌کند. تحلیل اصلی LoCoMo شامل ۵۹۹ پرسش در هفت گفت‌وگوست؛ QMSum با ۲۴۴ پرسش در ۳۵ جلسه و زیرمجموعه‌ی بیرونی EverMemBench-Dynamic با ۶۰۹ پرسش در چهار پروژه‌ی تولیدشده نقش‌های مکمل دارند.

در فضای ثابت و بودجه‌ی ۱۰۲۴ واژه، نویسنده ۴۴۳ پرسش LoCoMo را کامل می‌پوشاند و سقف تشخیصی ۴۶۸ مورد است. شکست‌ها به ۱۰۶ جلسه‌ی غایب، ۲۵ هندسه‌ی ناممکن و ۲۵ انتخاب ناموفقِ دارای امکان افراز می‌شوند. رزرو هشت جلسه، دسترسی کامل را از ۴۹۳ به ۵۰۷ مورد افزایش و پوشش واقعی را از ۴۴۳ به ۴۰۱ کاهش می‌دهد. QMSum نیز هم‌راستایی تقریبی مرز موضوع را با بهبود پوشش بازیابی همراه نشان نمی‌دهد.

نتیجه‌ی مرکزی، تمایز دسترسی، ظرفیت محلی و انتخاب است. سه مشارکت پژوهش، چارچوب کنترل‌شده، تجزیه‌ی تشخیصی دقیق در فضای ثابت و ناهم‌جهتی دسترسی و مونتاژ شاهد هستند. یافته‌ها به پوشش شاهد برچسبی تعلق دارند و کیفیت پاسخ مولد، فهم فلسفی یا ادراک انسانی را اندازه نمی‌گیرند. سابقه‌ی استفاده‌ی دوباره از داده و تحلیل‌های پس از نتیجه صریح حفظ شده است.

کلیدواژه‌ها حافظه‌ی گفت‌وگویی، قطعه‌بندی رویداد، بازیابی شاهد، امکان‌پذیری، تحلیل شکست، بازتولیدپذیری

Abstract

Conversational memory must retrieve useful evidence from long histories under a limited context budget. Changing memory boundaries can also change document counts, lengths, ranking statistics and selection opportunities, making architectural effects difficult to attribute. This thesis develops a controlled evaluation framework and an offline diagnostic for annotated evidence retrieval.

The central evaluation holds a turn-level BM25 index, anchors, legal windows and actual source-word costs fixed across selectors. An annotation-assisted auditor then determines exact complete-evidence feasibility and the minimum budget within that geometry. The core LoCoMo analysis uses 599 reused questions from seven conversations. Complementary analyses use 244 QMSum queries from 35 meetings and 609 fine-grained EverMemBench-Dynamic queries from four generated projects.

At 1,024 source words, the frozen writer completely covers 443 LoCoMo references, while the conditional diagnostic ceiling is 468. Its 156 failures comprise 106 missing-session cases, 25 geometry-infeasible cases and 25 feasible selection misses. Reserving eight sessions increases complete-session access from 493 to 507 questions, but decreases realized complete evidence from 443 to 401. QMSum similarly shows that approximate topic-onset alignment need not translate into higher retrieval coverage.

The contributions are controlled architecture evaluation, exact diagnosis within a fixed window space, and the empirical separation of session access from local evidence assembly. These are bounded retrieval findings. They do not measure answer accuracy, philosophical understanding or human episodic perception. Reused data, descriptive cluster uncertainty and post-result amendments retain their explicit status. The experimental scope ends at Phase19; the integrated manuscript synthesizes existing measurements without a new experiment.

Keywords conversational memory, event segmentation, evidence retrieval, feasibility, failure diagnosis, reproducibility

فهرست مطالب

فصل ۱ کلیات پژوهش ۵

فصل ۲ مبانی و پیشینه‌ی پژوهش ۸

فصل ۳ داده و روش پژوهش ۱۲

فصل ۴ سنتز چارچوب کنترل‌شده‌ی ارزیابی ۱۵

فصل ۵ شکاف هم‌راستایی مرز و پوشش بازیابی ۱۸

فصل ۶ تجزیه‌ی تشخیصی و مونتاژ شاهد ۲۱

فصل ۷ بحث و حدود اعتبار یافته‌ها ۲۶

فصل ۸ نتیجه‌گیری و ادامه‌ی پژوهش ۳۰

منابع بیرونی ۳۱

منابع داخلی و راهنمای شواهد ۳۴

پیوست الف نمادگذاری و شرط دقیق ۳۶

پیوست ب نقشه‌ی بازتولید ۳۷

پیوست پ واژه‌نامه ۳۸

فصل ۱ کلیات پژوهش

۱.۱ مسئله‌ی پژوهش

عامل گفت‌وگویی در تعامل طولانی با مسئله‌ای فراتر از نگهداری متن روبه‌روست. اطلاعات لازم برای یک پرسش ممکن است در چند نوبت، چند جلسه یا میان روایت‌های نامرتبط پراکنده باشد. سامانه باید زیر بودجه‌ی محدود، بخشی از گذشته را به متن قابل استفاده تبدیل کند. در این زنجیره، نحوه‌ی ساخت واحد حافظه، نمایه‌سازی، رتبه‌بندی و انتخاب زمینه همگی می‌توانند نتیجه را تغییر دهند. ادبیات حافظه‌ی گفت‌وگویی نیز این مراحل را با ساختارها و سنجه‌های متنوع بررسی می‌کند [P05، P08، P09].

ایده‌ی آغازین این پروژه آن بود که تغییر زمینه یا موضوع در گفت‌وگو می‌تواند برای ساخت واحدهای حافظه مفید باشد. یک جلسه ممکن است چند موضوع را در بر بگیرد و واحد جلسه برای بازیابی بیش از حد درشت باشد. از طرف دیگر، ذخیره‌ی هر نوبت به‌تنهایی ممکن است وابستگی‌های محلی را از هم جدا کند. پژوهش‌های بخش‌بندی گفت‌وگو و حافظه‌ی رویدادی این مسئله را پیش از پروژه‌ی حاضر مطرح کرده‌اند [P09، P10].

پرسش دشوار آن است که نتیجه‌ی مشاهده‌شده را به کدام جزء نسبت دهیم. تغییر مرز قطعه می‌تواند تعداد قطعه‌ها و طول اسناد را نیز عوض کند. حتی با فرمول رتبه‌بندی ثابت، امتیازها از تغییر آمار نمایه تاثیر می‌گیرند. بنابراین ارزیابی یک معماری به تعریف روشن هزینه، فرصت انتخاب و شاهد نیاز دارد. پژوهش حاضر همین مسئله‌ی انتساب و سپس محل شکست را موضوع اصلی خود قرار می‌دهد.

۱.۲ اهمیت و ضرورت

اهمیت عملی پژوهش در تصمیم مهندسی پیش از افزایش پیچیدگی سامانه است. وقتی پاسخ یا پوشش شاهد ضعیف است، تغییر مرزبند تنها یکی از اصلاح‌های ممکن است. اگر جلسه‌ی شاهد اصلا در مسیر نامزدگیری حاضر نباشد، تنظیم مرز در پنجره‌های موجود آن را وارد نمی‌کند. اگر بودجه‌ی محلی برای پوشش متن مرجع کافی نباشد، انتخاب بهتر در همان فضای محدود نیز پاسخ سنجه‌ی کامل‌پوشانی را عوض نمی‌کند. تفکیک این وضعیت‌ها می‌تواند تلاش توسعه را هدفمند کند.

ضرورت روش‌شناختی از تفاوت میان معیارهای میانی و نهایی می‌آید. رسیدن به یک جلسه، حضور نوبت مرجع، کفایت معنایی مجموعه و استفاده‌ی درست خواننده چهار اندازه‌گیری متفاوت‌اند. مطالعات جدید نیز فاصله‌ی ارتباط و کفایت یا پوشش و استفاده را برجسته می‌کنند [P11 تا P15]. این پایان‌نامه با یک قرارداد محاسباتی محدود، بخشی از زنجیره را به‌صورت دقیق و بازتولیدپذیر ممیزی می‌کند.

شکاف مورد بررسی، نبود مطلق تحلیل تشخیصی در ادبیات نیست. شکاف عملی در زنجیره‌ی این پژوهش، نیاز به انتساب کنترل‌شده‌ی اثر مرز و محاسبه‌ی امکان پوشش در همان فرصت‌هایی بود که بازیاب واقعا داشت. این

صورت‌بندی، سهم پژوهش را در برابر روش‌های پیشین مشخص می‌کند و از تبدیل یک نتیجه‌ی محدود به ادعای عمومی جلوگیری می‌کند.

۱.۳ هدف‌ها و پرسش‌ها

هدف اصلی، ساخت چارچوبی برای سنجش ادعاهای معماری حافظه و تشخیص محدودیت بازیابی شاهد در هزینه و فضای انتخاب مشخص است. پرسش نخست می‌پرسد با کنترل شمار قطعه، نمایه، لنگر و پنجره‌های مجاز، مرز چه مزیتی در پوشش شاهد نشان می‌دهد. پرسش دوم می‌پرسد شکست مشاهده‌شده به غیبت جلسه، هندسه‌ی ناممکن یا انتخاب ناموفقِ دارای امکان تعلق دارد. پرسش سوم رابطه‌ی دسترسی به جلسه و مونتاژ شاهد محلی را در مداخله‌ی رزرو جلسه بررسی می‌کند.

یک پرسش تحلیلی مکمل نیز از QMSum بیرون می‌آید: چرا هم‌راستایی تقریبی با آغاز موضوع به پوشش بهتر نوبت‌های مرتبط تبدیل نشده است. فصل ۵ یافته‌های مربوط به این شکاف را از فرضیه‌های توضیحی جدا می‌کند. تحلیل همبستگی تازه و آزمون مستقل هر فرضیه در دامنه‌ی تجربی این نسخه انجام نشده‌اند.

۱.۴ سه مشارکت پایان‌نامه

مشارکت نخست، چارچوب کنترل‌شده‌ی ارزیابی است. این چارچوب تفاوت شمار قطعه‌ی ساخته‌شده و انتخاب‌شده، سقف و مصرف واقعی، فرمول رتبه‌بند و نمایه‌ی آن و فرصت‌های مجاز انتخاب را آشکار می‌کند. مرحله‌ی ۱۷ صورت سخت‌گیرانه‌تر این کنترل را با نمایه و لنگر و هندسه‌ی مشترک اجرا کرده است.

مشارکت دوم، تجزیه‌ی تشخیصی دقیق در مرحله‌ی ۱۸ است. ممیز با استفاده‌ی آفلاین از برچسب مرجع، امکان پوشش کامل و کمترین بودجه را در هندسه‌ی ثابت تعیین و گواه موفق یا محدودیت را ارائه می‌کند. سقف ۴۶۸ از ۵۹۹ پرسش LoCoMo به همین قرارداد تعلق دارد و عملکرد به‌دست‌آمده‌ی یک روش تازه نیست [C07، C08].

مشارکت سوم، تمایز تجربی دسترسی به جلسه و مونتاژ شاهد محلی در مرحله‌ی ۱۹ است. افزایش دسترسی با رزرو هشت جلسه، در طراحی بررسی‌شده پوشش را افزایش نداده است. اصلاحیه‌ی کنترل تعداد تعویض نیز این ناهم‌جهتی را در مقایسه‌ی محدود دیگری بررسی می‌کند [C11 تا C13].

۱.۵ دامنه و کاربرد

این پروژه‌ی کارشناسی مهندسی کامپیوتر، پیاده‌سازی، داده‌ی نسخه‌دار، قرارداد ارزیابی و خروجی قابل بازاجرا دارد. آزمایش‌های محوری روی CPU و بدون استنتاج تجاری اجرا شده‌اند. دامنه‌ی تجربی پایان‌نامه تا مرحله‌ی ۱۹ بسته شده است. داده‌های انسانی تازه، نمونه‌گیری شرکت‌کننده، EEG و fMRI بخشی از اجرای پروژه نیستند.

کاربرد مستقیم، ممیزی و انتخاب محل اصلاح در بازیابی حافظه‌ی متنی است. مدیر یک خط لوله می‌تواند ابتدا دسترسی، سپس امکان پوشش و در پایان کیفیت انتخاب را وارسی کند. به‌کارگیری نتیجه در محصول واقعی به سنجش خواننده، هزینه‌ی کامل، حریم خصوصی و داده‌ی کاربرد همان محصول نیاز دارد؛ این موارد در این پروژه اندازه‌گیری نشده‌اند.

۱ ۶ سازمان پایان‌نامه

فصل ۲ مبانی و پیشینه را با تفکیک وضعیت انتشار و سنجه‌ها بررسی می‌کند. فصل ۳ قراردادهای داده و روش را توضیح می‌دهد. فصل ۴ مسیر کنترل‌شده شدن ارزیابی و نتیجه‌ی محوری آن را سنتز می‌کند. فصل ۵ به QMSum و فصل ۶ به تشخیص شکست و مونتاژ شاهد اختصاص دارند. فصل ۷ بحث و حدود اعتبار را ارائه می‌کند و فصل ۸ پاسخ پرسش‌ها و کارهای آینده را جمع‌بندی می‌کند. پیوست‌ها نمادگذاری، نقشه‌ی شواهد و راهنمای بازتولید را در اختیار خواننده قرار می‌دهند.

فصل ۲ مبانی و پیشینه‌ی پژوهش

۲ ۱ روش مرور منابع

این فصل حاصل مرور متمرکز منابع اصلی تا ۲۷ اکتبر ۲۰۲۶ است. منابع بر اساس ارتباط مستقیم با بخش‌بندی تجربه، ساخت حافظه، معیارهای شاهد و تحلیل تشخیصی انتخاب شدند. منبع ناشر، مجموعه‌مقالات رسمی یا نسخه‌ی نویسندگان در arXiv مبنای بررسی است. دامنه‌ی خواندن هر منبع در دفتر پیشینه ثبت شده و برای منابع محوری، بخش‌های روش و محدودیت نیز بررسی شده‌اند. این مرور، ادعای پوشش نظام‌مند تمام ادبیات یا تصدیق رتبه‌ی Q1 و Q2 ندارد.

وضعیت مقاله‌ی منتشرشده و پیش‌چاپ جدا نگه داشته می‌شود. تازه بودن یک پیش‌چاپ به معنی تایید مستقل نتیجه‌ی آن نیست. همچنین امتیاز پاسخ مقاله‌ای دیگر با پوشش برچسبی این پایان‌نامه در یک جدول رتبه‌بندی ادغام نمی‌شود. هدف مرور، روشن کردن پیشینه‌ی ایده‌ها و محل سهم محدود پژوهش است.

۲ ۲ معنا و حدود صورت‌بندی محاسباتی

استدلال اتاق چینی سرل به نسبت اجرای برنامه، قصدیت و فهم می‌پردازد [P01]. بحث او، خودبه‌خود دستورالعمل سنجش مرز یک گفت‌وگو یا معیار بازیابی متن فراهم نمی‌کند. در این پایان‌نامه، معنا در سطح فلسفی، انگیزه‌ی طرح پرسش بوده است. متغیر عملیاتی، تغییر واژگانی و پوشش متن مرجع است. رشد این متغیرها شاهدی برای حل مسئله‌ی فهم به معنای مورد نظر سرل محسوب نمی‌شود.

این تفکیک برای اعتبار سازه ضروری است. واژه‌ی «رویداد» می‌تواند به رویداد ادراک‌شده‌ی انسان، واحد موضوعیِ حاشیه‌نویسی‌شده یا قطعه‌ی ساخته‌شده توسط الگوریتم اشاره کند. هر کدام به تعریف و سنجه‌ی متناسب نیاز دارند. استفاده از یک نام مشترک، هم‌ارزی این سه واحد را برقرار نمی‌کند.

۲ ۳ بخش‌بندی رویداد در علوم شناختی

Zacks و همکاران نظریه‌ای ارائه می‌کنند که بخش‌بندی تجربه را با پیش‌بینی و به‌روزرسانی مدل رویداد مرتبط می‌سازد [P02]. این چارچوب برای ایده‌ی نگهداری واحدهای تجربه الهام‌بخش است. ادعای آن درباره‌ی ادراک و حافظه با مشاهده‌ی مرزهای واژگانی در متن آزموده نمی‌شود.

مطالعه‌ی Nguyen و همکاران در نسخه‌ی نهایی eLife، خطای پیش‌بینی و عدم قطعیت پیش‌بینی را با مدل‌سازی، رفتار و fMRI بررسی می‌کند و الگوهای هم‌پوشان و متمایز گزارش می‌دهد [P03]. این تمایز یادآور می‌شود حتی در نظریه‌ی شناختی، یک شاخص ساده همه‌ی سازوکارهای مرز را نمایندگی نمی‌کند. نویی جاکارد در پروژه‌ی حاضر جانشین واژگانی است و برآورد مستقیم هیچ‌یک از آن سیگنال‌های عصبی نیست.

۲ ۴ بازیابی و حافظه‌ی بیرونی

BM25 چارچوبی واژگانی برای رتبه‌بندی اسناد با توجه به فراوانی واژه و طول سند فراهم می‌کند [P04]. وقتی قطعه‌بندی عوض می‌شود، اسناد و آمار نمایه نیز تغییر می‌کنند. بنابراین ثابت نگه داشتن پارامترهای رتبه‌بند، برای ثابت نگه داشتن فرصت بازیابی کافی نیست. این نکته یکی از انگیزه‌های نمایه‌ی نوبتی مشترک در طراحی کنترل‌شده‌ی پروژه است.

RAG پیوندی میان بازیابی حافظه‌ی غیرپارامتری و تولید زبانی ایجاد می‌کند [P05]. این تفکیک اجازه می‌دهد انتخاب شاهد و عملکرد خواننده جدا بررسی شوند. پایان‌نامه‌ی حاضر در بخش بازیابی و ممیزی متن متوقف می‌شود و خواننده‌ی مولد اجرا نمی‌کند. پژوهش Lost in the Middle نیز حساسیت استفاده‌ی مدل از زمینه به جایگاه اطلاعات را نشان می‌دهد [P11]؛ حضور متن مرجع تنها یکی از پیش‌نیازهای استفاده‌ی درست است.

۲ ۵ معیارهای حافظه‌ی گفت‌وگویی

LoCoMo تاریخچه‌های طولانی چندجلسه‌ای را برای ارزیابی حافظه فراهم می‌کند [P06]. در پروژه‌ی حاضر، پرسش‌های واجد شرایط و شاهدهای نوبتی آن مبنای پوشش قرار می‌گیرند. امتیاز این پروژه بازتولید امتیاز رسمی پرسش‌وپاسخ مقاله نیست. QMSum برای خلاصه‌سازی جلسه با پرسش طراحی شده و بازه‌های مرتبط آن ممکن است پهن باشند [P07]. همین تفاوت برچسب، کامل‌پوشانی را در دو مجموعه به هدف‌هایی با دشواری متفاوت تبدیل می‌کند.

LongMemEval توانایی‌های حافظه را با ساختار نمایه‌سازی، بازیابی و خواندن بررسی می‌کند [P08]. این پیشینه نشان می‌دهد تفکیک مرحله‌های خط لوله ایده‌ی تثبیت‌شده‌ای است. EverMemBench زمینه‌ی چندنفره و چندگروهی و اطلاعات تحول‌یابنده را وارد ارزیابی می‌کند [P16]. اجرای بیرونی پروژه فقط زیرمجموعه‌ی مشخص پرسش‌های ریزدانه‌ی چهار پروژه‌ی تولیدشده را به کار برده و دامنه‌ی همه‌ی وظایف آن معیار را پوشش نداده است.

۲ ۶ ریزدانگی و حافظه‌ی رویدادی

SeCom ریزدانگی حافظه و ساخت واحدهای منسجم گفت‌وگو را بررسی و فشرده‌سازی را برای کاهش نویز بازیابی به کار می‌گیرد [P09]. روش، مرزبندی و تغییر محتوای نمایه را در طراحی گسترده‌تری قرار می‌دهد و تحلیل‌های حذف جزء نیز دارد. برای پاسخ به پرسش این پایان‌نامه درباره‌ی اثر راهنمای مرز، لازم است فرصت انتخاب مشترک نیز صریح شود؛ سنجه و قرارداد دو مطالعه یکسان نیستند.

ES-Mem بخش‌بندی رویداد و معماری سلسله‌مراتبی حافظه را برای عامل گفت‌وگویی پیشنهاد می‌کند [P10]. بنابراین اصل ایده‌ی پیوند رویداد و حافظه‌ی عامل، سهم ابداعی این پایان‌نامه معرفی نمی‌شود. تفاوت

پروژه‌ی حاضر در ممیزی کم‌هزینه‌ی یک نویسنده‌ی منجمد و تشخیص امکان پوشش در قرارداد ثابت است. ES-Mem در این مرور از نسخه‌ی پیش‌چاپ خوانده شده و روش آن در پروژه بازاجرا نشده است.

۲.۷ ارتباط و کفایت مجموعه‌ی شاهد

BFR مسئله را به ساخت مجموعه‌ی کافی برای پاسخ صورت‌بندی می‌کند و ترکیب شاهدهای مکمل و دستیابی به رکوردهای تازه را تفکیک می‌کند [P12]. کفایت در آن با داوری زبانیِ آفلاین و شاخص‌های جانشین سنجیده می‌شود و بودجه‌ی فراخوانی بازیابی نقش دارد. ممیز این پایان‌نامه به جای کفایت معنایی، پوشش دقیق همه‌ی موقعیت‌های مرجع را در پنجره‌های مجاز می‌سنجد. دو طراحی پرسش‌های مرتبط اما متفاوت دارند.

Raw-RAG از بازیابی متراکم و بازرتبه‌بندی روی تاریخچه‌ی خام به‌عنوان مبنای قوی استفاده می‌کند و پوشش، استفاده و حفظ روابط شاهد را تحلیل می‌کند [P13]. برای پروژه‌ی حاضر، پیام روش‌شناختی آن اهمیت خط پایه‌ی مناسب است. روش BM25 این پروژه معادل اجرای Raw-RAG نیست و نتایج آن مقاله برتری پیاده‌سازی ما را اثبات نمی‌کنند. کنترل‌های اوراکل آن نیز مداخلات و قراردادهای خاص خود را دارند.

۲.۸ تشخیص خطا و واحد ارزیابی

MemDerive حالت مشتق‌شده و مسیر استنتاج مرجع را برای تشخیص خطا تعریف می‌کند [P14]. MemTrace واحد دانش‌نقطه را جایگزین تجمیع صرف ردیف‌های پرسش می‌کند و وضعیت شاهد و استفاده را بررسی می‌کند [P15]. این آثار نشان می‌دهند نتیجه‌ی نهایی به‌تنهایی برای توضیح شکست کافی نیست. سهم این پایان‌نامه، تشخیص خطا در تمام حافظه یا مسیر استدلال عامل نیست؛ تشخیص به هندسه و پوشش متن در فضای معین محدود است.

گزارش غالب بودن یک گلوگاه میان مطالعه‌ها قابل انتقال مستقیم نیست. برای مثال، قابل بازیابی بودن در یک طراحی دانش‌نقطه‌محور و استفاده‌ی خواننده با الزام پوشش کامل همه‌ی واژه‌های نوبت‌های مرجع یکسان نیست. بنابراین غلبه‌ی غیبت جلسه در خطاهای مشخص LoCoMo این پروژه و اهمیت استفاده‌ی شاهد در یک معیار دیگر می‌توانند هم‌زمان برقرار باشند. تعیین ناسازگاری تجربی به داده، بازیاب، سنجه و مداخله‌ی مشترک نیاز دارد؛ این تطبیق، تحلیل مفهومی است.

۲.۹ مقایسه‌ی طراحی‌ها

جدول ۱ مقایسه‌ی طراحی‌های نزدیک

مطالعه	خروجی یا واحد اصلی	نوع تشخیص	نسبت با پژوهش حاضر
SeCom و ES-Mem	واحد حافظه و پاسخ	بررسی ساختار و اجزا	پیشینه‌ی مستقیم ریزدانگی و رویداد

مطالعه	خروجی یا واحد اصلی	نوع تشخیص	نسبت با پژوهش حاضر
BFR	مجموعه‌ی شاهد و پاسخ	ترکیب و تکمیل تحت بودجه	کفایت داوری‌شده با پوشش متن متفاوت است
Raw-RAG	متن خام و پاسخ	پوشش و استفاده و اوراکل	مبنای قوی با بازیاب و خواننده‌ی متفاوت
MemDerive و MemTrace	حالت مشتق‌شده یا دانش‌نقطه	مراحل و شرایط شکست	پیشینه‌ی تحلیل میانی و واحد ارزیابی
پژوهش حاضر	موقعیت واژه‌ی مرجع	دسترسی و امکان و انتخاب	ممیزی دقیق مشروط به پنجره‌های ثابت

۱۰۲ جایگاه سهم پژوهش

پیشینه، ضرورت سنجش مرحله‌های میانی و نقش ساختار حافظه را پشتیبانی می‌کند. سهم محدود این پایان‌نامه در اتصال کنترل فرصت‌ها به گواه دقیق امکان‌پذیری و سپس آزمون ناهم‌جهتی دسترسی و پوشش است. واژه‌ی «دقیق» به محاسبه‌ی داخل فضای قانونی اشاره دارد. این ویژگی دقت برچسب، استقلال داده، کیفیت پاسخ و تازگی جهانی مفهوم تشخیص را تضمین نمی‌کند.

فصل ۳ داده و روش پژوهش

۳ ۱ نوع مطالعه و نسخه‌ی مبنا

پژوهش، مطالعه‌ی محاسباتی کنترل‌شده با پیاده‌سازی و ممیزی آفلاین است. روش‌ها روی متن ثابت اجرا و انتخاب‌هایشان با مرجع مقایسه شده‌اند. مراحل متوالی، داده و نتایج پیشین را برای تصمیم بعدی به کار گرفته‌اند؛ ازاین‌رو ثبت طرح هر مرحله، داده‌ی قبلا مشاهده‌شده را به آزمون مستقل تازه تبدیل نمی‌کند. متن یکپارچه از نسخه‌ی منتشرشده‌ی بسته‌ی اول تدوین و خروجی‌های پژوهشی تا مرحله‌ی ۱۹ استفاده می‌کند.

۳ ۲ داده‌ها و دامنه‌ی استفاده

جدول ۲ داده‌ها و معنای مرجع

منبع	واحد استفاده‌شده در تحلیل محوری	معنای مرجع
LoCoMo	۵۹۹ پرسش در هفت گفت‌وگوی ارزیابی تاریخی	نوبت‌های شاهد غیرخالی
QMSum	۲۴۴ پرسش اختصاصی در ۳۵ جلسه	اجتماع نوبت‌های بازه‌ی مرتبط
منبع بیرونی	۶۰۹ پرسش ریزدانه در چهار پروژه	پیام‌های مرجع زمینه‌ای

در ممیزی اولیه‌ی ۲۷۴ ،LoCoMo پرسش توسعه و ۵۹۹ پرسش ارزیابی واجد شرایط شدند [C16]. برچسب تاریخی held_out درباره‌ی ترتیب آغاز پروژه است. همان پرسش‌ها پس از مشاهده‌ی نخستین نتیجه در مراحل دیگر بازاستفاده شده‌اند. LongMemEval و Memora نیز در مسیر توسعه بررسی شده‌اند؛ نتایج آن‌ها با توجه به سنجه‌ی متفاوت در فصل ۴ به‌عنوان زمینه‌ی روش‌شناختی مرور می‌شوند [S17L].

نسخه‌ی QMSum با بازنگری ثبت‌شده و فهرست ۳۵ فایل کنترل شده است. در داده‌ی بیرونی، بازنگری a6b210a32248e841967b7b64a64281d2ff3f669d از EverMemBench-Dynamic مبناست. موضوع‌های ۰۲ تا ۰۵ برای امتیازدهی انتخاب و موضوع ۰۱ و قالب قدیمی ۰۰۴ که برای فهم شِما دیده شده بودند کنار گذاشته شدند. پرسش‌های بیرونی پس از ثبت طرح مربوط باز شدند؛ چهار پروژه نمونه‌ی مستقل انسانی محسوب نمی‌شوند و اکنون همه دیده شده‌اند [S19].

۳ ۳ بازنمایی متن و هزینه

توکن‌ساز پروژه دنباله‌های واژه را با قواعد یونیکد و تبدیل حروف به کوچک استخراج می‌کند. واژه‌ها موقعیت‌دارند: همان رشته در محل دیگر، پوشش موقعیت مرجع قبلی نیست. شناسه‌ی جلسه و نوبت، متن را به

مختصات قابل ممیزی وصل می‌کند. نوبت خالی موقعیت واژه ندارد و مطابق قرارداد هر مرحله از مخرج مربوط کنار می‌رود؛ سیاست حذف یا حفظ پرسش در خروجی ثبت شده است.

بودجه‌های اصلی ۵۱۲، ۱۰۲۴ و ۲۰۴۸ واژه‌ی منبع‌اند. این واحد، تعداد توکن مدل زبانی یا قیمت اجرای آن نیست. در طراحی فرصت ثابت، اجتماع موقعیت‌های انتخاب‌شده هزینه را تعیین می‌کند. سقف یکسان، مصرف یکسان را به‌تنهایی تضمین نمی‌کند؛ اشباع ظرفیت به‌صورت جداگانه بررسی می‌شود.

۴ ۳ نویسنده‌ی علّی منجمد

منظور از نویسنده، الگوریتمی است که متن ورودی را به قطعه‌های حافظه تبدیل می‌کند. نویسنده‌ی علّی پروژه از متن نوبت فعلی و سه نوبت قبلی، نویی واژگانی بر پایه‌ی یک منهای جاکارد را محاسبه می‌کند. پس از حداقل ۶۴ واژه، آستانه‌ی ۰٫۸۵ می‌تواند مرز ایجاد کند؛ سقف هدف ۱۶۰ واژه نیز قید بستن است. نوبت تکیِ بلند در این سیاست به اجزای کوتاه‌تر بریده نمی‌شود [S10، S17].

قطعه‌ی بسته در آینده بازنویسی نمی‌شود. علّی بودن در اینجا به دسترسی نویسنده به گذشته و حال متن مربوط است. رتبه‌بندی پرسش‌ها در انتهای تاریخچه انجام می‌شود؛ این آزمایش، ارزیابی تعامل زنده یا سیستم علّی عصبی نیست. پارامترهای نویسنده در انتقال‌های محوری دوباره تنظیم نشده‌اند.

۵ ۳ رتبه‌بندی و کنترل فرصت

در مرحله‌ی ۱۷، BM25 نوبت‌محور با پارامترهای ثابت، واژه‌های یکتای مرتب‌شده‌ی پرسش و قاعده‌ی تساوی زمانی اجرا می‌شود. پارامترهای k1 و b به‌ترتیب ۱٫۲ و ۰٫۷۵ هستند. میانه‌ی هشت نوبت نخست لنگر را تعیین می‌کند. ناحیه‌های مجزا، عرض تخصیص نوبتی و همه‌ی شروع‌های قانونی پنجره از لنگر و بودجه ساخته می‌شوند و به روش انتخابگر وابسته نیستند [S17].

روش مرکزی نزدیک بودن پنجره به لنگر را مبنا قرار می‌دهد. روش مرزی هم‌پوشانی با قطعه‌ی حامل لنگر را بهینه و در تساوی از قواعد ثابت استفاده می‌کند. کنترل‌های تصادفی، پارتیشن‌های معتبر با تعداد قطعه‌ی برابر می‌سازند؛ این کنترل پس‌نگر و جایگزین نویسنده‌ی برخط نیست. طول قطعه و تمام ویژگی‌های آن‌ها با برابر کردن شمار قطعه یکسان نمی‌شوند.

۶ ۳ مداخله و ممیز

مرحله‌ی ۱۸ بر همان فضای ثابت، امکان پوشش کامل و کمترین بودجه را از مرجع محاسبه می‌کند. انتخاب عملی پیش از ورود برچسب به ممیزی ثبت می‌شود. ممیز وجود پاسخ متنی مجاز را بررسی می‌کند و بازیاب قابل استقرار نیست. شرط لازم و کافی و گواه‌ها در فصل ۶ و پیوست ریاضی توضیح داده شده‌اند.

مرحله‌ی ۱۹ سیاست‌های انتخاب هشت لنگر از فهرست ۶۴ نامزد مشترک را مقایسه می‌کند. رزرو چهار جلسه مقایسه‌ی اصلی و رزرو هشت جلسه دوز ثانویه است. پس از هر سیاست، ترتیب اولیه‌ی رتبه‌ها بازگردانده و

هندسه و امکان دوباره محاسبه می‌شوند. کنترل‌های اولیه‌ی برچسب جابه‌جاشده و اصلاحیه‌ی پسینیِ تعداد تعویض، نقش و شدت متفاوت دارند؛ جایگاهشان در گزارش جدا حفظ شده است [S19، S19B].

۳ ۷ سنجه‌ها و تجمیع

در LoCoMo، معیار اصلی محوری حضور کامل همه‌ی نوبت‌های شاهد غیرخالی است و برای هر پرسش مقدار همه‌یاهیچ دارد. در QMSum و منبع بیرونی، کسر نوبت‌ها یا پیام‌های مرجعِ کامل نیز استفاده شده است. شاخص حداقل یک شاهد، پوشش همه‌ی جلسه‌ها و امکان دقیق سنجه‌های دیگری‌اند. هیچ‌یک با صحت پاسخ تولیدی یکسان فرض نمی‌شود.

مقایسه‌ها ابتدا درون پرسش جفت می‌شوند و سپس مطابق طرح در سطح تاریخچه میانگین می‌گیرند. در LoCoMo، هفت گفت‌وگو وزن برابر دارند. بذرهای تصادفی درون پرسش میانگین می‌شوند؛ بذر، پرسش، سیاست و بودجه نمونه‌ی مستقل تازه نیستند. واحد بازنمونه‌گیری و نوع تجمیع در هر خروجی ثبت شده است. در تحلیل‌های محوری QMSum، وابستگی خانواده‌ی منبع نیز لحاظ شده است [S17، S18].

بازه‌های بوت‌استرپ توصیفی‌اند. آستانه‌ی عملی از پیش ثبت‌شده در طراحی مرحله‌ی ۱۷، دو واحد درصد بود. عبور از صفر در یک بازه‌ی توصیفی به‌تنهایی این شرط کاربردی یا اعتبار تاییدی را برقرار نمی‌کند. در مرحله‌ی ۱۹ نیز قاعده‌ی ادامه با شروط مشخص در دو منبع تعریف و تامین نشد [C10، C14].

۳ ۸ بازتولید و اعتبارسنجی

نسخه‌ی منبع، طرح، کد، خروجی عددی و سابقه‌ی اجرا قابل ردیابی‌اند. اعتبارسنج‌های مستقل از متن خام، هندسه، هزینه، گواه‌های موفق و آستانه‌ها را از خروجی ثبت‌شده بررسی می‌کنند. بازاجرای منبع‌دار علاوه بر این، دریافت داده‌ی نسخه‌دار را لازم دارد. موفق بودن اعتبارسنج پرونده‌ی عددی با انجام دوباره‌ی رتبه‌بندی از داده‌ی خام متفاوت است.

این گام تدوین، آزمایش تازه‌ای اجرا نمی‌کند. دفتر شواهد یکپارچه مقدارها را از خروجی‌های موجود می‌خواند و پرونده‌های تاریخی را با هش ثابت کنترل می‌کند. داده‌ی خام، کتاب‌های آموزشی ارسالی و فونت‌ها در مخزن بازتوزیع نمی‌شوند. راهنمای عملی بازتولید در پیوست آمده است.

فصل ۴ سنتز چارچوب کنترل‌شده‌ی ارزیابی

۱۴ منطق سازمان نتایج

مراحل پروژه در این فصل بر اساس پرسش روش‌شناختی کنار هم قرار می‌گیرند. مسیر توسعه نشان می‌دهد چرا کنترل شمار قطعه، نقش، هزینه و فرصت انتخاب به‌تدریج ضروری شد. امتیازهای مراحل مختلف با قراردادهای متفاوت در یک روند پیشرفت عددی قرار نمی‌گیرند. دفتر تاریخی مراحل ۱ تا ۱۶، منبع جزئیات و ترتیب تصمیم‌هاست [S17L].

۲۴ توسعه و محدودیت انتساب اولیه

مراحل ۱ تا ۳ ساختار شاهد را ممیزی و تنظیمات اولیه را روی بخش توسعه انتخاب کردند. مرحله‌ی ۴ انتقال منجمد به هفت گفت‌وگوی ارزیابی تاریخی را اجرا کرد. مراحل بعدی هزینه‌ی قطعه‌های حامل شاهد و نمایش واژگانی و LSA را بررسی کردند. این مسیر برای یافتن محدودیت مفید بود؛ در مقایسه‌های آن، همه‌ی فرصت‌های انتخاب و آمار نمایه یکسان نبودند.

استفاده از نمایش کم‌بعد یا نام‌گذاری یک مرزبند به‌عنوان معنایی، به‌تنهایی ادراک معنا را اندازه‌گیری نمی‌کند. نخستین انتقال به LongMemEval نیز با قواعد شاهد و نوبت‌های بلند روبه‌رو شد. این تجربه‌ها اهمیت ممیزی منبع و تعریف عملیاتی را نشان دادند و انگیزه‌ی نویسنده‌ی علّی و کنترل شمار قطعه را فراهم کردند.

۳۴ کنترل شمار و ریزدانگی

مراحل ۸ و ۹ نویسنده‌ی علّی منجمد و پارتیشن تصادفی معتبر با شمار قطعه‌ی برابر را بررسی کردند. چنین کنترلی توضیح مبتنی بر تعداد واحد را محدود می‌کند. طول قطعه، محتوای هر واحد و آمار سندی BM25 همچنان می‌توانند متفاوت باشند. در QMSum، هم‌راستایی تقریبی مرز و پوشش نوبت مرتبط به دو خروجی با جهت متفاوت تبدیل شدند؛ این گسست موضوع مستقل فصل ۵ است.

۴۴ نقش و به‌روزرسانی

مراحل ۱۲ و ۱۳ نشان دادند زمان جدیدتر و تنوع جلسه باید با برچسب دقیق شاهد سنجیده شوند. مراحل ۱۴ تا ۱۶ نیز وفاداری نقش‌های ورودی در Memora و رابطه‌ی حفظ نقش، بودجه و مرزبندی را بررسی کردند. برچسب جلسه‌ی شاهد با مکان دقیق شاهد در نوبت یکسان نیست و شمار انتخاب‌شده می‌تواند با شمار واحدهای ساخته‌شده تفاوت داشته باشد [S17L].

کاربرد این مراحل برای روایت نهایی، آشکار کردن مخدوش‌کننده‌های مشخص است. این ممیزی‌ها یک مدل زبانی رسمی را دوباره امتیازدهی نکردند و نتیجه‌ی نهایی یک معیار دیگر را باطل نمی‌کنند. قراردادهای متفاوت باید در تفسیر حفظ شوند.

۴ ۵ فرصت‌های دقیقا مشترک

مرحله‌ی ۱۷ کنترل قوی‌تری می‌سازد. نمایه‌ی نوبتی و رتبه‌ها، هشت لنگر، ناحیه‌ها، عرض‌ها، تعداد پنجره و هزینه‌ی یکتای واقعی میان انتخابگرها مشترک‌اند. نویسنده و کنترل تصادفی فقط راهنمای انتخاب در همین فضا را تغییر می‌دهند. این طراحی اثر الگوریتم را به پرسش محدودتری پیوند می‌دهد: با فرصت یکسان، راهنمای مرز چه تغییری در پوشش ایجاد می‌کند.

جدول ۳ اجزای مشترک و متغیر طراحی

جزء	وضعیت در مقایسه‌ی انتخابگرهای مرحله‌ی ۱۷
نمایه و ترتیب رتبه	مشترک
لنگر و ناحیه و عرض	مشترک
پنجره‌های قانونی و هزینه‌ی یکتا	مشترک
راهنمای مرز برای انتخاب پنجره	متغیر مقایسه
طول و محتوای قطعه‌های زیربنایی	الزام به یکسانی کامل ندارد

کنترل شمار قطعه به تعداد پارتیشن نوبتی مربوط است. ممیزی پس از نتیجه، چند قطعه‌ی فقط نوبت خالی در کنترل‌های تاریخی را آشکار کرد؛ این وضعیت ثبت و حفظ شده است. فضای قانونی پنجره و هزینه‌ی متن میان انتخابگرها مشترک باقی می‌مانند. این تمایز اجازه می‌دهد نقص کنترل زیربنایی از قرارداد فرصت خروجی جدا گزارش شود [S17].

۴ ۶ نتیجه‌ی محوری و اهمیت اندازه‌ی اثر

در LoCoMo و بودجه‌ی ۱۰۲۴ واژه، نویسنده ۴۴۳ از ۵۹۹ پرسش را کامل می‌پوشاند. اختلاف میانگین مساوی گفت‌وگو با میانگین کنترل‌های تصادفی حدود مثبت ۰٫۸۴ واحد درصد و بازه‌ی خوشه‌ای توصیفی حدود ۰٫۰۷ تا ۱٫۵۲ است. این مقدار به آستانه‌ی عملی دو واحد درصد نرسید. اختلاف با روش مرکزی حدود مثبت ۰٫۳۵ واحد درصد بود و بازه‌ی آن صفر را در بر می‌گرفت [C14].

در QMSum، اختلاف با میانگین تصادفی در سنجه‌ی کسر نوبت مرتبط حدود منفی ۰٫۰۹ واحد درصد و بازه‌ی توصیفی شامل صفر بود [C14]. دو نتیجه با سنجه‌های متفاوت گزارش می‌شوند. از آن‌ها یک درصد مشترک برای حافظه‌ی بهتر ساخته نمی‌شود. وجود یک اثر کوچک در نمونه‌ی ثابت نیز تعمیم پایدار یا ارزش کاربردی از پیش تعیین‌شده را تضمین نمی‌کند.

۷ ۴ سهم چارچوب و پیوند با تشخیص

چارچوب مشخص می‌کند کدام تغییر، در کدام فرصت و با چه هزینه‌ای سنجیده شده است. نتیجه‌ی محدود آن، پشتیبانی نکردن از برتری عملیِ مورد انتظار برای راهنمای مرز در قرارداد اصلی است. گام استدلالی بعدی می‌پرسد آیا روش انتخاب بهتر، در همین فضا ظرفیت کافی دارد. فصل ۶ با ممیز مرحله‌ی ۱۸ این ظرفیت را محاسبه و سپس با مداخله‌ی مرحله‌ی ۱۹ رابطه‌ی دسترسی و مونتاژ شاهد را بررسی می‌کند.

فصل ۵ شکاف هم‌راستایی مرز و پوشش بازیابی

۵.۱ پرسش تحلیلی

مرزی که به آغاز یک موضوع نزدیک است ممکن است برای بازیابی شاهد پرسش مفید باشد. آزمودن این انتظار نیازمند دو اندازه‌گیری جداست. نخست، مرزهای ساخته‌شده با شروع بازه‌های موضوعی مقایسه می‌شوند. سپس، پوشش نوبت‌های مرتبط با پرسش در متن بازیابی‌شده سنجیده می‌شود. مراحل ۱۰ و ۱۱ نشان دادند این دو هدف در طراحی بررسی‌شده هم‌جهت نشده‌اند. این فصل معنای این فاصله و توضیح‌های قابل بررسی آن را صورت‌بندی می‌کند [C01 تا C06؛ S10، S11].

۵.۲ داده و معنای مرجع

آزمایش QMSum شامل ۳۵ جلسه، ۲۴۴ پرسش اختصاصی و ۱۶۱ آغاز یکتای غیرصفر برای بازه‌های موضوعی است. QMSum برای خلاصه‌سازی جلسه بر حسب پرسش ساخته شده است. بازه‌ی موضوع و بازه‌ی مرتبط با خلاصه، دو برچسب با کارکرد متفاوت‌اند. آغاز دوباره‌ی یک موضوع نیز می‌تواند آغاز یک بازه‌ی ثبت‌شده باشد. برچسب موجود داوری مستقیم درباره‌ی مرز رویداد ادراک‌شده‌ی انسان نیست [S10].

سنجه‌ی هم‌راستایی، کسر آغازهایی است که مرز الگوریتم در فاصله‌ی مجاز آن‌ها قرار دارد؛ ابتدا در هر جلسه و سپس با وزن برابر جلسه‌ها محاسبه می‌شود. این سنجه همه‌ی مرزهای اضافه را جریمه نمی‌کند و شاخص دقت طبقه‌بندی یا F1 تشخیص مرز نیست. کنترل‌های تصادفی با شمار قطعه‌ی برابر، اثر تراکم مرز را تا حد مشخصی کنترل می‌کنند. طول‌ها و همه‌ی خواص معنایی قطعه‌ها با این کنترل یکسان نمی‌شوند.

۵.۳ دو نتیجه‌ی هم‌زمان

جدول ۴ مرز موضوعی و پوشش بازیابی

سنجه	نویسنده	میانه‌ی کنترل
آغاز موضوع با تلورانس دو نوبت	۸۴٫۳۷٪	۶۵٫۹۱٪
آغاز موضوع با تلورانس صفر	۲۲٫۹۲٪	۲۳٫۸۰٪
پوشش نوبت مرتبط در مسیر تخت	۳۴٫۶۹٪	۳۶٫۷۷٪
پوشش نوبت مرتبط در مسیر دومرحله‌ای	۱۶٫۷۸٪	۱۶٫۹۱٪

دو ردیف بازیابی به بودجه‌ی ۱۰۲۴ واژه تعلق دارند. ردیف نخست و دوم نتیجه‌ی مرحله‌ی ۱۰ و ردیف چهارم معیار اصلی مرحله‌ی ۱۱ است. مقدارهای دقیق در دفتر شواهد ثبت شده‌اند [C01 تا C04]. اختلاف نمایش‌داده‌شده از درصدهای گردشده نباید جای محاسبه با مقدار دقیق را بگیرد.

در تلورانس دو نوبت، نویسنده از میانه‌ی کنترل‌ها بالاتر است؛ با الزام تطابق دقیق چنین برتری‌ای دیده نمی‌شود. بنابراین یافته‌ی مثبت به نزدیکی مکانی در پنجره‌ی تعریف‌شده مربوط است. در جلسات کمیته، نویسنده و کنترل در سنجه‌ی دو نوبتی هر دو به سقف می‌رسند؛ قید اندازه و نوبت‌های بلند قدرت تمایز این بخش از داده را کم می‌کنند. نسبت دادن تمام هم‌راستایی به تشخیص محتوای موضوع با این وضعیت سازگار نیست [S10].

۴ ۵ مسیر نامزد تا متن خروجی

مرحله‌ی ۱۱ ابتدا قطعه‌ها را با BM25 رتبه‌بندی می‌کند و تا چهار برابر بودجه‌ی نهایی نامزد می‌گیرد. سپس نوبت‌های نامزد با همان خانواده‌ی رتبه‌بندی تا بودجه‌ی خروجی انتخاب می‌شوند. برای نویسنده، پوشش نامزد ۶۸٫۹۴٪ و پوشش نهایی ۱۶٫۷۸٪ است [C05]. این مقایسه محل افت را در مسیر نشان می‌دهد؛ نامزدها ظرفیت متنی بزرگ‌تری دارند و اختلاف، برآورد اثر خالص یک رتبه‌بند نیست.

تحلیل پس از نتیجه نشان می‌دهد شاخص رسیدن به حداقل یک نوبت شاهد برای نویسنده از ۸۷٫۸۱٪ در مسیر تخت به ۹۲٫۱۴٪ در مسیر دومرحله‌ای رسیده است [C06]. این تغییر با افت کسر پوشش قابل جمع است: یک خروجی می‌تواند به چند شاهد پراکنده برسد و سهم کمتری از بازه‌های طولانی مرجع را بازگرداند. این شاخص پسینی، معیار اصلی ثبت‌شده را جایگزین نمی‌کند و درباره‌ی کیفیت پاسخ تولیدی داوری نمی‌کند.

۵ ۵ فرضیه‌های توضیحی

فرضیه‌ی نخست، ناهم‌راستایی واحد موضوع و واحد شاهد است. پرسش ممکن است به بخش کوچکی درون یک موضوع یا به چند بازه‌ی جدا نیاز داشته باشد. در این صورت، نزدیک شدن به آغاز موضوع لزوما واحد مناسب انتخاب شاهد را نمی‌سازد. بررسی مستقیم این فرضیه مستلزم مقایسه‌ی مکانی دو نوع مرجع و بررسی پراکندگی شاهدهاست؛ نتیجه‌ی چنین اندازه‌گیری تازه‌ای در این بسته گزارش نشده است.

فرضیه‌ی دوم به هزینه‌ی پوشش مربوط است. بازه‌های مرتبط QMSum می‌توانند بلند باشند و بازگرداندن قطعه‌ی کامل، واژه‌هایی خارج از نوبت‌های مرجع را هم مصرف می‌کند. ممیزی مرحله‌ی ۱۸ نشان می‌دهد در هندسه‌ی ثابت بررسی‌شده و بودجه‌ی ۱۰۲۴، پوشش کامل تمام بازه‌ها تنها برای ۲۹ از ۲۴۴ پرسش ممکن است [C09]. این مشاهده اهمیت بودجه و ریزدانگی مرجع را تقویت می‌کند. از آن نمی‌توان علت مستقل افت مسیر دومرحله‌ای مرحله‌ی ۱۱ را استخراج کرد؛ دو مرحله فضای خروجی یکسان ندارند.

فرضیه‌ی سوم، تعامل مرزبندی با نمایه و رتبه‌بندی است. ثابت بودن فرمول BM25 به معنی ثابت بودن امتیازها نیست. تغییر قطعه‌ها، طول سند و فراوانی سندی واژه‌ها را تغییر می‌دهد. سنجه‌ی هم‌راستایی موضوعی نیز مستقیما ارتباط واژگانی قطعه با پرسش را بهینه نمی‌کند. برای سنجش اثر مستقل این عامل، نمایه و فرصت

انتخاب باید کنترل شوند. طراحی فرصت‌های ثابت مرحله‌ی ۱۷ بخشی از این مسئله‌ی روش‌شناختی را هدف گرفته است [S17].

۵ ۶ تحلیل همبستگی پیشنهادی

برای ادامه‌ی پس از پایان‌نامه می‌توان رابطه‌ی کیفیت مرز و پوشش را با واحد جلسه بررسی کرد. تعداد پرسش‌های هر جلسه، طول متن، شمار قطعه، طول شاهد و حوزه می‌توانند بر رابطه اثر بگذارند. داده‌های مرحله‌های ۱۰ و ۱۱ نیز قبلا دیده شده‌اند. ازاین‌رو، تعریف سنجه و کنترل‌ها باید پیش از محاسبه‌ی تکمیلی ثبت و تحلیل به‌عنوان اکتشافی معرفی شود. خانواده‌های منبع QMSum در ارزیابی حساسیت وابستگی حفظ شوند. دو میانگین کلی برای محاسبه‌ی یک همبستگی معتبر کافی نیستند.

اگر پس از کنترل عوامل اندازه رابطه‌ای مشاهده شود، آن رابطه فقط همراهی را نشان می‌دهد. اگر رابطه نزدیک صفر باشد، توان سنجه و دامنه‌ی تغییر نیز باید بررسی شود. این بسته ضریب همبستگی، مقدار احتمال یا اثر علّی تازه‌ای تولید نمی‌کند.

۵ ۷ جمع‌بندی

شاهد موجود نشان می‌دهد هم‌راستایی تقریبی با آغاز موضوع در قرارداد بررسی‌شده برای بهبود پوشش بازیابی کافی نبوده است. تفسیر آن به تلورانس مرز، ریزدانگی مرجع، هزینه و مسیر انتخاب وابسته است. این شکاف، ضرورت تحلیل مرحله‌های میانی حافظه را روشن می‌کند و زمینه‌ی ورود به تجزیه‌ی تشخیصی فصل بعد را می‌سازد.

فصل ۶ تجزیه‌ی تشخیصی و مونتاژ شاهد

۱۶ هدف و دامنه

این فصل دو پرسش را به هم متصل می‌کند. نخست، در فضای انتخاب ثابت چه سهمی از شکست‌ها با انتخاب بهتر قابل رفع است. دوم، اگر دسترسی به جلسه‌های بیشتری فراهم شود، پوشش شاهد چه تغییری می‌کند. مرحله‌ی ۱۸ به پرسش نخست با ممیز دقیق پاسخ می‌دهد و مرحله‌ی ۱۹ رابطه‌ی دسترسی و پوشش را با مداخله در لنگرها بررسی می‌کند. هر دو درباره‌ی شاهد برچسبی و هزینه‌ی متن منبع‌اند [S18، S19].

۲۶ تعریف عملیاتی زنجیره

برای هر پرسش، نمایه‌ی نوبت‌محور BM25 متن را رتبه‌بندی می‌کند. در طراحی مبنا، هشت نوبت به‌عنوان لنگر انتخاب می‌شوند. لنگرها ناحیه‌هایی مجزا در جلسه‌های خود دارند و سیاست تخصیص نوبتی، عرض هر پنجره را تعیین می‌کند. پنجره‌ی مجاز باید در ناحیه بماند و لنگر را در بر بگیرد. مرزبند یا روش مرکزی از میان همین فرصت‌ها پنجره انتخاب می‌کند [S17، S18F].

شاهد مرجع، اجتماع واژه‌های نوبت‌های غیرخالیِ برچسب‌خورده است. پوشش کامل زمانی رخ می‌دهد که همه‌ی آن واژه‌ها در اجتماع پنجره‌های خروجی حاضر باشند. هزینه بر موقعیت یکتای واژه در منبع تکیه دارد؛ بازگشت دوباره‌ی همان موقعیت دوباره شمرده نمی‌شود. واژه‌ی همسان در موقعیت دیگر جدا شمرده می‌شود. واحد هزینه دنباله‌های واژه در توکن‌ساز پروژه است و شمار توکن یک مدل زبانی را اندازه نمی‌گیرد.

بازیاب عملی به برچسب شاهد دسترسی ندارد. ممیز پس از ثبت انتخاب‌ها از برچسب استفاده می‌کند تا وجود یک انتخاب موفق مجاز را بررسی کند. جدایی ورودی انتخاب و ورودی ممیزی برای تفسیر این فصل ضروری است.

۳۶ شرط امکان‌پذیری

اگر جلسه‌ای حامل واژه‌ی مرجع هیچ لنگری نداشته باشد، پنجره‌های موجود نمی‌توانند آن واژه را پوشش دهند. افزایش عرض در جلسه‌های دیگر این محدودیت را رفع نمی‌کند. اگر همه‌ی جلسه‌های مرجع در دسترس باشند، در هر ناحیه فاصله‌ی لازم برای دربرگرفتن لنگر و تمام واژه‌های مرجع همان ناحیه محاسبه می‌شود. پوشش کامل دقیقا زمانی ممکن است که عرض تخصیص‌یافته‌ی هر ناحیه دست‌کم به اندازه‌ی این فاصله باشد [S18F].

ضرورت شرط از پیوستگی پنجره و مجزا بودن ناحیه‌ها می‌آید. پنجره‌ی ناحیه‌ی دیگر نمی‌تواند واژه‌ی جامانده در این ناحیه را جبران کند. کفایت شرط با ساخت یک شروع مجاز برای هر پنجره نشان داده می‌شود؛ همه‌ی پنجره‌ها با همان عرض و همان هزینه، واژه‌های مرجع را می‌پوشانند. این گواه سازنده، امکان را از حدس درباره‌ی کیفیت روش جدا می‌کند.

برای کمترین بودجه، ممیز جایگاه تخصیص واژه‌ی مورد نیاز هر ناحیه را در ترتیب نوبتی محاسبه می‌کند. بزرگ‌ترین این جایگاه‌ها، نخستین بودجه‌ای است که همه‌ی شرط‌ها را هم‌زمان برقرار می‌کند. در این بودجه گواه موفق ساخته می‌شود و در یک واژه کمتر دست‌کم یک شرط برقرار نیست. اگر جلسه‌ی شاهد غایب باشد، بودجه‌ی متناهی تعریف نمی‌شود. اثبات و نمادگذاری کامل در قرارداد رسمی مرحله‌ی ۱۸ آمده است [S18F].

۴۶ افراز شکست‌ها در LoCoMo

جدول ۵ تجزیه‌ی پرسش‌های LoCoMo

وضعیت در ۱۰۲۴ واژه	تعداد پرسش
پوشش کامل توسط نویسنده	۴۴۳
جلسه‌ی شاهد غایب	۱۰۶
هندسه‌ی ناممکن با جلسه‌های در دسترس	۲۵
انتخاب ناموفق با وجود پنجره‌ی موفق	۲۵

چهار ردیف افراز ۵۹۹ پرسش‌اند. سقف ۴۶۸ از جمع ۴۴۳ موفقیت و ۲۵ انتخاب ناموفقِ دارای امکان به دست می‌آید و دسته‌ی پنجم نیست [C07، C08]. از ۱۵۶ شکست، ۱۳۱ مورد، حدود ۸۴٪، در همان فرصت‌های ثابت با تغییر صرف انتخاب رفع نمی‌شوند. غیبت جلسه با ۱۰۶ مورد بزرگ‌ترین دسته است. این دسته‌بندی محل محدودیت را در خط لوله‌ی ممیزی‌شده مشخص می‌کند و به‌تنهایی علت شناختی شکست را تعیین نمی‌کند.

میانگین مساوی هفت گفت‌وگو برای روش موجود ۷۴٫۱۹٪ و برای سقف ۷۸٫۳۸٪ است. فاصله‌ی دقیقِ گردشده ۴٫۱۹ واحد درصد و بازه‌ی بازنمونه‌گیری خوشه‌ای توصیفی ۲٫۹۶ تا ۵٫۱۳ واحد درصد است [C08]. نسبت شمار پرسش‌ها وزن‌دهی دیگری دارد: ۴۴۳ از ۵۹۹ حدود ۷۳٫۹۶٪ و ۴۶۸ از ۵۹۹ حدود ۷۸٫۱۳٪ است. این دو شیوه‌ی تجمیع نباید در یک استدلال جای هم قرار بگیرند.

سقف از محل شاهد مرجع اطلاع دارد و عملکرد به‌دست‌آمده‌ی یک بازیاب عملی محسوب نمی‌شود. همچنین به لنگر، عرض، ترتیب تخصیص و فضای قانونی ثابت وابسته است. تغییر هر یک از این اجزا به ممیزی تازه نیاز دارد. عدد ۲۵ نیز ظرفیت باقی‌مانده‌ی همین فضای انتخاب است؛ یک رتبه‌بند که لنگرها را عوض می‌کند فضای دیگری می‌سازد.

۶٫۵ سه گواه برای فهم محدودیت

در گفت‌وگوی conv-30 و پرسش با شناسه‌ی ۲، جلسه‌ی اول در دسترس نیست؛ ممیز کمترین بودجه را تعریف‌نشده ثبت می‌کند. در پرسش ۲۶ همان گفت‌وگو، ناحیه‌ای به عرض ۳۱۰ نیاز دارد، ولی در بودجه‌ی ۱۰۲۴ تنها ۱۲۸ واژه به آن رسیده است؛ کمترین بودجه‌ی کل ۲۳۸۸ است. در پرسش ۴، پنجره‌ی موفق از بودجه‌ی ۸۵۳ قابل ساخت است و نویسنده با بودجه‌ی ۱۰۲۴ آن را انتخاب نکرده است [S18].

این نمونه‌ها پس از مشاهده‌ی نتایج برای توضیح انتخاب شده‌اند و نمونه‌ی آماری مستقل نیستند. هر کدام نوع متفاوتی از گواه می‌دهند: غیبت مسیر دسترسی، عرض ناکافی و وجود فرصت استفاده‌نشده. نسبت دادن همه‌ی آن‌ها به جای مرز، اطلاعات تشخیصی را از بین می‌برد.

۶٫۶ ممیزی QMSum

در قرارداد کامل‌پوشانی مرحله‌ی ۱۸، QMSum دارای ۲۳ موفقیت، صفر جلسه‌ی غایب، ۲۱۵ هندسه‌ی ناممکن و ۶ انتخاب ناموفقِ دارای امکان است. سقف دقیق ۲۹ از ۲۴۴ است [C09]. هر پرسش از جلسه‌ی مربوط به خود بازیابی می‌شود، بنابراین سنجه‌ی دسترسی به جلسه در این قرارداد قدرت تمایز کمی دارد. محدودیت عمده به پوشش همه‌ی واژه‌های بازه‌های مرتبط و هندسه‌ی مجاز مربوط است.

این خروجی، سنجه‌ی کامل‌پوشانی مشترک است. سنجه‌ی کسر نوبت‌های مرتبط در فصل ۵ تعریف دیگری دارد. بزرگی یک بازه‌ی برچسب‌خورده درباره‌ی حداقل اطلاعات لازم برای پاسخ قطعی نمی‌دهد. امکان پاسخ از شاهد جایگزین یا زیرمجموعه‌ی کوتاه‌تر در این ممیز مدل نشده است.

۶٫۷ مداخله در دسترسی به جلسه

مرحله‌ی ۱۹ از فهرست مشترک ۶۴ نامزد BM25 و هشت لنگر استفاده می‌کند. سیاست اصلی reserve4 نماینده‌ی چهار جلسه‌ی متمایز را تا حد امکان رزرو می‌کند و باقی را با ترتیب اصلی پر می‌کند. سیاست ثانویه‌ی reserve8 همین کار را برای هشت جلسه انجام می‌دهد. پس از انتخاب، ترتیب BM25 بازگردانده می‌شود تا ترتیب تخصیص متغیر آزاد اضافی نشود. هندسه و سقف امکان برای هر سیاست دوباره محاسبه می‌شود [S19].

رزرو چهار جلسه در LoCoMo تنها در ۸ از ۵۹۹ پرسش و در منبع بیرونی تنها در ۱ از ۶۰۹ پرسش مجموعه‌ی لنگرها را تغییر داد. قاعده‌ی اصلی ادامه تامین نشد [C10؛ S19]. بنابراین نتیجه‌ی خنثی این سیاست با شدت مداخله‌ی اندک همراه است. از آن نمی‌توان بی‌فایده بودن همه‌ی سیاست‌های استفاده از ساختار جلسه را نتیجه گرفت.

جدول ۶ دسترسی و امکان و پوشش

شاخص LoCoMo در ۱۰۲۴ واژه	مبنای BM25	رزرو هشت جلسه
دسترسی به همه‌ی جلسه‌های شاهد	۴۹۳	۵۰۷
امکان دقیق پوشش کامل	۴۶۸	۴۶۱
پوشش کامل واقعی	۴۴۳	۴۰۱

این اعداد برای نویسنده و قرارداد مرحله‌ی ۱۹ هستند [C11]. افزایش دسترسی همراه با کاهش امکان و پوشش رخ داده است. آوردن جلسه‌های بیشتر، بخشی از لنگرهای قبلی را جایگزین و ظرفیت‌های محلی را تغییر می‌دهد. نتیجه‌ی محدود این است که در سیاست آزموده‌شده، دسترسی بیشتر برای ساخت شاهد کامل کافی نبوده است.

در چهار پروژه‌ی تولیدشده‌ی EverMemBench-Dynamic، دسترسی کامل از ۴۹ به ۵۹ پرسش افزایش یافت، اما میانگین مساوی پروژه‌ها برای کسر پیام‌های مرجعِ کامل از **۱۹٫۵۳٪** به **۱۵٫۶۵٪** رسید [C12]. معیار بیرونی با شاخص همه‌یاهیچ LoCoMo متفاوت است. ادغام این دو درصد در یک امتیاز کلی معنا ندارد.

۸٫۶ کنترل شدت تغییر و اصلاحیه‌ی اکتشافی

پس از مشاهده‌ی مداخله‌ی ضعیف کنترل‌های اولیه، اصلاحیه‌ی مرحله‌ی ۱۹ب ثبت شد. کنترل جدید به تعداد تعویض لنگر در سیاست هشت‌جلسه‌ای وابسته است: لنگر اول حفظ می‌شود، تعدادی از لنگرهای باقی‌مانده نگه داشته می‌شوند و همان تعداد جایگزین از رتبه‌های ۹ تا ۶۴ گرفته می‌شود. ده بذر درون هر پرسش میانگین می‌شوند. تعداد تعویض برابر است؛ امتیاز BM25 یا کیفیت معنایی جایگزین‌ها برابر نشده است [S19B].

پوشش سیاست هشت‌جلسه‌ای از میانگین این کنترل‌ها در LoCoMo برابر **۴٫۰۱** واحد درصد و در منبع بیرونی **۱٫۴۲** واحد درصد پایین‌تر است [C13]. انتظار دسترسیِ کنترل با شمارش ترکیبی دقیق نیز محاسبه شده و سیاست هشت‌جلسه‌ای از آن در دسترسی بالاتر است. هم‌زمانی این دو مشاهده، تمایز دسترسی و مونتاژ شاهد را تقویت می‌کند. این اصلاحیه پس از نتیجه‌ی اصلی شکل گرفته و جایگاه اکتشافی خود را حفظ می‌کند.

تمام شرط‌های مقایسه‌ی اصلی ۱۰۲۴ واژه هزینه‌ی یکتای برابر دارند. اشباع ظرفیت در بخشی از کنترل‌های بودجه‌ی ۲۰۴۸ جداگانه گزارش شده است. برابر بودن هزینه در بودجه‌ی اصلی را نباید به تمام بودجه‌ها تعمیم داد [S19].

۹.۶ نتیجه‌ی فصل

سه سطح تشخیصی اکنون قابل تفکیک‌اند: دسترسی به منبع شاهد، امکان پوشش در ظرفیت محلی و انتخاب واقعی شاهد. مرحله‌ی ۱۸ ظرفیت اصلاح را در فضای ثابت مشخص می‌کند و مرحله‌ی ۱۹ نشان می‌دهد بهبود سطح دسترسی می‌تواند با افت دو سطح دیگر همراه شود. این نتیجه برای انتخاب محل اصلاح معماری کاربرد دارد و به قرارداد شاهد و هزینه‌ی این پژوهش محدود است.

فصل ۷ بحث و حدود اعتبار یافته‌ها

۱۷ پاسخ به پرسش پژوهش

انتظار آغازین پژوهش این بود که قطعه‌بندی الهام‌گرفته از رویداد بتواند نگهداری و بازیابی اطلاعات را بهتر کند. مجموعه‌ی شواهد از یک برتری پایدار برای نویسنده‌ی بررسی‌شده تحت معیارهای اصلی پشتیبانی نمی‌کند. هم‌زمان، تحلیل‌ها توضیح دقیق‌تری درباره‌ی محل محدودیت به دست می‌دهند: هم‌راستایی تقریبی مرز موضوع کافی نیست، بخشی از شکست‌ها در فضای انتخاب موجود قابل رفع نیستند و افزایش دسترسی به جلسه می‌تواند با کاهش پوشش محلی همراه شود [C01 تا C13].

این پاسخ به یک نویسنده‌ی ثابت، رتبه‌بندی واژگانی و قراردادهای مشخص تعلق دارد. «معنا» به تعبیر فلسفی سرل و ادراک اپیزودیک انسان انگیزه‌ی مفهومی بوده‌اند. سنجه‌های این پژوهش حضور متن مرجع را می‌سنجند و برای داوری مستقیم درباره‌ی آن مفاهیم طراحی نشده‌اند [P01 تا P03].

۲۷ مشارکت در روش ارزیابی

با تغییر واحد حافظه، چند عامل ممکن است هم‌زمان جابه‌جا شوند. حتی اگر فرمول BM25 و سقف خروجی ثابت باشند، تغییر طول اسناد، شمار قطعه و آمار نمایه می‌تواند رتبه‌ها را تغییر دهد. مراحل کنترل شمار قطعه و سپس فرصت‌های ثابت، این ابهام را محدود کرده‌اند. در مرحله‌ی ۱۷، نمایه، لنگرها، پنجره‌های مجاز، عرض و هزینه‌ی یکتا میان انتخابگرها یکسان‌اند؛ تنها راهنمای انتخاب پنجره تفاوت دارد [S17].

این کنترل، شناسایی اثر الگوریتم در همان مقایسه‌ی جفت‌شده را بهتر می‌کند. داده‌ی قبلا دیده‌شده، شمار محدود تاریخچه‌ها و محدودیت سنجه همچنان باقی‌اند. در مرحله‌ی ۱۹ با تغییر سیاست لنگر، فرصت‌ها میان سیاست‌ها یکسان نیستند و ممیزی امکان برای هر سیاست دوباره انجام می‌شود. تفکیک این دو طراحی برای تفسیر رابطه‌ی مرز و عملکرد ضروری است.

۳۷ ارزش تجزیه‌ی تشخیصی

سقف ۴۶۸ از ۵۹۹ به پرسش مهندسی مشخصی پاسخ می‌دهد: در همین هندسه چه تعداد پرسش امکان پوشش کامل دارند. فاصله‌ی روش موجود تا سقف، ظرفیت انتخاب بهتر را مشخص می‌کند. شمار ۱۰۶ جلسه‌ی غایب نیز نشان می‌دهد افزایش عرض پنجره‌های موجود برای همه‌ی شکست‌ها راه‌حل مناسبی نیست [C07، C08].

کاربرد عملی این تجزیه، تخصیص تلاش توسعه است. اگر شاهد اصلا در جلسات در دسترس نباشد، مسیر دسترسی بررسی می‌شود. اگر عرض و ناحیه اجازه‌ی پوشش ندهند، هندسه و تخصیص بررسی می‌شوند. اگر گواه موفق موجود باشد و روش آن را پیدا نکند، انتخابگر هدف مناسبی برای بررسی است. این راهنما به گواه‌های محاسباتی متکی است و موفقیت یک اصلاح پیشنهادی را از پیش تضمین نمی‌کند.

۴ ۷ نتیجه‌ی منفی و محتوای آموزشی آن

نتیجه‌ی منفی زمانی اطلاعات بیشتری می‌دهد که مداخله واقعا رخ داده، معیار روشن و قدرت تفسیر کنترل مشخص باشد. رزرو چهار جلسه در بیشتر پرسش‌ها بی‌تغییر بود و نتیجه‌ی خنثی آن دامنه‌ی رد محدودی دارد. در مقابل، رزرو هشت جلسه انتخاب‌ها را در موارد بیشتری تغییر داد و با دسترسی بالاتر و پوشش پایین‌تر همراه شد. کنترل تعویض هم‌تعداد نیز بخشی از توضیح مبتنی بر شدت تغییر را بررسی کرد [C10 تا C13].

کنترل تعویض، افت ارتباط واژگانی یا تغییر هندسه را به‌تنهایی جدا نمی‌کند. تعبیر دقیق این است که سیاست مشخص تنوع جلسه، تحت این هزینه و این انتخابگر، بر کنترل مورد بررسی مزیت پوشش نداشته است. ادعای کلی درباره‌ی بی‌فایده بودن تنوع، حافظه‌ی سلسله‌مراتبی یا مرزبندی معنایی از این نتیجه فراتر می‌رود.

۵ ۷ اعتبار سنجه‌ی شاهد

حضور تمام واژه‌های مرجع یک سنجه‌ی سخت‌گیرانه و قابل محاسبه است. پاسخ ممکن است با زیرمجموعه‌ای کوتاه‌تر، شاهد تکرارشده در جای دیگر یا استنباط از متن متفاوت قابل تولید باشد. از سوی دیگر، حضور تمام متن مرجع تضمین نمی‌کند خواننده پاسخ درست تولید کند. بنابراین پوشش برچسبی، کفایت معنایی و استفاده‌ی مدل از شاهد سه متغیر جدا باقی می‌مانند [S18، S19].

این تمایز در QMSum و منبع بیرونی برجسته است. بازه‌ی مرتبط با خلاصه ممکن است پهن باشد. در منبع بیرونی، میانه‌ی طول پیام‌های مرجع هر پرسش ۱۴۳۵ واژه است و برای ۴۳۱ از ۶۰۹ پرسش مجموع واژه‌های مرجع از بودجه‌ی ۱۰۲۴ بیشتر است [C15؛ S19D]. این مشاهده محدودیت کامل‌پوشانی برچسب را نشان می‌دهد و به معنی ناممکن بودن پاسخ معنایی نیست. درصد LoCoMo و درصد پیام‌های مرجع بیرونی به دلیل تفاوت هدف، سنجه‌ی عملکرد یکسانی نمی‌سازند.

۶ ۷ اعتبار آماری و سابقه‌ی مشاهده

پرسش‌های یک تاریخچه زمینه‌ی مشترک دارند. بذرهای کنترل نیز داده‌ی انسانی تازه تولید نمی‌کنند. شمار زیاد شرط‌های پرسش و سیاست و بودجه، تعداد نمونه‌ی مستقل را افزایش نمی‌دهد. LoCoMo بر هفت گفت‌وگو متکی است و چهار پروژه‌ی بیرونی از فرایند تولید مشترک آمده‌اند. بازه‌های خوشه‌ای حساسیت توصیفی را بیان می‌کنند و ادعای تعمیم به جمعیت گسترده نمی‌سازند [S18، S19].

در QMSum، ۳۵ جلسه در خانواده‌های منبع قرار می‌گیرند. بازنمونه‌گیری سطح جلسه در مرحله‌ی ۱۱ سابقه‌ی تاریخی خود را دارد؛ مراحل بعدی وابستگی خانواده را صریح‌تر بررسی کرده‌اند. مقایسه‌ی بازه‌های این طراحی‌ها بدون توجه به واحد بازنمونه‌گیری مناسب نیست. در Memora نیز دوره‌های چندگانه‌ی یک شخصیت، شخصیت مستقل تازه محسوب نمی‌شوند [S17L].

ثبت محلی طرح پیش از امتیازدهی یک روش با آزمون روی داده‌ی دست‌نخورده متفاوت است. بسیاری از تحلیل‌ها روی داده‌ی دیده‌شده انجام شده‌اند. اصلاحیه‌ی کنترل تعویض و تشخیص حداقل یک شاهد صریحا پس از نتیجه تعریف شده‌اند. ترتیب واقعی تصمیم و مشاهده باید در پایان‌نامه حفظ شود. ثبت‌های محلی بعدا منتشرشده، ثبت عمومی مستقل پیش از مشاهده معرفی نمی‌شوند.

۷ ۷ بازتولیدپذیری و هزینه

پیاده‌سازی‌های اصلی مرحله‌های ۱۸ و ۱۹ روی CPU و بدون فراخوانی استنتاج تجاری اجرا شده‌اند. زمان اجرای کد با زمان مرور منابع، نگارش و آماده‌سازی گزارش یکسان نیست. هزینه‌ی خروجی متنی نیز هزینه‌ی مالی یک مدل یا کل هزینه‌ی ساخت حافظه را اندازه نمی‌گیرد [S18، S19].

خروجی‌های عددی، قراردادها، گواه‌ها و راهنمای بازاجرا منتشر شده‌اند. در مرحله‌ی ۱۹ب، یک فایل ردیفِ صفربایتی رد و تنها بازاجراهای کامل و یکسان پذیرفته شدند. حفظ این سابقه و نتایج منفی، امکان ممیزی را بیشتر می‌کند. متن خام مجموعه‌ها و فونت‌های ارسالی بازتوزیع نمی‌شوند. این بسته‌ی تدوین نیز هش خروجی‌های تاریخی را بررسی می‌کند و نتایج آن‌ها را بازنویسی نمی‌کند [S19E].

۷ ۸ ادامه‌ی پژوهش پس از پایان‌نامه

جهت نخست، بررسی ۲۵ خطای انتخابِ دارای امکان است. این موارد برای مطالعه‌ی مکانیزم انتخاب مفیدند، اما بر اساس مشاهده‌ی برچسب مرجع شناخته شده‌اند. تنظیم روش روی همین موارد و گزارش بهبود روی همان‌ها، ارزیابی مستقل نمی‌سازد. اگر رتبه‌بند تازه لنگرها یا نامزدها را تغییر دهد، سقف امکان باید دوباره محاسبه شود. اگر انتخابگر در همان فضای ثابت تغییر کند، گواه‌های موجود برای تشخیص باقی‌مانده‌ی خطا کاربرد دارند.

جهت دوم، رزرو تطبیقی وابسته به ویژگی پرسش است. نوع پرسش در بازیاب عملی باید از ورودی مجاز تعیین شود و به برچسب مرجع آزمون متکی نباشد. شدت تغییر، ارتباط لنگر و ظرفیت محلی هر سیاست باید اندازه‌گیری شود. این پیشنهاد از یافته‌ی رزرو ثابت انگیزه می‌گیرد و نتیجه‌ی موفق برای آن در دست نیست.

جهت سوم، تحلیل رابطه‌ی کیفیت مرز و پوشش شاهد است. طرح پیشنهادی فصل ۵ می‌تواند توضیح‌ها را محدودتر کند. ریزدانگی مرجع، طول متن و وابستگی جلسه‌ها باید در آن لحاظ شوند. این سه جهت با زیرساخت موجود قابل بررسی‌اند و در دامنه‌ی الزامی پایان‌نامه قرار ندارند.

نسخه‌ی کوتاه قابل ارائه می‌تواند پرسش امکان‌پذیری، تجزیه‌ی فاز ۱۸ و ناهم‌جهتی دسترسی و پوشش فاز ۱۹ را محور قرار دهد. تعیین کارگاه، قواعد ارسال و سیاست نویسندگی پس از تثبیت متن و با نظر استاد انجام می‌شود. این بسته شامل ادعای پذیرش، ارسال مقاله یا تعیین هم‌نویسنده نیست.

۹.۷ جمع‌بندی بحث

ارزش پژوهش در این است که یک انتظار معماری را به مجموعه‌ای از پرسش‌های قابل سنجش و شکست‌های قابل تشخیص تبدیل می‌کند. نتیجه‌ی مرکزی، وابستگی پوشش شاهد به دسترسی، ظرفیت محلی و انتخاب است. چارچوب موجود به تصمیم توسعه جهت می‌دهد و حدود خود را درباره‌ی برچسب، داده، هزینه و تعمیم روشن نگه می‌دارد.

از استاد امیر نوری برای راهنمایی دانشگاهی و هدایت روایت پایان‌نامه، و از دکتر آرش فکری، بنیان‌گذار فردیت FARDIAT، مجتمع فوق تخصصی مغز و شناخت، برای آموزش علوم اعصاب شناختی و بررسی و تایید پروپوزال سپاسگزارم.

فصل ۸ نتیجه‌گیری و ادامه‌ی پژوهش

۸.۱ پاسخ نهایی به پرسش‌ها

در روش و داده و هزینه‌ی بررسی‌شده، برتری عملی و پایدار مورد انتظار از نویسنده‌ی مرزی مشاهده نشد. کنترل دقیق‌تر نشان داد بخشی از تفاوت‌های مراحل اولیه می‌توانند با شمار قطعه، نمایه، نقش و فرصت انتخاب درآمیزند. چارچوب نهایی این عوامل را روشن و مقایسه‌ی محدودتری را قابل دفاع کرده است.

در فضای ثابت مرحله‌ی ۱۸، سقف کامل‌پوشانی LoCoMo برابر ۴۶۸ از ۵۹۹ و عملکرد نویسنده ۴۴۳ مورد است. از شکست‌های آن، ۱۰۶ مورد به جلسه‌ی غایب، ۲۵ مورد به هندسه‌ی ناممکن و ۲۵ مورد به انتخاب ناموفق با وجود فرصت مجاز تعلق دارد. این تشخیص نشان می‌دهد انتخاب بهتر در همان فضا ظرفیت محدودی دارد و تغییر صرف مرزبند پاسخ همه‌ی شکست‌ها نیست [C07، C08].

مرحله‌ی ۱۹ نشان داد رزرو هشت جلسه می‌تواند دسترسی به همه‌ی جلسه‌های شاهد را بیشتر و پوشش واقعی را کمتر کند. شواهد تکمیلیِ اکتشافی در کنترل تعداد تعویض نیز این ناهم‌جهتی را حفظ می‌کنند [C11 تا C13]. نتیجه به سیاست آزموده‌شده و قراردادهای منبع وابسته است؛ کفایت معنایی و پاسخ نهایی در این پروژه سنجیده نشده‌اند.

۸.۲ ارزش و کاربرد

سه مشارکت قابل دفاع پایان‌نامه، چارچوب ارزیابی کنترل‌شده، گواه دقیق تشخیصی در فضای ثابت و تمایز دسترسی و مونتاژ شاهد محلی‌اند. این ترکیب به توسعه‌دهنده کمک می‌کند پیش از تغییر معماری، معلوم کند محدودیت از دسترسی، ظرفیت یا انتخاب می‌آید. در پژوهش نیز امکان گزارش نتیجه‌ی منفی با محتوای توضیحی و قابل ممیزی را فراهم می‌کند.

۸.۳ اولویت‌های آینده

پس از پایان‌نامه، انتخابگر قوی‌تر در فرصت‌های ثابت، رزرو تطبیقی مبتنی بر ورودی مجاز پرسش و رابطه‌ی کیفیت مرز با پوشش می‌توانند بررسی شوند. روش باید پیش از امتیازدهی تکمیلی، قرارداد، هزینه و سنجه‌ی روشن داشته باشد. تنظیم روی خطاهای شناسایی‌شده به‌تنهایی ارزیابی مستقل ایجاد نمی‌کند. تغییر لنگر یا هندسه نیز نیازمند محاسبه‌ی دوباره‌ی سقف است.

سنجش پاسخ مستند و شاهد کمینه می‌تواند اعتبار کاربردی را گسترش دهد، اما به خواننده و داوری مناسب نیاز دارد. آزمون ادراک انسانی یا سازوکار عصبی نیز طراحی و داده‌ی جدا می‌خواهد. این مسیرها برای تکمیل پایان‌نامه‌ی حاضر الزام اجرایی نیستند.

منابع بیرونی

شناسه‌های P به منابع اصلی زیر ارجاع دارند. وضعیت انتشار و دامنه‌ی خواندن در دفتر پیشینه ثبت شده است.

P01

John R. Searle. 1980. Minds, brains, and programs. Behavioral and Brain Sciences 3(3), 417–424.

https://doi.org/10.1017/S0140525X00005756

P02

Jeffrey M. Zacks; Nicole K. Speer; Khena M. Swallow; Todd S. Braver; Jeremy R. Reynolds. 2007. Event perception: a mind-brain perspective. Psychological Bulletin 133(2), 273–293.

https://pubmed.ncbi.nlm.nih.gov/17338600/

P03

Tan T. Nguyen; Joset A. Etzel; Matthew A. Bezdek; Jeffrey M. Zacks. 2026. Multiple event segmentation mechanisms in the human brain. eLife 107955.3, Version of Record, 7 July 2026.

https://elifesciences.org/articles/107955

P04

Stephen Robertson; Hugo Zaragoza. 2009. The Probabilistic Relevance Framework: BM25 and Beyond. Foundations and Trends in Information Retrieval 4(1–2), 1–174.

https://doi.org/10.1561/1500000019

P05

Patrick Lewis; Ethan Perez; Aleksandra Piktus; Fabio Petroni; Vladimir Karpukhin; Naman Goyal; Heinrich Küttler; Mike Lewis; Wen-tau Yih; Tim Rocktäschel; Sebastian Riedel; Douwe Kiela. 2020. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. NeurIPS 2020 acceptance stated on author arXiv record.

https://arxiv.org/abs/2005.11401v4

P06

Adyasha Maharana; Dong-Ho Lee; Sergey Tulyakov; Mohit Bansal; Francesco Barbieri; Yuwei Fang. 2024. Evaluating Very Long-Term Conversational Memory of LLM Agents. ACL 2024, 13851–13870.

https://aclanthology.org/2024.acl-long.747/

P07

Ming Zhong; Da Yin; Tao Yu; Ahmad Zaidi; Mutethia Mutuma; Rahul Jha; Ahmed Hassan Awadallah; Asli Celikyilmaz; Yang Liu; Xipeng Qiu; Dragomir Radev. 2021. QMSum: A New Benchmark for Query-based Multi-domain Meeting Summarization. NAACL 2021, 5905–5921.

https://aclanthology.org/2021.naacl-main.472/

P08

Di Wu; Hongwei Wang; Wenhao Yu; Yuwei Zhang; Kai-Wei Chang; Dong Yu. 2025. LongMemEval: Benchmarking Chat Assistants on Long-Term Interactive Memory. ICLR 2025 official proceedings.

https://proceedings.iclr.cc/paper_files/paper/2025/hash/d813d324dbf0598bbdc9c8e79740ed01-Abstract-Conference.html

P09

Zhuoshi Pan; Qianhui Wu; Huiqiang Jiang; Xufang Luo; Hao Cheng; Dongsheng Li; Yuqing Yang; Chin-Yew Lin; H. Vicky Zhao; Lili Qiu; Jianfeng Gao. 2025. SeCom: On Memory Construction and Retrieval for Personalized Conversational Agents. ICLR 2025 official proceedings.

https://proceedings.iclr.cc/paper_files/paper/2025/hash/e56f394bbd4f0ec81393d767caa5a31b-Abstract-Conference.html

P10

Huhai Zou; Tianhao Sun; Chuanjiang He; Yu Tian; Zhenyang Li; Li Jin; Nayu Liu; Jiang Zhong; Kaiwen Wei. 2026. ES-Mem: Event Segmentation-Based Memory for Long-Term Dialogue Agents. arXiv preprint; reviewed venue not verified here.

https://arxiv.org/abs/2601.07582v2

P11

Nelson F. Liu; Kevin Lin; John Hewitt; Ashwin Paranjape; Michele Bevilacqua; Fabio Petroni; Percy Liang. 2024. Lost in the Middle: How Language Models Use Long Contexts. Transactions of the Association for Computational Linguistics 12, 157–173.

https://aclanthology.org/2024.tacl-1.9/

P12

Yufeng Li; Shuxin Li; Zhenhua Xu; Junxian Li; Peng Zeng; Sheng Yao; Changting Lin; Gaolei Li; Ran Bi; Meng Han. 2026. Relevance Is Not Sufficiency: What Actually Closes the Evidence Gap in Long-Term Memory QA. arXiv preprint, 7 October 2026.

https://arxiv.org/html/2610.09348v1

P13

Zhengye Bao; Shengtao Zhang; Haokai Zhang; Shiqi Lou; Muning Wen; Minnan Luo. 2026. Is Complex Agentic Memory Always Needed? Naive RAG Is Stronger Than We Thought. arXiv preprint, 22 October 2026.

https://arxiv.org/html/2610.30755v1

P14

Sen Gao; Yongan Li; Han Chen; Bingsheng He; Ming Wu; Jason Zeng; Michael Heinrich; Shixuan Sun. 2026. MemDerive: A Diagnostic Benchmark for Agent Memory over Evolving Data. arXiv preprint, 18 October 2026.

https://arxiv.org/abs/2610.25373v1

P15

Xianxuan Long; Zhikai Chen; Shenglai Zeng; Shouren Wang; Kai Guo; Jiliang Tang. 2026. MemTrace: Probing What Final Accuracy Misses in Long-Term Memory. arXiv preprint, 15 June 2026.

https://arxiv.org/abs/2606.17328v1

P16

Chuanrui Hu; Tong Li; Xingze Gao; Hongda Chen; Yi Bai; Dannong Xu; Tianwei Lin; Xiaohong Li; Yunyun Han; Jian Pei; Yafeng Deng. 2026. Evaluating Long-Horizon Memory for Multi-Party Collaborative Dialogues. Author arXiv v3; dataset-card KDD statement not independently verified in this review.

https://arxiv.org/abs/2602.01313v3

منابع داخلی و راهنمای شواهد

نسخه‌ها و شناسه‌ها

خروجی‌های تجربی تا مرحله‌ی ۱۹ در نسخه‌ی db76c5eb85c019c840ad76ace7e9aa5043fac283 و بسته‌ی اول تدوین در نسخه‌ی 3dff8ac1db62cb8759487b67df322d4b5b458e7d مبنا قرار دارند. شناسه‌های C به ادعاهای عددی و P به کتاب‌شناسی بیرونی اشاره دارند. شناسه‌های S به پرونده‌های داخلی زیر مربوط‌اند. هر مسیر نسبت به ریشه‌ی مخزن است.

جدول ۷ منابع داخلی پژوهش

کد	منبع
S10	docs/phase10.md و results/phase10_summary.json
S11	docs/phase11.md و results/phase11_summary.json و results/phase11_posthoc_diagnostics.json
S17	docs/phase17.md و docs/phase17_formal_contract.md و configs/phase17_plan.json و results/phase17_summary.json
S17L	docs/phase17_state_ledger.md
S18	docs/phase18.md و results/phase18_summary.json
S18F	docs/phase18_formal_contract.md
S19	docs/phase19.md و docs/phase19_research_note_en.md و results/phase19_summary.json
S19B	docs/phase19b_amendment.md و results/phase19b_summary.json
S19D	docs/phase19.md و results/phase19_diagnostics.json
S19E	docs/phase19_execution_notes.md و docs/phase19_reproduce.md

ادعاهای تکمیلی دفتر یکپارچه

جدول ۸ ادعاهای تکمیلی

شناسه	شاهد افزوده‌شده	قید
C14	مقایسه‌های مرحله‌ی ۱۷ در ۱۰۲۴ واژه	فرصت‌های ثابت و بازه‌ی توصیفی

شناسه	شاهد افزوده‌شده	قید
C15	دانه‌بندی مرجع در LoCoMo و منبع بیرونی	شاهد برچسبی و تفاوت سنجه
C16	۲۷۴ توسعه و ۵۹۹ ارزیابی اولیه	داده‌ی ارزیابی بعدا دیده شده است

دفتر یکپارچه در evidence_ledger_integrated.json مقدار دقیق و نشانی هر شاهد را ثبت می‌کند. ابزار بررسی، آن را از خروجی‌های موجود بازمی‌سازد و با نسخه‌ی ثبت‌شده مقابله می‌کند. قالب گزارش و تغییر فصل‌ها، نتیجه‌ی محاسباتی تازه‌ای ایجاد نمی‌کنند.

خاستگاه و قدردانی

این پژوهش، پروژه‌ی کارشناسی مهندسی کامپیوتر دانشگاه آزاد اسلامی واحد کرج، به پژوهشگری یوسف ابوالفتحی روزبهانی و راهنمایی دانشگاهی استاد امیر نوری است. از استاد نوری برای راهنمایی علمی و هدایت روایت پایان‌نامه و از دکتر آرش فکری، بنیان‌گذار فردیت FARDIAT، مجتمع فوق تخصصی مغز و شناخت، برای آموزش علوم اعصاب شناختی و بررسی و تایید پروپوزال سپاسگزاری می‌شود.

پیوست الف نمادگذاری و شرط دقیق

ناحیه و پنجره‌ی مجاز

ناحیه‌ی i در یک جلسه، بازه‌ی نیمه‌باز $[l_i, u_i)$ با لنگر a_i و ظرفیت c_i است. عرض آن در بودجه‌ی B با w_i نمایش داده می‌شود. پنجره پیوسته، داخل ناحیه و حامل لنگر است. کوچک‌ترین فاصله‌ی پوشاننده‌ی لنگر و موقعیت‌های مرجع داخل ناحیه، r_i است؛ اگر مرجع خالی باشد، r_i برابر یک است.

$F_q(B)$ شاخص امکان کامل‌پوشانی پرسش q است. S_G و S_A به‌ترتیب مجموعه‌ی جلسه‌های مرجع و دارای لنگرند. k تعداد ناحیه‌ها و در قرارداد محوری هشت است. نماد $\mathbf{1}$ شاخص شرط است؛ حاصل‌ضرب، برقرار بودن شرط عرض برای همه‌ی ناحیه‌ها را الزام می‌کند.

$$F_q(B) = \mathbf{1}[S_G \subseteq S_A] \prod_{i=1}^{k} \mathbf{1}[w_i(B) \geq r_i]$$

رابطه‌ی ۱ شرط دقیق امکان پوشش در فضای ثابت

ضرورت از پیوستگی و مجزا بودن ناحیه‌ها و کفایت از ساخت شروع مجاز پنجره نتیجه می‌شود. صورت‌بندی، اثبات و قرارداد برچسب در S18F ثبت شده‌اند؛ معادله از همان مرحله است.

کمترین بودجه‌ی تخصیص نوبتی

$T_i(r)$ جایگاه واژه‌ی rام ناحیه‌ی i در ترتیب تخصیص نوبتی است. پیش از دور r، هر ناحیه حداقل ظرفیت خود یا r منهای یک واژه دریافت کرده است. در همان دور، ناحیه‌های فعال تا i نیز به هزینه‌ی پیش از واژه‌ی مورد نیاز اضافه می‌شوند. بزرگ‌ترین جایگاه لازم، کمترین بودجه‌ی کل را تعیین می‌کند.

$$B_{\min} = \max_{i} \left[\sum_{j} \min(c_j, r_i - 1) + \sum_{j \leq i} \mathbf{1}(c_j \geq r_i) \right]$$

رابطه‌ی ۲ معادله‌ی کمترین بودجه برای تخصیص نوبتی ثبت‌شده

این مقدار به تخصیص و لنگرهای ثابت وابسته است و برای جلسه‌ی غایب متناهی نیست. این کمینه، شاهد معنایی پاسخ یا حد بهینه‌ی معماری دیگر نیست. کد و صورت رسمی معادلات در مخزن موجود است.

پیوست ب نقشه‌ی بازتولید

بررسی بدون متن خام

اجرای فرمان‌های زیر نتایج ثبت‌شده را از نظر ساختار، فرصت، گواه و اتصال ادعا بررسی می‌کند. این فرمان‌ها بازیابی تازه از تاریخچه‌ی خام انجام نمی‌دهند و فراخوانی مدل زبانی ندارند.

```
python scripts/build_thesis_evidence.py --check
python scripts/build_thesis_synthesis.py --check
python scripts/validate_phase17.py --directory results
python scripts/validate_phase18.py --directory results
python scripts/validate_phase19.py --directory results
python scripts/validate_phase19.py --directory results --prefix phase19b
```

بازاجرای منبع‌دار

دریافت منبع باید با نسخه و هش قرارداد انجام شود. راهنمای مرحله‌ی ۱۸ و ۱۹ مسیر دریافت، رتبه‌بندی، امتیازدهی و مقایسه‌ی خروجی را مشخص کرده است. اجرای منبع‌دار به دسترسی شبکه و داده نیاز دارد. خروجی تازه در پوشه‌ی جدا ذخیره شود تا سابقه‌ی منتشرشده جایگزین نشود. زمان اجرای محاسباتی، زمان دریافت داده، مرور منابع و تدوین را شامل نمی‌شود.

دفتر ادعا و سابقه

شناسه‌های C01 تا C13 به دفتر بسته‌ی اول و C14 تا C16 به امتداد یکپارچه‌ی آن تعلق دارند. هر مدخل، مقدار دقیق، مسیر پرونده، JSON pointer و هش منبع را نگه می‌دارد. نسخه‌ی اصلی دفتر و گزارش بسته‌ی اول حفظ می‌شوند. دفتر تازه، مرحله‌ی ۱۷، ممیزی اندازه‌ی مرجع و تقسیم توسعه و ارزیابی اولیه را نیز به متن متصل می‌کند.

پیوست پ واژه‌نامه

جدول ۹ واژه‌نامه

اصطلاح	تعریف در این پژوهش
جلسه	واحد بومی تاریخچه در منبع و قرارداد همان داده
قطعه	واحدی که الگوریتم مرزبندی می‌سازد
لنگر	موقعیت واژه‌ی منتخب از نوبت رتبه‌گرفته
ناحیه	بازه‌ی اختصاصی لنگر در همان جلسه
فرصت انتخاب	تمام پنجره‌های قانونی با عرض و لنگر ثابت
پوشش کامل	حضور همه‌ی موقعیت‌های واژه‌ی مرجع تعریف‌شده
امکان دقیق	وجود دست‌کم یک انتخاب مجاز با پوشش کامل
مونتاژ شاهد	کنار هم قرار گرفتن شاهدهای مورد نیاز در خروجی
کفایت معنایی	امکان تعیین پاسخ از مجموعه‌ی شاهد و پرسش
صحت پاسخ	درست بودن پاسخ تولیدشده طبق داوری مشخص
تحلیل پس از نتیجه	تحلیلی که پس از دیدن نتیجه‌ی انگیزاننده تعریف شده
بازتولیدپذیری	امکان بازسازی نتیجه با نسخه و قرارداد ثبت‌شده