گزارش پژوهشی مرحله‌ی دهم سنجش مرزهای موضوعی در گفت‌وگوهای جلسه‌ای

تاریخ: ۱۳ اکتبر ۲۰۲۶. وضعیت: اجرای محاسباتی و ممیزی کامل؛ گزارش پیشرفت پژوهش، نه پایان‌نامه‌ی نهایی. موضوع: انتقال نویسنده‌ی علّی حافظه به داده‌ی مستقل با بازه‌های موضوعی برچسب‌خورده.

چکیده

در مرحله‌های پیشین، روش مرزبندی حافظه با شواهد پرسش‌های LoCoMo سنجیده شد، اما آزمون مستقلی برای نزدیک بودن مرزهای آن به آغاز موضوع‌های درون یک جلسه نداشتیم. در این مرحله نویسنده‌ی علّی با تنظیمات ثابت مرحله‌ی هشتم روی ۳۵ جلسه‌ی مجموعه‌ی آزمون QMSum اجرا شد و با ۲۰ مرزبندی تصادفیِ دارای دقیقا همان تعداد قطعه در هر جلسه مقایسه شد. معیار اصلی، میانگین جلسه‌ای پوشش آغاز بازه‌های موضوعی انسان‌برچسب در فاصله‌ی حداکثر دو نوبت بود. نویسنده ۸۴٫۳۷٪ و میانه‌ی کنترل‌ها ۶۵٫۹۱٪ پوشش داد؛ هیچ‌یک از ۲۰ کنترل به مقدار نویسنده نرسید. اما در فاصله‌ی دقیق صفر نوبت، نویسنده ۲۲٫۹۲٪ و میانه‌ی کنترل‌ها ۲۳٫۸۰٪ داشت. مهم‌تر، در معیار فرعی بازیابی نوبت‌های مرتبط با پرسش و بودجه‌ی ۱۰۲۴ واژه، نویسنده ۳۴٫۶۹٪، کنترل تصادفی ۳۶٫۷۷٪ و قطعه‌ی ثابت ۳۸٫۵۹٪ به دست آورد. پس نزدیک شدن مرزهای واژگانی به شروع بازه‌ی موضوعی، به‌تنهایی بهبود بازیابی را تضمین نکرد. این مطالعه برچسب «موضوع جلسه» دارد، نه داوری ادراک رویداد یا ثبت عصبی آن.

اهمیت و پرسش پژوهش

QMSum برای ۲۳۲ جلسه و ۱۸۰۸ جفت پرسش و خلاصه، ساختار موضوعی و بازه‌های مرتبط را با برچسب انسانی فراهم کرده است [۱]. نویسنده‌ی علّی این پروژه در LoCoMo با شمار قطعه‌ی بالاتر از بعضی مقایسه‌گرها نتیجه‌ی متفاوتی داشت و مرحله‌ی نهم کنترل شمار قطعه را افزود؛ اما آن آزمون مستقل از برچسب موضوع درون جلسه نبود. شکاف دقیق در همین زنجیره‌ی پژوهشی این است که نمی‌دانستیم مرزبندی علّیِ ثابت‌شده با آغاز بازه‌ی موضوعی انسان‌برچسب هم‌راستا می‌شود یا نه و آیا این هم‌راستایی به بازیابی کمک می‌کند. این پرسش دو خروجی متفاوت دارد و نباید فقط یکی از آن‌ها به عنوان موفقیت انتخاب شود.

این ایده در مرز علوم شناختی و سامانه‌های حافظه قرار دارد، اما تازگی آن محدود و مشخص است. پژوهش ES-Mem قبلا بخش‌بندی رویداد و حافظه‌ی سلسله‌مراتبی را برای عامل گفت‌وگو پیشنهاد کرده است [۲]. مطالعه‌ی Nguyen و همکاران روی داده‌ی fMRI، سازوکارهای مرتبط با خطای پیش‌بینی و عدم قطعیت را در بخش‌بندی تجربه از هم متمایز می‌کند [۳]. نوپی Jaccard این پروژه شاخص ساده‌ی تغییر واژگان است و اندازه‌گیری مستقیم آن سازوکارهای مغزی یا «معنا» به تعبیر فلسفی نیست. ارزش کاربردی مرحله در ممیزی کم‌هزینه و قابل بازتولید مرزهای یک نویسنده‌ی قابل اجرای CPU، با یک معیار بیرونی است.

داده و قرارداد ثبت‌شده

configs/phase10_plan.json، docs/phase10_plan.md و فهرست ۳۵ فایل با هش منبع در شاخه‌ی پژوهشی پیش از محاسبه‌ی امتیازهای مرحله‌ی دهم ثبت شدند. منبع، بازنگری 83d7768c1f2b4dfeb091385d3dc7e239b8e5bb7e از مخزن رسمی QMSum است [۴]. هر فایل خام با هش Git و اندازه‌ی ثبت‌شده تطبیق یافت. در ۹ جلسه‌ی دانشگاهی، ۲۰ جلسه‌ی طراحی محصول و ۶ جلسه‌ی کمیته، مجموعا ۲۰۷۱۸ نوبت، ۱۷۹ بازه‌ی موضوعی، ۱۶۱ شروع یکتای غیرصفر و ۲۴۴ پرسش اختصاصی دارای ۲۸۶ بازه‌ی مرتبط وجود داشت. هیچ اندیس بازه‌ای خارج از محدوده نبود. داده‌ی خام در ریپوی ما منتشر نشده است.

QMSum موضوع‌ها را با بازه‌هایی ثبت می‌کند که ممکن است ناپیوسته باشند؛ شروع دوباره‌ی همان موضوع نیز یک آغاز بازه‌ی ثبت‌شده است، نه الزام به ظهور موضوع کاملا جدید [۱]. برای معیار اصلی، اندیس شروع هر بازه‌ی موضوعی بزرگ‌تر از صفر را گرفتیم و شروع‌های تکراری را در همان جلسه یک‌بار شمردیم. پایان بازه در این معیار استفاده نمی‌شود. نبود برچسب در سایر نوبت‌ها، «نبود تغییر موضوع» را ثابت نمی‌کند.

روش محاسبه

هر جلسه یک تاریخچه‌ی مستقل برای ساخت قطعه است. نویسنده‌ی علّی مرحله‌ی هشتم بدون تغییر آستانه اجرا شد: متن نوبت فعلی و سه نوبت قبل، نویی واژگانی Jaccard، شرط باز بودن حداقل ۶۴ واژه، آستانه‌ی ۰٫۸۵ و سقف ۱۶۰ واژه. اگر افزودن نوبت از سقف عبور کند قطعه بسته می‌شود؛ نوبت تکی بلند بریده نمی‌شود. مرز الگوریتم، اندیس نخستین نوبت قطعه‌ی تازه است؛ قطعه‌ی بسته با آینده بازنویسی نمی‌شود. نقش گوینده، موضوع‌ها، پرسش‌ها و پاسخ‌ها به نویسنده داده نشد. $1 - $

در هر جلسه، کنترل تصادفی با برنامه‌ریزی پویا دقیقا همان شمار قطعه‌ی نویسنده را زیر همان قید ۱۶۰ واژه و حفظ نوبت کامل می‌سازد و از میان تمام تقسیم‌های معتبر به‌طور یکنواخت نمونه می‌گیرد. ۲۰ بذر ثابت ۰ تا ۱۹ به کار رفت. تصمیم کنترل فقط طول نوبت‌ها و شمار قطعه‌ی مرجع را می‌بیند. چون شمار قطعه از گفت‌وگوی کامل آمده، کنترل پس‌نگر است؛ این ویژگی آن را نویسنده‌ی برخط قابل استقرار نمی‌کند.

برای هر جلسه، کسر آغازهای موضوعی با مرز در فاصله‌ی حداکثر دو نوبت محاسبه و سپس ۳۵ کسر به‌طور برابر میانگین شد. کنترل‌ها نیز ۲۰ میانگین هم‌تعریف دارند. فاصله‌های صفر، یک و پنج نوبت و تفکیک حوزه از پیش به عنوان حساسیت ثبت شدند. ۲۰ بذر، ۲۰ جلسه‌ی مستقل تازه نیستند و تعداد کنترل‌های برابر یا بهتر، مقدار p نیست.

برای معیار فرعی، بازه‌های فراگیر انتهاییِ specific_query_list به اجتماع اندیس نوبت‌های مرتبط با هر پرسش تبدیل شدند. با همان BM25 و گزینش حریصانه‌ی قطعه‌ی کامل، کسر نوبت‌های مرتبط بازیابی‌شده در بودجه‌های ۵۱۲، ۱۰۲۴ و ۲۰۴۸ واژه محاسبه شد. ابتدا پرسش‌های هر جلسه و سپس جلسه‌ها به‌طور برابر میانگین شدند. مقایسه‌گرها کنترل تصادفیِ هم‌شمار و قطعه‌ی ثابتِ هم‌تراز با نوبت و هدف ۱۲۸ واژه‌اند. پرسش‌های عمومی و کیفیت خلاصه یا پاسخ تولیدی در این سنجه وارد نشده‌اند.

هم‌راستایی با آغاز بازه‌های موضوعی

تلورانس نسبت به شروع بازه	نویسنده، میانگین ۳۵ جلسه	میانه‌ی ۲۰ کنترل	دامنه‌ی کنترل	کنترل برابر یا بهتر
دقیقا صفر نوبت	۲۲٫۹۲٪	۲۳٫۸۰٪	۱۶٫۵۶ تا ۲۶٫۹۹٪	۱۳ از ۲۰
حداکثر یک نوبت	۶۷٫۴۶٪	۴۹٫۱۸٪	۴۴٫۵۴ تا ۵۸٫۹۹٪	صفر از ۲۰
حداکثر دو نوبت، معیار اصلی	۸۴٫۳۷٪	۶۵٫۹۱٪	۶۲٫۵۷ تا ۷۵٫۰۲٪	صفر از ۲۰
حداکثر پنج نوبت	۹۶٫۱۶٪	۹۰٫۷۷٪	۸۶٫۵۴ تا ۹۵٫۱۴٪	صفر از ۲۰

تفاوت معیار اصلی با میانه‌ی کنترل ۱۸٫۴۶ واحد درصد است. این به معنی یافتن لحظه‌ی دقیق تغییر موضوع نیست: در تلورانس صفر، نویسنده کمی پایین‌تر از میانه‌ی کنترل بود. تحلیل توصیفیِ پس از نتیجه نشان داد نزدیک‌ترین مرز نویسنده برای ۴۵ مورد از ۱۶۱ شروع دقیقا روی آن، برای ۲۷ مورد یک نوبت قبل و برای ۴۱ مورد یک نوبت بعد قرار داشت. ۵ شروع، مرزی در فاصله‌ی پنج نوبت نداشتند. این تحلیل جهت فاصله، فرضیه‌ی جدیدی درباره‌ی زمان تشخیص مرز ایجاد می‌کند ولی از پیش معیار اصلی نبوده است.

حوزه	جلسه	شروع موضوع	نویسنده با تلورانس ۲	میانه‌ی کنترل
دانشگاهی	۹	۳۱	۸۶٫۱۱٪	۶۵٫۰۹٪
طراحی محصول	۲۰	۸۴	۷۸٫۹۰٪	۵۸٫۵۶٪
کمیته	۶	۴۶	۱۰۰٪	۱۰۰٪

در جلسات کمیته، هر دو روش به سقف ۱۰۰٪ رسیدند و این حوزه قدرت تمایز ندارد. ۱۳۰ نوبتِ بلندتر از ۱۶۰ واژه از ۱۸۷ نوبت بلند کل داده در همین حوزه بودند؛ قید اندازه مرزهای زیادی را تحمیل می‌کند. در سطح جلسه و معیار اصلی، نویسنده نسبت به میانه‌ی کنترل همان جلسه در ۲۱ جلسه بالاتر، در ۱۱ جلسه برابر و در سه جلسه پایین‌تر بود. شمار ۳۳۲۸ قطعه‌ی نویسنده در ۳۵ جلسه شامل ۲۶۶۳ بستن با شرط نویی، ۶۳۰ مورد با سقف اندازه و ۳۵ بستن انتهای جلسه است. نسبت دادن هر هم‌راستایی به «فهم موضوع» با وجود این مرزهای اجباری درست نیست.

بازیابی بازه‌های مرتبط با پرسش

بودجه‌ی واژه	نویسنده‌ی علّی	میانه‌ی ۲۰ کنترل تصادفی	قطعه‌ی ثابت ۱۲۸
۵۱۲	۲۴٫۸۶٪	۲۴٫۹۵٪	۲۴٫۷۹٪
۱۰۲۴	۳۴٫۶۹٪	۳۶٫۷۷٪	۳۸٫۵۹٪
۲۰۴۸	۴۸٫۱۷٪	۵۰٫۰۷٪	۵۲٫۹۰٪

در بودجه‌ی ۱۰۲۴ و ۲۰۴۸، هر ۲۰ کنترل تصادفی در میانگین جلسه‌ایِ بازیابی بهتر از نویسنده بودند. این نتیجه در جهت مخالف هم‌راستایی مرزهای موضوعی است. از ۲۴۴ پرسش اختصاصی، در بودجه‌ی ۱۰۲۴ برای نویسنده ۷۳٪ پرسش‌ها از نظر مجموع هزینه‌ی قطعه‌های حامل همه‌ی نوبت‌های مرتبط، از نظر ساختاری در بودجه جا می‌گرفتند؛ با این حال فقط ۲۳ پرسش تمام نوبت‌های مرتبط را واقعا بازیابی کردند. این توضیح می‌دهد چرا معیار فرعی کسر پوشش است. هم‌راستایی محلی مرز با آغاز موضوع ممکن است طول، ترکیب واژگان و رتبه‌ی BM25 را به شکلی تغییر دهد که بازیابی را بهتر نکند؛ این تبیین یک استنباط است و اثر خالص هر عامل در این مرحله جدا نشده است.

اعتبارسنجی و محدودیت‌ها

اعتبارسنج، هش طرح و فهرست منبع، ۳۵ فایل خامِ معتبر، ۱۶۱ شروع، ۲۴۴ پرسش، ماتریس کامل ۱۶۱۰۴ ردیف پرسش × روش × بذر × بودجه، برابری شمار قطعه‌ی هر کنترل، حفظ ترتیب همه‌ی نوبت‌ها، سقف واژه، فراگیری انتهای بازه و محاسبه‌ی دوباره‌ی تمام میانگین‌ها را وارسی کرد. آزمون‌های جداگانه نمونه‌گیری یکنواخت در حالت دوپارتیشنی، نوبت بلند، قطعی بودن بذر و جدایی فیلدهای برچسب از ورودی نویسنده را کنترل کردند. خروجی کاملِ عددی فشرده است؛ متن خام جلسه و پاسخ‌ها در ریپو نیستند.

برچسب‌های QMSum برای خلاصه‌سازی موضوعی جلسه ساخته شده‌اند [۱]؛ برچسب رویداد ادراک‌شده یا منفیِ کامل برای همه‌ی نوبت‌ها نیستند. در حوزه‌ی کمیته، سقف شاخص و نوبت‌های بلند قدرت تفکیک را از بین برده‌اند. عبارت «نزدیک‌تر» وابسته به پنجره‌ی دو نوبتی از پیش ثبت‌شده است؛ فاصله‌ی صفر نتیجه‌ی متفاوتی داشت. بازیابی، حضور نوبت‌های مرتبط را می‌سنجد، نه دقت پاسخ، کیفیت خلاصه، حفظ حافظه در تعامل زنده، یا بازنمایی نورونی. پرسش‌ها درون جلسات وابسته‌اند؛ روش در QMSum بازتنظیم نشد و این داده قبلا برای آزمون مرحله‌های پیشین استفاده نشده بود، اما یک مجموعه‌ی بیرونی به‌تنهایی تعمیم گسترده را ثابت نمی‌کند. هیچ اندازه‌گیری fMRI، EEG، مارکر عصبی یا فهم معنایی به معنای سرل انجام نشد.

نتیجه و گام بعد

نتیجه‌ی محدود و قابل دفاع این است که نویسنده‌ی علّی با تنظیمات قبلی، در حوزه‌های دانشگاهی و طراحی محصول اغلب نزدیک به شروع بازه‌های موضوعی برچسب‌خورده مرز می‌گذارد؛ مکان دقیق مرز و بازیابی شاهد بهتر نشد. برای مرحله‌ی بعد، اگر هدف کاربردی حافظه است، باید قید اندازه، طول قطعه و رتبه‌بندی را در طراحی مجزایی کنترل کرد؛ اگر هدف ادراک اپیزودیک است، به برچسب مستقل مرز رویداد با دستورالعمل شناختی و سنجه‌ی رفتار انسان نیاز است. این دو پرسش را نباید با همین جدول یکی کرد.

بازتولید

با python scripts/fetch_phase10_data.py --download نسخه‌ی دقیق ۳۵ فایل از منبع رسمی در مسیر نادیده‌گرفته‌شده‌ی data/raw/qmsum_test دریافت و با هش بررسی می‌شود. سپس python scripts/validate_phase10.py و برای python -m unittest discover -s tests -v، محاسبه‌ی دوباره python scripts/run_phase10_topic_transfer.py --output /tmp/phase10-recheck.json اجرا شوند. scripts/package_phase10.py خروجی اصلی را فشرده و چکیده را بازسازی می‌کند. نتیجه با CPU و بدون سرویس پولی ساخته شده است.

سپاسگزاری و خاستگاه آموزشی



از دکتر آرش فکری، بنیان‌گذار **FARDIAT**، مجتمع فوق تخصصی مغز و شناخت و استاد من در این حوزه، برای آموزش‌های مغز و شناخت و Cognitive Neuroscience و بررسی و تایید پروپوزال سپاسگزارم. ایده‌ی سنجش مرزبندی رویداد در حافظه‌ی گفت‌وگو از این آموزش‌ها الهام گرفت. از استاد نوری ولنده، استاد دانشگاهی من در درس پروژه، برای حمایت از ایده‌های نو و همراهی در مسیر اجرای پژوهش سپاسگزارم. نشان فردیت با فایل تصویری ارائه‌شده از سوی پژوهشگر در نسخه‌ی قابل چاپ آمده است.

منابع

[۱] Zhong et al. (2021), QMSum: A New Benchmark for Query-based Multi-domain Meeting Summarization, NAACL, 5905–5921. source

[۲] Zou et al. (2026), ES-Mem: Event Segmentation-Based Memory for Long-Term Dialogue Agents, preprint arXiv:2601.07582v2. source

[۳] Nguyen et al. (2026), Multiple event segmentation mechanisms in the human brain, eLife 15:RP107955. source

[۴] Yale-LILY, QMSum official repository, pinned revision and source license. source