گزارش پژوهشی مرحله‌ی یازدهم: وقتی مرز کافی نیست، آزمون مسیر حافظه تا شاهد

تاریخ: ۱۴ اکتبر ۲۰۲۶. وضعیت: آزمایش محاسباتی کامل، تحلیل اکتشافی و کنترل تکرارپذیری؛ این گزارش پیشرفت پروژه‌ی کارشناسی است و ادعای مقاله‌ی پذیرفته‌شده یا پایان‌نامه‌ی نهایی ندارد.

چکیده

در مرحله‌ی دهم، مرزهای نویسنده‌ی علّی تا فاصله‌ی دو نوبت به شروع موضوع‌های برچسب‌خورده نزدیک‌تر از کنترل تصادفی بودند، ولی بازیابی نوبت‌های مرتبط بهتر نشد. مرحله‌ی یازدهم این گسست را با یک تغییر کنترل‌شده بررسی کرد: به‌جای بازگرداندن کل قطعه، قطعه‌ها با BM25 رتبه‌بندی شدند، قطعه‌های نامزد تا سقف چهار برابر بودجه انتخاب شدند و سپس نوبت‌های درون آن‌ها با همان BM25 تا بودجه‌ی نهایی بازگردانده شدند. در ۳۵ جلسه‌ی QMSum و ۲۴۴ پرسش اختصاصی، معیار اصلی از پیش ثبت‌شده در بودجه‌ی ۱۰۲۴ واژه، پوشش نوبت‌های شاهد بود: روش دومرحله‌ای با مرزهای نویسنده ۱۶٫۷۸٪ و با میانه‌ی ۲۰ مرزبندی تصادفیِ هم‌شمار ۱۶٫۹۱٪؛ قطعه‌ی ثابت ۱۷٫۰۶٪ و جست‌وجوی مستقیم تمام نوبت‌ها ۱۶٫۹۶٪. در مسیر قبلیِ بازگرداندن کل قطعه، نویسنده ۳۴٫۶۹٪ داشت. بنابراین بازیابی دومرحله‌ای با این رتبه‌بند و این سنجه، مسئله را حل نکرد و مزیت مستقیمی برای مرزهای نویسنده نشان نداد. تحلیل پس از مشاهده‌ی نتیجه نشان داد احتمال بازگرداندن حداقل یک نوبت شاهد با همان نویسنده از ۸۷٫۸۱٪ به ۹۲٫۱۴٪ افزایش یافت؛ این سنجه با پوشش تمام بازه‌ی شاهد یکسان نیست. نتیجه توضیح می‌دهد چرا تعریف هدف بازیابی باید با ریزدانگی برچسب و کاربرد نهایی هماهنگ شود.

اهمیت، شکاف و نسبت با پژوهش‌های روز

ارزش عملی حافظه‌ی گفت‌وگو فقط به جای مرز وابسته نیست: نوشته‌ی ذخیره‌شده باید برای پرسش بعدی به شاهد قابل استفاده تبدیل شود. مرحله‌ی دهم نشان داد هم‌راستایی تقریبی با مرز موضوعی برای بهبود بازیابی کافی نیست. در پژوهش‌های معاصر، SeCom اهمیت ریزدانگی واحد حافظه و فشرده‌سازی را نشان می‌دهد [۱]؛ ES-Mem حافظه‌ی سلسله‌مراتبی مبتنی بر بخش‌بندی رویداد دارد [۲]؛ TiMem پیوستگی زمانی و سطوح حافظه را برجسته می‌کند [۳]؛ HiGMem از ساختار رویداد تا نوبت برای بازیابی استفاده می‌کند [۴]؛ HingeMem مرز و بازیابی سازگار با پرسش را پیوند می‌دهد [۵]؛ و CompassMem حافظه را در گرافی از رابطه‌های رویدادی سازمان می‌دهد [۶]. این‌ها پژوهش‌های پیشین نزدیک به ایده‌ی ما هستند. سهم این مرحله، اختراع روش دومرحله‌ای یا ادعای برتری بر آن‌ها نیست؛ سهم محدود آن ممیزی جفت‌شده‌ی مرز، ریزدانگی خروجی و سقف پردازش با یک نویسنده‌ی ثابت و کنترل شمار قطعه است.

پژوهش Memora نشان می‌دهد حافظه‌ی شخصی‌سازی‌شده باید به اطلاعات منسوخ و به‌روزرسانی نیز حساس باشد [۷]. QMSum اصولا مجموعه‌ای برای خلاصه‌سازی جلسه بر حسب پرسش است [۸] و مقاله‌ی Nguyen و همکاران بخش‌بندی تجربه را با رفتار و fMRI بررسی کرده است [۹]. نه در این پروژه به‌روزرسانی دانسته‌ها آزموده شد و نه برچسب موضوع QMSum برابر با مرز ادراک‌شده‌ی انسان یا نشانگر نورونی فرض شد. واژه‌ی «اپیزود» در اینجا الهام طراحی است، نه شاهدی بر فهم معنای فلسفی به تعبیر سرل.

طراحی و قرارداد ثبت‌شده

طرح عددی configs/phase11_plan.json و توضیح آن در docs/phase11_plan.md پیش از محاسبه‌ی امتیازهای مرحله‌ی یازدهم در شاخه‌ی گیت ثبت شد. البته نتیجه‌های مرحله‌ی دهم روی همین ۳۵ جلسه قبلا دیده شده بودند؛ از این رو ثبت

طرح، داده‌ی بازاستفاده‌شده را به مجموعه‌ی آزمون مستقل تبدیل نمی‌کند. ۳۵ فایل خام نسخه‌ی ۸۳d7768c1f2b4dfeb091385d3dc7e239b8e5bb7e با اندازه و هش Git ثبت‌شده تطبیق یافتند: ۲۰۷۱۸ نوبت، ۱۷۹ بازه‌ی موضوعی و ۲۴۴ پرسش اختصاصی با ۲۸۶ بازه‌ی مرتبط. برچسب‌های relevant_text_span با انتهای فراگیر به اجتماع نوبت‌های شاهد تبدیل شدند. میانگین اندازه‌ی این اجتماع در ۲۴۴ پرسش ۵۴٫۶ نوبت و میانه‌ی آن ۲۷ نوبت بود؛ ۴۰ پرسش بیش از ۱۰۰ نوبت شاهد داشتند.

نویسنده‌ی علّی مرحله‌ی هشتم، قطعه‌ی ثابت ۱۲۸ واژه و ۲۰ کنترل تصادفی با شمار قطعه‌ی دقیقا برابر در هر جلسه بدون تنظیم دوباره استفاده شدند. برای هر قطعه‌بندی سه مسیر وجود داشت: مسیر تخت با BM25 قطعه و بازگرداندن قطعه‌ی کامل؛ مسیر دومرحله‌ای با BM25 قطعه، نامزدگیری قطعه‌ی کامل تا سقف ۴ × بودجه و BM25 روی نوبت‌های نامزد برای بازگرداندن نوبت کامل تا سقف نهایی؛ و کنترل نوبت سراسری با BM25 روی تمام نوبت‌های جلسه. کنترل آخر دامنه‌ی پردازش بزرگ‌تری دارد و رقیب هم‌هزینه‌ی روش دوم نیست. بودجه‌های خروجی ۵۱۲، ۱۰۲۴ و ۲۰۴۸ واژه بودند. متن خام، موضوع برچسب‌خورده، پاسخ و نوبت‌های شاهد به نویسنده یا رتبه‌بند داده نشدند.

معیار اصلی: کسر نوبت‌های شاهدی که در متن خروجی حاضرند؛ ابتدا میانگین پرسش‌ها در هر جلسه و سپس میانگین مساوی ۳۵ جلسه. در بودجه‌ی ۱۰۲۴ واژه، تفاوت روش دومرحله‌ای نویسنده با میانه‌ی ۲۰ کنترل هم‌شمار ثبت شد. اختلاف بهبود مسیر دومرحله‌ای نسبت به تخت، پوشش نامزد، حوزه، بودجه‌های دیگر و فاصله‌ی بوت‌استرپِ توصیفی معیارهای فرعی هستند. ۲۰ بذر به معنای ۲۰ مجموعه‌ی داده‌ی مستقل یا مقدار p نیست. هیچ پاسخ تولیدی ارزیابی نشده است.

نتیجه‌ی معیار اصلی و مقایسه‌های از پیش تعریف‌شده

بودجه‌ی خروجی	نویسنده، کل قطعه	نویسنده، دومرحله‌ای	میانه‌ی کنترل، دومرحله‌ای	قطعه‌ی ثابت، دومرحله‌ای	نوبت سراسری
۵۱۲ واژه	۲۴٫۸۶٪	۱۱٫۳۹٪	۱۱٫۲۸٪	۱۱٫۵۲٪	۱۱٫۳۲٪
۱۰۲۴ واژه؛ معیار اصلی	۳۴٫۶۹٪	۱۶٫۷۸٪	۱۶٫۹۱٪	۱۷٫۰۶٪	۱۶٫۹۶٪
۲۰۴۸ واژه	۴۸٫۱۷٪	۲۵٫۲۳٪	۲۵٫۲۲٪	۲۵٫۳۳٪	۲۵٫۳۶٪

در بودجه‌ی اصلی، تفاوت دومرحله‌ای نویسنده با میانه‌ی کنترل منفی ۰٫۱۴ واحد درصد است؛ ۱۶ کنترل از ۲۰ کنترل برابر یا بهتر بودند. فاصله‌ی صدکی بوت‌استرپ جفت‌شده‌ی ۳۵ جلسه برای این اختلاف، حدود منفی ۰٫۳۹ تا مثبت ۰٫۱۵ واحد درصد بود؛ این فاصله توصیفی است و به دلیل مشاهده‌ی قبلی داده آزمون تاییدی نیست. در ۱۳ جلسه نویسنده از میانه‌ی کنترل همان جلسه بهتر، در ۹ جلسه برابر و در ۱۳ جلسه بدتر بود. تفکیک حوزه در بودجه‌ی اصلی برای نویسنده در برابر میانه‌ی کنترل هر جلسه: دانشگاهی ۸٫۰۹٪ در برابر ۸٫۲۶٪، طراحی محصول ۱۵٫۷۵٪ در برابر ۱۵٫۶۰٪، و کمیته ۳۳٫۲۱٪ در برابر ۳۳٫۹۹٪. میانگین‌های حوزه‌ای با قواعد سطح جلسه هستند و با میانه‌ی کنترل ۳۵ جلسه یکی نیستند.

تغییر مسیر نسبت به قطعه‌ی کامل در نویسنده منفی ۱۷٫۹۱ واحد درصد بود. کنترل تصادفی نیز افت داشت؛ اختلاف تغییرات نویسنده با میانه‌ی تغییرات کنترل حدود مثبت ۱٫۹۰ واحد درصد شد. این برهم‌کنش توصیفی به معنای موفقیت روش نیست، زیرا نتیجه‌ی مستقیم دومرحله‌ایِ نویسنده همچنان اندکی زیر کنترل و قطعه‌ی ثابت ماند. سقف نامزد چهار برابر و بودجه‌ی خروجی یکسان است، اما هزینه‌ی محاسباتی BM25 در دو سطح و جست‌وجوی نوبت سراسری در این جدول به صورت قیمت یا زمان برابر نشده است.

چرا پوشش شاهد افت کرد؟ تحلیل محدود، با تفکیک قبل و بعد از نتیجه

در بودجه‌ی ۱۰۲۴ واژه، نامزدهای نویسنده پیش از گزینش نهایی به‌طور میانگین ۶۸٫۹۴٪ از نوبت‌های شاهد را در بر داشتند، اما خروجی نهایی ۱۶٫۷۸٪ را بازگرداند. در نمونه‌ی پرسش‌ها، میانگین سقف نامزد مصرف‌شده حدود ۳۹۳۷ واژه از ۴۰۹۶ و متن نهایی حدود ۱۰۲۴ واژه بود؛ فقط در ۶ پرسش از ۲۴۴ پرسش هیچ نوبت شاهدی وارد نامزد نویسنده نشد. بنابراین بخش بزرگی از افت پس از مرحله‌ی نامزدگیری و هنگام رتبه‌بندی و محدودسازی نوبت‌های خروجی رخ می‌دهد. این مشاهده به‌تنهایی اثر مستقل BM25، طول نوبت و سقف بودجه را از هم جدا نمی‌کند.

تشخیص پس از مشاهده‌ی معیار اصلی، خارج از طرح پیشین: در ۱۰۲۴ واژه، اگر هدف فقط رسیدن به حداقل یک نوبت شاهد باشد، میانگین جلسه‌ایِ نویسنده از ۸۷٫۸۱٪ با قطعه‌ی کامل به ۹۲٫۱۴٪ با روش دومرحله‌ای می‌رسد. برای میانه‌ی کنترل‌ها این اعداد ۸۸٫۵۵٪ و ۹۱٫۹۱٪ و برای قطعه‌ی ثابت ۸۷٫۵۸٪ و ۹۲٫۶۲٪ بودند. این معیار تشخیصی نشان می‌دهد بازگرداندن یک شاهد و پوشش سهم بزرگی از یک بازه‌ی طولانی می‌توانند نتیجه‌ی مخالف بدهند؛ انتخاب آن پس از دیدن نتیجه نباید به‌عنوان موفقیت از پیش پیش‌بینی‌شده بازنویسی شود. نسبت نوبت‌های برچسب‌خورده در نوبت‌های بازگردانده‌شده نیز برای نویسنده در مسیر تخت ۱۸٫۴۲٪ و دومرحله‌ای ۱۵٫۹۴٪ بود؛ چون نوبت‌های خارج از بازه لزوما نامرتبط نیستند، این نسبت را «دقت بازیابی» یا قضاوت معنایی نمی‌نامیم.

صحت، محدودیت و ارزش پژوهشی

اعتبارسنجی روی خروجی عددیِ فشرده، هش طرح و منبع، ۳۵ جلسه و ۱۶۸۳۶ ردیف انجام شد. از آن میان ۱۶۱۰۴ ردیف مسیر تخت به‌صورت تک‌پرسش، تک‌بذر و تک‌بودجه با مرحله‌ی دهم تطبیق کامل دارند؛ ۷۳۲ ردیف برای کنترل نوبت سراسری است. سقف نامزد و خروجی، یکپارچگی نوبت‌ها، نبود دسترسی الگوریتم به برچسب، و بازحساب میانگین‌ها بررسی شدند. ۳۰ آزمون برنامه‌نویسی گذشت. خروجی مخزن فقط عدد و شناسه دارد، نه متن خام QMSum.

محدودیت‌های اصلی: این ۳۵ جلسه قبلا بررسی شده‌اند؛ شاهد QMSum بازه‌ی موضوعی و مرتبط با خلاصه‌سازی است، نه پاسخ دقیق در حد یک نوبت یا مرز ادراک انسانی؛ برگرداندن کل قطعه ممکن است به‌طور اتفاقی نوبت‌های بسیار زیادی از بازه‌ی طلایی را پوشش دهد؛ نوبت‌محور کردن خروجی همان واژه‌ها را به نوبت‌های پراکنده تخصیص می‌دهد. پس افت کسر پوشش به معنی نامناسب بودن تمام بازیابی‌های سلسله‌مراتبی در کاربرد واقعی نیست. برعکس، بهبود «حداقل یک شاهد» نیز کیفیت پاسخ نهایی را ثابت نمی‌کند. مطالعه فقط BM25 واژگانی، یک سقف نامزد ثابت، سه بودجه و یک مجموعه‌ی جلسه را آزموده است. پژوهش‌های ادراک رویداد مغز از طرح‌های رفتاری و عصبی دیگری استفاده می‌کنند [۹].

ارزش مرحله برای پروژه‌ی کارشناسی: مسیر ذخیره‌سازی و مسیر بازیابی را به‌صورت قابل ممیزی از هم جدا کردیم، یک پیش‌بینی جذاب ولی نادرست برای معیار اصلی را ثبت و ابطال محدود کردیم، و نشان دادیم انتخاب سنجه چگونه تفسیر «حافظه‌ی بهتر» را تغییر می‌دهد. این صداقت روش‌شناختی نقطه‌ی شروع طراحی مرحله‌ی بعد است: تعریف شاهد ریزدانه‌تر یا سنجش پاسخ مستند به شاهد، با قرارداد مستقل و بدون تغییر پنهانی معیار.

بازتولید

ابتدا python scripts/fetch_phase10_data.py --download را برای دریافت ۳۵ فایل هش‌دار منبع اجرا کنید. سپس python -m unittest discover -s tests -v و python scripts/run_phase11_hierarchical.py --output results/phase11_retrieval.json، بعد python scripts/package_phase11.py و python scripts/validate_phase11.py را اجرا کنید. python scripts/phase11_diagnostics.py تشخیص‌هایی را که بعد از دیدن نتیجه افزوده شدند جداگانه بازسازی می‌کند. مسیرهای خام منبع و JSON حجیم در .gitignore هستند. این مرحله روی CPU و بدون سرویس پولی اجرا شده است.

سپاسگزاری و خاستگاه آموزشی

از دکتر آرش فکری، بنیان‌گذار **FARDIAT**، مجتمع فوق تخصصی مغز و شناخت و استاد من در Cognitive Neuroscience، برای آموزش‌های الهام‌بخش و بررسی و تایید پروپوزال پژوهش سپاسگزارم. از استاد نوری، استاد دانشگاهی من در درس پروژه، برای حمایت از ایده‌های نو و همراهی با اجرای دقیق پژوهش سپاسگزارم. نشان فردیت با تصویر ارائه‌شده از سوی پژوهشگر در نسخه‌ی چاپی آمده است.

منابع

[۱] Pan et al. (2025), On Memory Construction and Retrieval for Personalized Conversational Agents. source

[۲] Zou et al. (2026), ES-Mem: Event Segmentation-Based Memory for Long-Term Dialogue Agents. source

[۳] Li et al. (2026), TiMem: Temporal-Hierarchical Memory Consolidation for Long-Horizon Conversational Agents. source

[۴] Cao et al. (2026), HiGMem: A Hierarchical and LLM-Guided Memory System for Long-Term Conversational Agents. source

[۵] Zhong et al. (2026), HingeMem: Boundary Guided Long-Term Memory with Query Adaptive Retrieval for Scalable Dialogues, preprint. source

[۶] Hu et al. (2026), Memory Matters More: Event-Centric Memory as a Logic Map for Agent Searching and Reasoning. source

[۷] Uddin et al. (2026), From Recall to Forgetting: Benchmarking Long-Term Memory for Personalized Agents. source

[۸] Zhong et al. (2021), QMSum: A New Benchmark for Query-based Multi-domain Meeting Summarization. source

[۹] Nguyen et al. (2026), Multiple event segmentation mechanisms in the human brain, eLife 14:RP107955. source