گزارش پژوهشی مرحله‌ی دوازدهم: حافظه در برابر اصلاح اطلاعات

پژوهش کارشناسی | ۱۷ اکتبر ۲۰۲۶ | نتیجه‌ی اکتشافی ثبت‌شده

چکیده

در مرحله‌ی یازدهم، جدا کردن مسیر ذخیره و بازیابی نشان داد که کیفیت مرز به‌تنهایی کیفیت دسترسی به شاهد را تعیین نمی‌کند. این مرحله مسئله‌ی تازه‌تری را آزمود: وقتی اطلاعات قدیمی در گفت‌وگو به‌روز می‌شود، آیا ترتیب زمانی به بازیابی شاهد جدید کمک می‌کند؟ قرارداد آزمون پیش از امتیازدهی در تاریخچه‌ی گیت ثبت شد. روی ۷۲ پرسش پاسخ‌پذیرِ knowledge-update از LongMemEval-S، سه مسیر BM25 نوبت‌محور، مرتب‌سازی زمانیِ ۲۰ نامزد واژگانیِ برتر، و ۲۰ ترتیب تصادفی همان نامزدها با بودجه‌ی برابر مقایسه شدند. معیار اصلی دستیابی به نوبتِ علامت‌خورده از جلسه‌ی تازه‌تر در ۱۰۲۴ واژه بود. BM25 به ۶۶ از ۷۲ پرسش، روش زمانی به ۵۱ از ۷۲ و میانه‌ی کنترل‌های تصادفی به ۳۵٫۵ از ۷۲ رسید. بنابراین تازگی نسبت به تصادفی‌سازی نشانه‌ی مفیدی بود، ولی جایگزین کردن رتبه‌ی واژگانی با ترتیب زمانی به معیار اصلی آسیب زد. این پژوهش پاسخ تولید نکرده و صحت آن را ارزیابی نکرده است.

ضرورت و جایگاه پژوهش

حافظه‌ی عامل در استفاده‌ی بلندمدت با داده‌های تازه‌ای روبه‌رو می‌شود که ممکن است دانسته‌های قدیمی را تغییر دهند. LongMemEval، پژوهش ICLR ۲۰۲۵، به‌روزرسانی دانش را صریحا یکی از محورهای ارزیابی معرفی کرده [۱]. Memora در Findings of ACL ۲۰۲۶ مشکل استفاده از خاطره‌ی نامعتبر و نیاز به سنجه‌ی حساس به فراموشی را برجسته می‌کند [۲]. مسئله‌ی عملی این پژوهش «کدام شاهد به خواننده‌ی عامل می‌رسد» است؛ اگر شاهد تازه در متن بازیابی‌شده نباشد، پاسخ مستند به آن دشوار می‌شود، ولی وجود شاهد نیز به‌تنهایی پاسخ درست را تضمین نمی‌کند.

در سوی شناختی، Panela و همکاران در مجله‌ی Communications Psychology با مشارکت پژوهشگران دانشگاه تورنتو، مرزبندی رویداد در روایت‌ها را با قضاوت انسانی سنجیده‌اند [۳]. Nguyen و همکاران در eLife از دانشگاه واشنگتن در سنت‌لوئیس، سیگنال‌های خطای پیش‌بینی و عدم قطعیت را در مرزبندی رویداد مغز انسان بررسی کرده‌اند [۴]. این منابع الهام طراحی می‌دهند، اما مطالعه‌ی حاضر هیچ آزمون انسانی، تصویربرداری مغزی یا معیار معتبرِ «معنا» به مفهوم فلسفی آن ندارد. در خبر پژوهشی تازه، مخزن رسمی LongMemEval از انتشار V2 در مه ۲۰۲۶ خبر داده است؛ V2 برای حافظه در زمینه‌ی عامل طراحی شده و اعداد این مرحله مربوط به آن نیستند [۵].

مقاله‌های [۳] و [۴] ژورنالی و [۱] و [۲] کنفرانسی هستند. رتبه‌ی Q1/Q2 به سال و شاخه‌ی پایگاه نمایه‌سازی وابسته است؛ در این گزارش رتبه‌ی تاییدنشده به هیچ منبعی نسبت نداده‌ایم. سهم محدود این مرحله یک مقایسه‌ی کم‌هزینه، جفت‌شده و شفاف است که نشان می‌دهد افزودن زمان چه وقت می‌تواند با ارتباط واژگانی تعارض پیدا کند.

پرسش، داده و روش

پرسش: آیا تقدم دادن به تازه‌ترین نوبت در میان ۲۰ نامزد برتر BM25، احتمال دستیابی به شاهد جدید را در بودجه‌ی خروجی ثابت بیشتر می‌کند؟ قرارداد و معیار اصلی پیش از محاسبه‌ی نتیجه در docs/phase12_plan.md و configs/phase12_plan.json ثبت شدند. نتیجه‌های مرحله‌ی هفتم روی همین مجموعه و ممیزی ساختار آن از قبل دیده شده‌اند؛ ثبت پیشینی این مرحله آن را به مطالعه‌ی تاییدی مستقل تبدیل نمی‌کند.

نسخه‌ی پاک‌سازی‌شده‌ی رسمی LongMemEval-S با هش SHA-256 برابر d6f21ea9d60a0d56f34a05b609c79c88a451d2ae03597821ea3d5a9678c3a442 استفاده شد. ۷۸ رکوردِ نوع به‌روزرسانی شناسایی شد؛ ۶ پرسش _abs که انتظار خودداری از پاسخ دارند مطابق طرح کنار رفتند. در ۷۲ مورد باقی‌مانده دو جلسه‌ی رسمی پاسخ وجود دارد. جلسه‌ی دوم در ترتیب آرایه «تازه‌تر» تعریف شد؛ در یک رکورد رشته‌ی تاریخ با این ترتیب سازگار نبود. دو رکورد شناسه‌ی جلسه‌ی تکراری دارند؛ در دو مورد نیز نوبتِ قدیمی علامت شاهد ندارد، ولی همه‌ی ۷۲ مورد در جلسه‌ی متاخر نوبتِ شاهدِ علامت‌خورده دارند. این موارد حذف پنهانی نشده‌اند.

نوبت‌های کامل با توکن‌ساز ثابت پروژه و BM25 رتبه‌بندی شدند. روش زمانی تنها ۲۰ رتبه‌ی اول را بر پایه‌ی موقعیت جلسه و نوبت از جدید به قدیم مرتب کرد و باقی فهرست را ثابت گذاشت. کنترل‌ها همین ۲۰ نامزد را با بذرهای ۰ تا ۱۹ جابه‌جا کردند. هر سه روش فقط متن، پرسش و ترتیب عرضه‌شده به عامل را دیدند؛ پاسخ و برچسب‌ها پس از انتخاب برای امتیازدهی خوانده شدند. هزینه با شمار واژه‌ی نوبت‌های کامل در بودجه‌های ۵۱۲، ۱۰۲۴ و ۲۰۴۸ محدود شد. معیار اصلی وجود حداقل یک نوبتِ علامت‌خورده از جلسه‌ی جدید در خروجی ۱۰۲۴ واژه بود.

نتیجه‌های ثبت‌شده

بودجه‌ی واژه	**BM25**: شاهد تازه	زمان در ۲۰ نامزد: شاهد تازه	میانه‌ی ۲۰ ترتیب تصادفی	اختلاف زمان با **BM25**
۵۱۲	۶۲ از ۷۲	۳۴ از ۷۲	۲۶ از ۷۲	منفی ۲۸ پرسش
۱۰۲۴، معیار اصلی	۶۶ از ۷۲، ۹۱٫۶۷٪	۵۱ از ۷۲، ۷۰٫۸۳٪	۳۵٫۵ از ۷۲، ۴۹٫۳۱٪	منفی ۱۵ پرسش، ۲۰٫۸۳ واحد درصد
۲۰۴۸	۶۸ از ۷۲	۶۷ از ۷۲	۵۳ از ۷۲	منفی ۱ پرسش

در معیار اصلی، دو پرسش فقط با مسیر زمانی و ۱۷ پرسش فقط با **BM25** شاهد تازه را برگرداندند. فاصله‌ی صدکی ۹۵٪ بوت‌استرپ جفت‌شده‌ی توصیفی برای اختلاف کسر موفقیتِ زمان منهای BM25 حدود منفی ۳۱٫۹۴ تا منفی ۹٫۷۲ واحد درصد است. به دلیل ساختِ تاریخچه‌های معیار و مشاهده‌ی قبلی این داده، آن را آزمون معنی‌داری تعمیم‌پذیر تعبیر نمی‌کنیم. میانگین بودجه‌ی استفاده‌شده در دو روش تقریبا یکسان و نزدیک ۱۰۲۴ واژه بود.

بازگرداندن فقط شاهد قدیمی در ۱۰۲۴ واژه برای BM25 در ۳ پرسش و روش زمانی در ۲ پرسش رخ داد. اما دسترسی هم‌زمان به هر دو شاهد از ۶۱ پرسش با BM25 به ۱۵ با زمان افت کرد؛ پس کم شدن بازیابی قدیمی به‌تنهایی بهبود فراموشی یا حل تعارض نیست. دو پرسش با نبود برچسب نوبت قدیمی در تفسیر این سنجه محدودیت دارند. میانه‌ی کنترل تصادفی در جدول ممکن است نیم‌عدد باشد، چون میانه‌ی ۲۰ شمار صحیح است؛ به معنای وجود نیم پرسش نیست.

تشخیص پس از مشاهده‌ی نتیجه و تبیین محتاطانه

این بخش بعد از دیدن معیار اصلی محاسبه شد و در فرض پیشینی وارد نیست. نوبتِ شاهد تازه در ۶۹ از ۷۲ پرسش در میان ۲۰ رتبه‌ی نخست BM25 قرار داشت؛ میانه‌ی بهترین رتبه‌ی آن ۲ بود و در ۲۵ پرسش رتبه‌ی اول داشت. در ۶۵ از ۷۲ تاریخچه، جلسه‌های مزاحمِ بعد از جلسه‌ی شاهد جدید وجود داشتند؛ میانه‌ی شمار آنها ۷ بود. به‌عنوان تبیین محتمل، مقدم داشتن زمان در میان نامزدهای مرتبط اغلب فرصت شاهدی را که BM25 نزدیک صدر گذاشته بود به نوبت‌های دیرتر می‌دهد. این شمارش سازوکار علّی همه‌ی افت‌ها را اثبات نمی‌کند و به‌عنوان موفقیت جایگزین ثبت نشده است.

ارزش، محدودیت و مسیر دقیق بعدی

ارزش این نتیجه در محدود کردن یک ادعای رایج است: «جدیدتر» به‌خودی‌خود معیار کافی برای «مرتبط‌تر و درست‌تر» نیست. برای ساخت حافظه‌ی رویدادی، ترتیب زمانی باید در کنار ارتباط با پرسش، ردگیری منشأ شاهد و تشخیص تعارض استفاده شود. فرض آزمون بعدی می‌تواند این باشد که زمان تنها میان شواهدی که درباره‌ی یک واقعیتِ واحد تعارض دارند اثر بگذارد؛ این فرض به برچسب مستقلِ واقعیتِ منسوخ و ارزیابی پاسخ مستند نیاز دارد و از داده‌ی فعلی قابل نتیجه‌گیری نیست. بنابراین آن را به‌عنوان نتیجه‌ی مرحله‌ی دوازدهم نمی‌فروشیم.

این آزمون، با یک رایانه و بدون هزینه‌ی API، بازیابی شاهد را اندازه گرفته است؛ نه پاسخ‌گویی عامل، تشخیص تناقض، درست بودن «جدیدترین» پاسخ در تمام زمینه‌ها، ادراک اپیزودیک انسان، یا کارایی LongMemEval-V2. ۷۲ پرسش می‌توانند از تاریخچه‌های تولیدی و مواد تکراری بهره ببرند. دو موردِ شناسه‌ی تکراری، یک ناسازگاری تاریخ و دو نبود برچسب شاهد قدیمی ثبت شده‌اند. آزمون در مجموعه‌ی دیده‌شده انجام شده و تنظیم پس از نتیجه جای ادعای تاییدی را نمی‌گیرد.

بازتولید و ممیزی

ابتدا داده‌ی نسخه‌بندی‌شده را مطابق scripts/fetch_phase7_data.py تهیه کنید. اجرای python scripts/run_phase12_temporal.py --source data/raw/longmemeval_s_cleaned.json، سپس python scripts/package_phase12.py و python scripts/validate_phase12.py خروجی ۴۷۵۲ ردیفی و خلاصه را بازسازی می‌کند. دستور python scripts/phase12_posthoc.py --source data/raw/longmemeval_s_cleaned.json تشخیص پس از نتیجه را جدا تولید می‌کند. مجموعه‌ی داده‌ی خام و متن پرسش‌ها در مخزن کپی نشده‌اند. گزارش Word/PDF راست‌چین با قلم B Nazanin تهیه شده و قلم دارای مجوز در مخزن منتشر نشده است.

سپاسگزاری و خاستگاه آموزشی

از دکتر آرش فکری، بنیان‌گذار **FARDIAT**، مجتمع فوق تخصصی مغز و شناخت و استاد من در علوم اعصاب شناختی، برای آموزش‌ها و بررسی و تایید پروپوزال سپاسگزارم. از استاد نوری ولنده، استاد دانشگاهی درس پروژه، برای حمایت از ایده‌های نو و همراهی در اجرای دقیق پژوهش سپاسگزارم. نشان فردیت در نسخه‌ی چاپی با تصویر ارائه‌شده از سوی پژوهشگر آمده است.

منابع

[۱] Wu et al. (2025), LongMemEval: Benchmarking Chat Assistants on Long-Term Interactive Memory, ICLR. source

[۲] Uddin et al. (2026), From Recall to Forgetting: Benchmarking Long-Term Memory for Personalized Agents, Findings of ACL. source

[۳] Panela et al. (2025), Event segmentation applications in large language model enabled automated recall assessments, Communications Psychology. source

[۴] Nguyen et al. (2026), Multiple event segmentation mechanisms in the human brain, eLife. source

[۵] Wu et al., LongMemEval-V2 official repository (2026). source