بازیابی شاهد پیش و پس از اصلاح اطلاعات

گزارش پژوهش کارشناسی مرحله‌ی سیزدهم | ۱۷ اکتبر ۲۰۲۶ | آزمون اکتشافی

چکیده

مرحله‌ی دوازدهم نشان داد مقدم کردن تازگی بر ارتباط واژگانی می‌تواند شاهد تازه را از بودجه بیرون براند. در این مرحله یک پرسش محدودتر آزموده شد: اگر بعد از بهترین نوبت BM25، بهترین نوبت از جلسه‌ای دیگر را جلو بیاوریم، آیا شاهدهای قبل و بعد از اصلاح اطلاعات با هم بیشتر بازیابی می‌شوند؟ قرارداد پیش از امتیازدهی در گیت ثبت شد. در ۷۰ پرسش واجد دو شاهدِ علامت‌خورده از LongMemEval-S و بودجه‌ی ۵۱۲ واژه، BM25 در ۵۴ و تنوع جلسه در ۵۵ پرسش هر دو شاهد را بازگرداند. روش «تازه‌ترین جلسه‌ی دیگر» فقط در ۴۸ پرسش موفق شد. افزایش یک پرسش برای ادعای برتری پایدار کافی نیست؛ مسیر منتخب همچنین دستیابی به شاهد تازه را از ۶۲ به ۶۱ مورد در کل ۷۲ پرسش پاسخ‌پذیر کاهش داد. هدف، ممیزی دسترسی به شاهد بوده است، نه پاسخ نهایی عامل یا تشخیص تعارض معنایی.

ضرورت، شکاف و انتخاب ایده

عاملِ دارای حافظه‌ی بلندمدت باید تغییر یک واقعیت را در بافت زمانی آن دنبال کند. LongMemEval در ICLR ۲۰۲۵ به‌روزرسانی دانش را به‌عنوان توانایی مستقل می‌سنجد [۴]؛ Memora در Findings of ACL ۲۰۲۶ استفاده از اطلاعات منسوخ را مسئله‌ای باز گزارش می‌کند [۳]. دو نمونه‌ی معماریِ روز، APEX-MEM در ACL ۲۰۲۶ با گراف رخداد و نگهداری تاریخچه‌ی تغییر [۱] و AMA با بازبینی ناسازگاری در فرایند بازیابی [۲] هستند. گزارش دقت پاسخ آن سامانه‌ها قابل قیاس عددی با پوشش شاهد در این مرحله نیست. مطالعه‌ی Panela و همکاران در مجله‌ی Communications Psychology نشان می‌دهد سنجش مرزبندی رویداد انسانی به اعتبارسنجی رفتاری جداگانه نیاز دارد [۵]. کتاب آموزشی Computational Cognitive Neuroscience از منابع ارائه‌شده‌ی پژوهشگر، حافظه‌ی اپیزودیک را در بستر شناختی توضیح می‌دهد [۶]؛ این کتاب شاهد تجربی برای نتیجه‌ی الگوریتم ما نیست.

از میان سه مسیر، گراف کاملِ تعارض به مدل و برچسب مستقلِ واقعیت نیاز داشت؛ مقدم کردن کلیِ زمان نیز در مرحله‌ی پیش افت کرده بود. بنابراین یک جزء کم‌هزینه انتخاب شد: تنوع جلسه در جایگاه دوم فهرست بازیابی. نوآوری ادعاشده در اینجا اختراع حافظه‌ی گرافی یا عاملِ حل تعارض نیست؛ جداسازی اثر یک تصمیم ساده‌ی رتبه‌بندی در بودجه‌ی برابر است. منابع [۱] تا [۴] مقالات کنفرانسی و [۵] مقاله‌ی ژورنالی‌اند. برچسب Q1/Q2 را بدون تایید پایگاه، دسته و سال برای این مقالات به کار نبرده‌ایم.

روش و قرارداد پیش از نتیجه

طرح در docs/phase13_plan.md و configs/phase13_plan.json قبل از اجرا ثبت شد. داده‌ی رسمی LongMemEval-S با SHA-256 برابر d6f21ea9d60a0d56f34a05b609c79c88a451d2ae03597821ea3d5a9678c3a442 به کار رفت. از ۷۸ مورد knowledge-update، ۶ مورد _abs که برای خودداری از پاسخ‌اند کنار رفتند. از ۷۲ پرسش پاسخ‌پذیر، ۷۰ مورد در هر دو جلسه‌ی رسمی پاسخ نوبتِ علامت‌خورده دارند؛ دو موردِ فاقد علامت قدیمی از معیار اصلی کنار گذاشته شدند، اما در سنجه‌ی شاهد تازه‌ی ۷۲تایی حضور دارند. این مجموعه و نتیجه‌های مراحل پیشین از قبل دیده شده‌اند؛ مطالعه تاییدی مستقل نیست.

BM25 با همان توکن‌ساز و بازگرداندن نوبتِ کاملِ مرحله‌ی دوازدهم همه‌ی نوبت‌ها را رتبه‌بندی کرد. مسیرهای دیگر فقط یک نوبت را به جایگاه دوم آوردند: بالاترین نوبت از جلسه‌ای متفاوت در ۲۰ رتبه‌ی نخست، تازه‌ترین نوبت از جلسه‌ای متفاوت در همان ۲۰ رتبه، یا یک نوبتِ تصادفی از همان مجموعه با ۲۰ بذر. بعد از دو رتبه‌ی اول، ترتیب BM25 حفظ شد؛ مجموعه‌ی نامزدها، هزینه‌ی واژه و متن پرسش برابر بودند. نوع پرسش، پاسخ و برچسب شاهد به رتبه‌بند داده نشد. معیار اصلی سهم پرسش‌های واجد

شرط بود که در ۵۱۲ واژه هر دو شاهد قدیم و جدید را دریافت کنند. شاهد تازه در همه‌ی ۷۲ مورد و «فقط قدیمی» در ۷۰ مورد معیارهای نگهبان بودند. بودجه‌های ۲۵۶ و ۱۰۲۴ واژه فرعی‌اند.

نتیجه‌های عددی

بودجه‌ی واژه	**BM25**، هر دو شاهد	بهترین جلسه‌ی دیگر	تازه‌ترین جلسه‌ی دیگر	میانه‌ی کنترل تصادفی	اختلاف بهترین با **BM25**
۲۵۶	۴۹ از ۷۰	۵۲ از ۷۰	۴۴ از ۷۰	۴۶٫۵ از ۷۰	مثبت ۳ پرسش
۵۱۲، معیار اصلی	۵۴ از ۷۰، ٪۷۷٫۱۴	۵۵ از ۷۰، ٪۷۸٫۵۷	۴۸ از ۷۰، ٪۶۸٫۵۷	۴۸٫۵ از ۷۰	مثبت ۱ پرسش، ۱٫۴۳ واحد درصد
۱۰۲۴	۶۱ از ۷۰	۶۱ از ۷۰	۵۹ از ۷۰	۶۰٫۵ از ۷۰	صفر

در ۵۱۲ واژه تنها یک پرسش با «بهترین جلسه‌ی دیگر» موفق و با BM25 ناموفق بود؛ موردی در جهت عکس وجود نداشت. فاصله‌ی صدکی ٪۹۵ بوت‌استرپ جفت‌شده‌ی توصیفی برای اختلاف سهم موفقیت صفر تا ۴٫۲۹ واحد درصد است؛ این اعداد به دلیل انتخاب مسئله بر پایه‌ی نتیجه‌ی قبلی، تاریخچه‌های ساخته‌شده و حجم کوچک، اثبات تعمیم‌پذیری نیستند. نصف‌بودن میانه‌ی کنترل تصادفی ناشی از میانه‌گیری روی ۲۰ شمار صحیح است.

نگهبانِ شاهد تازه در همه‌ی ۷۲ پرسش در بودجه‌ی ۵۱۲ برای BM25 برابر ۶۲، بهترین جلسه‌ی دیگر ۶۱ و تازه‌ترین جلسه‌ی دیگر ۵۶ بود. «فقط شاهد قدیمی» در ۷۰ مورد واجد شرط به‌ترتیب ۴، ۴ و ۱۰ رخ داد. بنابراین حتی افزایش یک مورد در معیار اصلی، همراه یک مورد افتِ شاهد تازه است و بهبود عملی مطمئن به حساب نمی‌آید. میانگین واژه‌ی خروجی همه‌ی روش‌ها نزدیک ۵۱۲ بود. بهترین جلسه‌ی دیگر تنها در ۲۸ از ۷۲ پرسش فهرست BM25 را واقعا تغییر داد؛ گزینه‌ی جلسه‌ی متفاوت در هر ۷۲ پرسش وجود داشت. انتخاب تازه‌ترین جلسه‌ی دیگر در ۷۱ فهرست تغییر ایجاد کرد و آشکارا بدتر شد.

ممیزی و تفسیر

نتیجه‌ی BM25 در ۱۴۴ ردیف مشترکِ پرسش و بودجه‌ی ۵۱۲/۱۰۲۴، در سطح تک‌پرسش با مرحله‌ی دوازدهم تطبیق کامل داشت. فایل نتیجه‌ی فشرده ۴۹۶۸ ردیف عددی، شناسه و هش منبع دارد و هیچ متن مکالمه یا کتاب بارگذاری‌شده را بازنشر نمی‌کند. سنجه‌های اصلی از فایل خروجی دوباره محاسبه شدند و ۳۵ آزمون کد گذشت. طرحِ پیش از نتیجه و گزارش نتیجه دو تعهد جداگانه در گیت دارند.

ارزش این مرحله روشن شدن اندازه‌ی واقعی یک ایده‌ی جذاب است: تنوع جلسه در رتبه‌ی دوم در این آزمون تنها یک پرسش اضافه کرد، در حالی که گزینش براساس تازگی بیشتر آسیب زد. حفظ دو منبع شاهد، بدون این‌که بدانیم واقعا درباره‌ی یک واقعیت واحد حرف می‌زنند، حل تعارض یا «فهم معنا» نیست. معیار فقط نوبت‌های has_answer را می‌سنجد؛ پاسخ نهایی، شناسایی مقدار منسوخ، ادراک رویداد انسانی، هزینه‌ی زمانی اجرا یا کیفیت یک عامل کامل آزمون نشده است. داده‌های این مرحله قبلا بررسی شده‌اند و تفاوت کوچک را نباید به پژوهش‌های دیگر یا کاربران واقعی تعمیم داد.

مسیر بعدی از این نتیجه مشخص می‌شود: پیش از افزودن گراف و مدلِ سنگین، باید مجموعه‌ای با برچسب مستقلِ واقعیت، مقدار قبلی و مقدار به‌روزشده تهیه یا تعریف کرد و پاسخِ مستند به هر دو شاهد را سنجید. این نیاز پژوهشی است، نه نتیجه‌ای که آزمایش حاضر به دست آورده باشد.

بازتولید

ابتدا داده‌ی نسخه‌بندی‌شده را مطابق scripts/fetch_phase7_data.py دریافت و هش را کنترل کنید. سپس python scripts/run_phase13_provenance.py --source data/raw/longmemeval_s_cleaned.json، python scripts/package_phase13.py و python scripts/validate_phase13.py را اجرا کنید. آزمون‌ها با python -m unittest discover -s tests -v اجرا می‌شوند. کد CPU و کتابخانه‌ی استاندارد پایتون برای آزمایش اصلی کافی است. گزارش Word/PDF با قلم B Nazanin به‌صورت راست‌چین تهیه شده؛ قلم و فایل‌های کتاب در مخزن توزیع نشده‌اند.

سپاسگزاری و خاستگاه آموزشی

از دکتر آرش فکری، بنیان‌گذار **FARDIAT**، مجتمع فوق تخصصی مغز و شناخت و استاد من در علوم اعصاب شناختی، برای آموزش‌ها و بررسی و تایید پروپوزال سپاسگزارم. از استاد نوری، استاد دانشگاهی درس پروژه، برای حمایت از ایده‌های نو و همراهی با اجرای دقیق پژوهش سپاسگزارم. نشان فردیت با تصویر ارائه‌شده از سوی پژوهشگر در نسخه‌ی چاپی آمده است.

منابع

[۱] Banerjee et al. (2026), APEX-MEM: Agentic Semi-Structured Memory with Temporal Reasoning for Long-Term Conversational AI, ACL Long Papers. source

[۲] Huang et al. (2026), AMA: Adaptive Memory via Multi-Agent Collaboration, Findings of ACL. source

[۳] Uddin et al. (2026), From Recall to Forgetting: Benchmarking Long-Term Memory for Personalized Agents, Findings of ACL. source

[۴] Wu et al. (2025), LongMemEval: Benchmarking Chat Assistants on Long-Term Interactive Memory, ICLR. source

[۵] Panela et al. (2025), Event segmentation applications in large language model enabled automated recall assessments, Communications Psychology. source

[۶] O'Reilly, Munakata, Frank, Hazy et al., Computational Cognitive Neuroscience, fourth edition, uploaded textbook, chapter on episodic memory.