گزارش پژوهشی مرحله‌ی پانزدهم

نقش پیام کاربر، هزینه‌ی متن و بازیابی شواهد حافظه در Memora

تاریخ: ۱۹ اکتبر ۲۰۲۶

نوع کار: آزمایش اکتشافی جفت‌شده روی نمایه‌ی جلسات و دو تحلیل حساسیت پس از نتیجه

حد ادعا: بازیابی جلسه‌ی مرجع شاهد؛ پاسخ‌دهی مدل، FAMA و ادراک انسانی رویداد در این مرحله سنجیده نشد.

چکیده

مرحله‌ی ۱۴ نشان داد در یک شاخه از ارزیاب مستقیم Memora، نام نقش پیام‌های کاربر با نقش پذیرفته‌شده در قالب‌ساز یکسان نیست. در این مرحله اثر نمایش متن را بر یافتن جلسات شاهد بررسی کردیم، نه امتیاز مقاله را. در ۳۰ تاریخچه، سه نمایه‌ی «فقط دستیار»، «دستیار و کاربر به ترتیب اصلی» و «فقط کاربر» با BM25 یکسان بر ۶۰۰ پرسش اعمال شدند. برای ۳۹۸ پرسش دارای شناسه‌ی مستقیم شاهد فعال، با پنج جلسه‌ی برابر، نسخه‌ی کامل در ۲۱۴ و نسخه‌ی فقط دستیار در ۲۰۰ پرسش دست‌کم یک جلسه‌ی شاهد فعال یافت؛ اختلاف ۱۴ پرسش از ۳۹۸ بود و بازه‌ی توصیفی گروهی آن از ۰٫۰۱۲۶- تا ۰٫۰۸۰۱+ امتداد داشت. اما پنج جلسه‌ی کامل به‌طور میانگین ۱۴۵۷ واژه و پنج جلسه‌ی فقط دستیار ۸۳۷ واژه مصرف کرد. در تحلیل پس از نتیجه با ۱۰۲۴ واژه‌ی برابر، ترتیب به ۱۸۸ در برابر ۲۰۶ برگشت. بنابراین پوشش نقش و هزینه‌ی متن با هم بر نتیجه اثر دارند. این یافته درباره‌ی فرصت بازیابی جلسه است؛ شاهدی برای خطای نهایی مدل یا برتری یک روش قطعه‌بندی نیست.

اهمیت، شکاف و نسبت با پژوهش‌های جدید

Memora یادآوری، استدلال و توصیه را در تاریخچه‌های متغیر زمانی می‌سنجد و برای اطلاعات منسوخ نیز معیار فراموشی دارد [۱]. SEEM از چارچوب‌های اپیزودیک و پیوند منشأ شاهد استفاده می‌کند [۲]؛ CompassMem گراف رویداد را برای هدایت بازیابی پیشنهاد می‌کند [۳]؛ LoCoMo-Plus نشان می‌دهد بعضی قیدهای ضمنی را نمی‌توان به بازیابی واژه‌ی صریح تقلیل داد [۴]؛ و APEX-MEM تاریخچه‌ی تغییرناپذیر و حل تعارض هنگام بازیابی را ترکیب می‌کند [۵]. این‌ها مسیر پژوهش‌اند، نه مقایسه‌ی مستقیم با سه نمایه‌ی ساده‌ی ما.

شکاف عملی پروژه‌ی کارشناسی این است: پیش از نسبت دادن اثر به «مرز معنایی اپیزود»، باید دو عامل پایه را جدا سنجید؛ چه نقش‌هایی وارد حافظه می‌شوند و برای چند واژه جا داریم. اگر یکی از این دو بین روش‌ها عوض شود، برد و باخت ظاهری ممکن است به مرزبندی ربطی نداشته باشد. این مرحله یک کنترل زیرساختی، قابل اجرای تک‌نفره و بی‌نیاز از API فراهم می‌کند.

ثبت طرح و منشأ داده

طرح معیار اصلی و برش‌ها در commit f13a58370024bde842e3211e652d92b8c1787a33، پیش از امتیازدهی ثبت شد. مرحله‌ی ۱۴ و ساختار اولیه‌ی داده قبلا دیده شده بود؛ پس مطالعه مستقل و کور نیست. پس از دیدن تفاوت ۱۴۵۷ و ۸۳۷ واژه، تحلیل بودجه‌ی برابر در commit d96b154a3a8dc1bb99503e8fab7ffd9c2e73f1f3 و پیش از محاسبه‌ی همان تحلیل ثبت شد. پس از مشاهده‌ی ناهمگنی طرح برچسب، تحلیل فهرست session_history در commit ۴۰۳۷۷b91763ce64cd4b8786d3340badaa8d76487 ثبت شد. ترتیب زمانی این سه تصمیم در تاریخچه‌ی Git باقی می‌ماند.

داده و سوال‌ها از commit ثابت a6493188efc836d6511ed5e4163fe3ba87da30ff مخزن رسمی Memora [۶] خوانده شدند. ۱۰ شخصیت در هر یک از دوره‌های هفتگی، ماهانه و فصلی، جمعا ۲۷٬۶۱۴ جلسه و ۶۰۰ پرسش دارند. متن گفتگو در ریپوی پژوهش ذخیره نشده است.

روش

برای هر گروه شخصیت و دوره، هر جلسه یک سند جدا بود. واژه‌ساز Unicode پروژه، متن پیام‌های ai_agent، متن پیام‌های ai_agent همراه user_agent به ترتیب مکالمه، یا فقط متن user_agent را ساخت. کد BM25 با k1=1.2 و b=0.75 برای هر نمایه، آمار طول و بسامد واژه را جدا محاسبه کرد؛ نمره‌ی برابر با جلسه‌ی جدیدتر شکسته شد. فقط رشته‌ی پرسش برای رتبه‌بندی خوانده شد. زیرپرسش‌های داوری، پاسخ‌ها، فراداده‌ی عملیات، پرچم share_memory و شناسه یا مقدار شاهد به رتبه‌بند راه نیافتند. این نمایش‌ها متن دقیق پرامپت مدل رسمی نیستند؛ این یک آزمایش بازیابی مستقل با همان تفاوت نقش‌هاست.

معیار اصلی: در پرسش‌های دارای memory_evidence.session_id، آیا در پنج جلسه‌ی اول دست‌کم یکی از جلسات شاهد فعال هست؟ ۲۰۲ پرسش فاقد این نوع مشخص از شناسه از مخرج اصلی کنار رفتند؛ این به معنی نبود هر نوع شاهد در آن پرسش‌ها نیست. ۲۰۴ پرسش فاقد forgetting_evidence.session_id نیز از مخرج تحلیل شاهد منسوخ کنار رفتند. ۱۳۸ پرسش در دو مجموعه‌ی شناسه هم‌پوشانی دارند؛ بازیابی جلسه‌ی مشترک برای هر دو نوع شماره می‌شود و نمی‌توان آن را «اشتباه فراموشی» نامید.

متغیرهای از پیش ثبت‌شده شامل افق زمانی، نوع پرسش، تعداد جلسه‌های شاهد فعال، تازگی جدیدترین شاهد و هم‌پوشانی فعال و منسوخ بودند. تفاوت اصلی با ۲۰۰۰ بازنمونه‌گیری از ۳۰ گروه شخصیت و دوره، با seed برابر ۱۵، بازه‌ی توصیفی گرفت. پرسش‌های یک گروه مستقل فرض نشدند؛ این بازه ادعای تایید آماری نیست. رتبه‌های ۱ و ۱۰ و بازیابی شاهد منسوخ تحلیل‌های ثانویه بودند.

نتیجه‌ی اصلی با تعداد جلسه‌ی برابر

نمایش متن	پرسش با دست‌کم یک شاهد فعال در پنج جلسه از ۳۹۸	پرسش با دست‌کم یک شاهد منسوخ از ۳۹۶	میانگین واژه‌ی پنج جلسه
فقط دستیار	۲۰۰	۱۷۸	۸۳۷
دستیار و کاربر	۲۱۴	۲۴۵	۱۴۵۷
فقط کاربر	۲۰۰	۲۴۳	۶۳۱

در مقایسه‌ی جفت‌شده‌ی فعال، نسخه‌ی کامل در ۵۱ پرسش برنده و در ۳۷ پرسش بازنده بود؛ در ۳۱۰ پرسش نتیجه یکسان شد. اختلاف خالص ۱۴ از ۳۹۸، معادل ۳٫۵۲ واحد درصد است. بازه‌ی توصیفی گروهی برای اختلاف نسبت، تقریبا ۱٫۲۶− تا ۸٫۰۱+ واحد درصد بود. نسخه‌ی فقط کاربر یک آزمون حذف نقش دستیار است و از این جدول نمی‌توان نسخه‌ی کامل یک عامل پاسخ‌دهنده را انتخاب کرد.

برش اصلی	پرسش واجد شرایط	برد کامل	برد فقط دستیار	اختلاف خالص
هفتگی	۱۱۲	۱۷	۸	+۹
ماهانه	۱۰۶	۱۵	۱۰	+۵
فصلی	۱۸۰	۱۹	۱۹	۰
یادآوری	۴۴	۰	۳	−۳
استدلال	۱۵۴	۱۹	۱۵	+۴
توصیه	۲۰۰	۳۲	۱۹	+۱۳

این برش‌ها توصیفی‌اند؛ اندازه‌ی گروه‌ها یکسان نیست و شکل ثبت شاهد در پرسش‌های تولید محتوا تفاوت دارد. از ۳۹۸ پرسش واجد شاهد مستقیم، ۳۲۱ پرسش تازه‌ترین شاهدشان در نزدیک‌ترین ده درصد انتهای تاریخچه قرار دارد، و فقط ۱۳ پرسش شاهدی با سن نسبی بالای ۰٫۵ دارند. بنابراین درباره‌ی رویدادهای خیلی دور نمی‌توان نتیجه‌ی محکم گرفت. در ۲۲۴ پرسش تعداد جلسات شاهد فعال بیش از پنج است؛

بازیابی همه‌ی شواهد در پنج جلسه از نظر ساختاری ناممکن است. به همین دلیل «حداقل یک شاهد» معیار اصلی بود و پوشش همه‌ی شاهدها به‌صورت فرعی گزارش می‌شود.

حساسیت پس از نتیجه با واژه‌ی برابر

پس از مشاهده‌ی تفاوت هزینه، روش انتخاب به این صورت ثبت شد: رتبه‌بندی همان BM25، پیمایش به‌ترتیب نمره، افزودن جلسه‌ی کامل در صورت جا شدن در بودجه، رد جلسه‌ی بزرگ‌تر از فضای باقی‌مانده، و ادامه‌ی پیمایش. جلسه‌ی بی‌متن انتخاب نمی‌شود. این روش پنج جلسه‌ی ثابت را با حداکثر واژه‌ی برابر جایگزین می‌کند؛ صفر بودن نمره‌ی واژگانی مانع انتخاب جلسه‌ی رتبه‌پایین نمی‌شود، پس نتیجه را باید در چارچوب همین قرارداد خواند.

بودجه و نمایش	شاهد فعال از ۳۹۸	شاهد منسوخ از ۳۹۶	میانگین جلسه	میانگین واژه‌ی مصرفی
۱۰۲۴، فقط دستیار	۲۰۶	۲۰۴	۶٫۴۱	۱۰۰۵
۱۰۲۴، دستیار و کاربر	۱۸۸	۲۰۶	۳٫۸۱	۹۹۱
۱۰۲۴، فقط کاربر	۲۴۱	۲۶۹	۸٫۵۲	۱۰۱۲
۲۰۴۸، فقط دستیار	۲۵۴	۲۵۳	۱۲٫۵۳	۲۰۲۹
۲۰۴۸، دستیار و کاربر	۲۳۴	۲۷۲	۷٫۳۵	۲۰۱۴
۲۰۴۸، فقط کاربر	۲۷۶	۳۰۲	۱۶٫۴۳	۲۰۳۶

در بودجه‌ی ۱۰۲۴، اختلاف جفت‌شده‌ی نسخه‌ی کامل منهای فقط دستیار ۱۸- پرسش از ۳۹۸ است: ۳۸ برد در برابر ۵۶ باخت، با بازه‌ی توصیفی حدود ۹٫۵۴- تا ۰٫۲۵+ واحد درصد. در بودجه‌ی ۲۰۴۸ اختلاف ۲۰- پرسش بود، با بازه‌ی حدود ۸٫۶۲- تا ۱٫۶۰- واحد درصد. این‌ها تحلیل‌های پس از مشاهده‌ی نتیجه‌ی اصلی هستند؛ حتی وقتی بازه‌ای صفر را در بر نگیرد، تایید مستقل فرضیه یا برتری علّی یک سامانه‌ی کامل نیستند. تعداد جلسات متفاوت، تفاوت طول متن و شکل تولید مصنوعی گفتگو همگی در نتیجه نقش دارند.

تاریخچه‌ی محتوای تولیدشده و ناهمگنی برچسب

هنگام راستی‌آزمایی دیدیم ۱۵۶ پرسش یادآوری از نوع تولید محتوا به جای شیء session_id، فهرست عددی session_history دارند؛ ۷۵۵ ارجاع آن‌ها همگی به جلسه‌ی موجود وصل شدند. این فهرست ممکن است تاریخچه‌ی مراجعه به محتوا را نشان دهد و معادل شاهد دقیق جواب نیست. در تحلیل جداگانه‌ی ثبت‌شده، در پنج جلسه‌ی اول نسخه‌ی فقط دستیار دست‌کم یکی از این شناسه‌ها را برای ۱۳۱ پرسش و نسخه‌ی کامل برای ۱۵۶ پرسش پیدا کرد. با ۱۰۲۴ واژه، این اعداد به‌ترتیب ۱۳۸ و ۱۵۶ بودند. سقف ۱۵۶ از ۱۵۶ و موفقیت ۱۵۵ از ۱۵۶ در رتبه‌ی اولِ نسخه‌ی فقط کاربر نشان می‌دهد این زیرگروه ساده یا دارای هم‌خوانی واژگانی مستقیم است؛ آن را به ۳۹۸ پرسش اصلی نمی‌افزاییم. ۴۶ پرسش استدلالی دیگر نیز شناسه‌ی شاهد مستقیم نداشتند و برای این معیار واجد شرایط نبودند.

تفسیر و حدود اعتبار

بازگرداندن پیام کاربر در شمار جلسه‌ی برابر اندکی به یافتن شاهد فعال کمک کرد، اما در بودجه‌ی محدود همان متن بلندتر فضای کمتری برای جلسات دیگر گذاشت. این وارونگی دلیل قاطعی است که هزینه‌ی زمینه و فرصت بازیابی باید هم‌زمان گزارش شوند. بازیابی جلسه‌ی دارای شاهد منسوخ می‌تواند برای تشخیص حذف یا تعارض مفید باشد؛ آن را نشانه‌ی بازگویی نادرست نمی‌نامیم. برچسب شاهد از فراداده‌ی مولد داده آمده و حضور جلسه، یافتن خود جمله‌ی شاهد یا درک معنا را تضمین نمی‌کند. هیچ مدل پاسخ‌دهنده، داور FAMA یا اندازه‌گیری ادراک انسانی اجرا نشد. پژوهش‌های SEEM، CompassMem و APEX-MEM با مدل‌های و معیارهای متفاوت گزارش شده‌اند؛ اعدادشان در این جدول قابل قیاس مستقیم نیستند.

گام منطقی بعدی برای ایده‌ی اصلی ما، ساخت حافظه‌ی قطعه‌بندی‌شده با دو کنترل جدی است: ثابت نگه داشتن نقش‌های قابل مشاهده و هزینه‌ی واژگانی، و مقایسه‌ی مرز معنایی با مرز تصادفیِ هم‌تعداد در تاریخچه‌ی زمانی یکسان. نتیجه‌ی این مرحله می‌گوید از ادعای «معنای بهتر» پیش از عبور از این کنترل‌ها پرهیز کنیم.

بازتولید و کنترل کیفیت

```
git clone https://github.com/geniesinc/Memora.git ../memora-upstream
git -C ../memora-upstream checkout a6493188efc836d6511ed5e4163fe3ba87da30ff
python scripts/run_phase15_role_retrieval.py --upstream ../memora-upstream
python scripts/run_phase15_budget.py --upstream ../memora-upstream
python scripts/run_phase15_history.py --upstream ../memora-upstream
python scripts/validate_phase15.py
python -m unittest tests/test_phase15_role_retrieval.py -v
```

خروجی‌ها در results/phase15_summary.json، results/phase15_rows.json.gz، results/phase15_budget.json.gz و results/phase15_history.json.gz فقط ردیف عددی و شناسه‌ی پرسش دارند. اجرای مجدد به‌طور پیش‌فرض فایل نتیجه‌ی موجود را بازنویسی نمی‌کند؛ برای تکرار باید مسیر خروجی تازه بدهید. راستی‌آزمایی ۳۰ گروه، ۶۰۰ کلید پرسش، ۵۴۰۰ ردیف اصلی، ۳۶۰۰ ردیف بودجه و ۲۳۴۰ ردیف تاریخچه را کنترل می‌کند.

سپاسگزاری

از دکتر آرش فکری، بنیان‌گذار FARDIAT، مجتمع فوق تخصصی مغز و شناخت، استاد من در علوم اعصاب شناختی و تاییدکننده‌ی پروپوزال، سپاسگزارم. از استاد نوری، استاد دانشگاهی درس پروژه، برای حمایت از پژوهش دقیق و ایده‌های نو سپاسگزارم.

منابع

[۱] Uddin, M. N., et al. (2026). From Recall to Forgetting: Benchmarking Long-Term Memory for Personalized Agents. Findings of ACL. source

[۲] Lu, Z., et al. (2026). Structured Episodic Event Memory. ACL Long Papers. source

[۳] Hu, Y., et al. (2026). Memory Matters More: Event-Centric Memory as a Logic Map for Agent Searching and Reasoning. Findings of ACL. source

[۴] Li, Y., et al. (2026). LoCoMo-Plus: Beyond-Factual Cognitive Memory Evaluation Framework for LLM Agents. ACL Long Papers. source

[۵] Banerjee, P., et al. (2026). APEX-MEM: Agentic Semi-Structured Memory with Temporal Reasoning for Long-Term Conversational AI. ACL Long Papers. source

[۶] Genies Inc. Memora: released data and evaluation code, pinned commit `a6493188efc836d6511ed5e4163fe3ba87da30ff`. source