گزارش پژوهشی مرحله‌ی شانزدهم مرزهای هم‌تعداد در حافظه‌ی گفت‌وگو

تاریخ: ۲۰ اکتبر ۲۰۲۶. نوع مطالعه: آزمون اکتشافی جفت‌شده روی Memora با کنترل نقش، شمار قطعه‌ی ساخته‌شده و سقف واژه. هدف گزارش: تشخیص اینکه اثر احتمالی مرزبندی از کنترل‌های ساده‌ی بازیابی فراتر می‌رود یا نه.

چکیده

مرحله‌ی پانزدهم نشان داد نتیجه‌ی بازیابی با تغییر نقش‌های ورودی و بودجه‌ی متن وارونه می‌شود. در این مرحله، متن پیام‌های کاربر و دستیار را برای همه‌ی روش‌ها یکسان گذاشتیم و نویسنده‌ی برخط مرحله‌ی هشتم را با پنج مرزبندی تصادفیِ دارای همان شمار قطعه در هر جلسه مقایسه کردیم. در سقف ۱۰۲۴ واژه و ۳۹۸ پرسش دارای شناسه‌ی مستقیم شاهد فعال، نویسنده برای ۲۹۱ پرسش و کنترل‌ها برای ۲۷۲ تا ۲۸۵ پرسش دست‌کم یک جلسه‌ی شاهد یافتند. اختلاف نویسنده با میانگین پنج کنترل ۳٫۰۷ واحد درصد و بازه‌ی بازنمونه‌گیری توصیفیِ ۳۰ گروه ۱٫۲۲ تا ۴٫۹۱ واحد درصد بود. اما با وجود شمار قطعه‌ی ساخته‌شده و سقف واژه‌ی برابر، نویسنده به‌طور میانگین ۱۵٫۲۸ قطعه و کنترل‌ها حدود ۱۴ قطعه را انتخاب کرد. در حساسیتِ پس از نتیجه با تعداد قطعه‌ی انتخاب‌شده‌ی برابر، اختلاف به ۱٫۵۶ واحد درصد رسید؛ مصرف واقعی واژه هنوز متفاوت بود. این اعداد بازیابی جلسه‌ی مرجع هستند و کیفیت جواب، شاهد دقیق درون جلسه یا فهم معنایی را نمی‌سنجند.

اهمیت و شکاف پژوهش

Memora حافظه‌ی کاربر را در کارهای یادآوری، استدلال و توصیه با تغییرات زمانی می‌سنجد [۱]. CompassMem حافظه‌ی رویدادمحور و گراف روابط را پیشنهاد می‌کند [۲] و SEEM چارچوب اپیزودیکِ متصل به منشأ شاهد دارد [۳]. بنابراین اصل ایده‌ی «حافظه‌ی رویدادی» تازه نیست. شکاف عملی این پروژه در نسبت دادن درست اثر مرز است: سود یک سامانه‌ی قطعه‌بندی‌شده ممکن است از دیدن پیام کاربر، افزایش تعداد قطعه‌های قابل انتخاب، یا صرف واژه‌ی متفاوت ناشی شود. در مرحله‌ی پانزدهم، بازیابی متن دو نقش با پنج جلسه‌ی برابر بهتر بود ولی با واژه‌ی برابر بدتر شد. مرحله‌ی شانزدهم به پرسش محدودتری پاسخ می‌دهد: در یک نمای متن ثابت و سقف واژه‌ی یکسان، نویسنده‌ی ازپیش‌ثابت‌شده نسبت به مرزهای تصادفیِ هم‌شمار چگونه عمل می‌کند؟

این مطالعه برای اجرای تک‌نفره مفید است: بازتولید با CPU، داده‌ی عمومی و بدون پاسخ‌گوی API یا نمونه‌گیری انسانی انجام می‌شود. از دید علوم شناختی، ایده‌ی رویداد تنها الهام طراحی است. فاصله‌ی واژگانی Jaccard نه اندازه‌گیری ادراک انسان است و نه آزمون «معنا» در آزمایش فکری سرل.

طرح ثبت‌شده و منشأ

طرح اصلی در commit d609e32fc4d90743eceac9a777d7f9ebe4eb1b85 شاخه‌ی پژوهش، پیش از اجرای امتیازدهی ثبت شد. منبع، بازنگری ثابت a6493188efc836d6511ed5e4163fe3ba87da30ff مخزن رسمی Memora [۴] است. مرحله‌های ۱۴ و ۱۵ قبلا طرح برچسب‌ها و بخشی از رفتار بازیابی همین داده را آشکار کرده بودند؛ پس این ثبت طرح، داده‌ی کور یا مجموعه‌ی آزمون مستقل ایجاد نمی‌کند. ۳۰ تاریخچه‌ی شخصیت و دوره شامل ۲۷٬۶۱۴ جلسه و ۶۰۰ پرسش است. از آن‌ها ۳۹۸ پرسش memory_evidence.session_id و ۳۹۶ پرسش forgetting_evidence.session_id دارند. نبود این نوع شناسه به معنی نبود هر نوع شاهد در پرسش‌های دیگر نیست.

پس از نتیجه‌ی اصلی، تفاوت تعداد قطعه‌ی انتخاب‌شده دیده شد؛ قرارداد تحلیل حساسیت در commit ۷۵e65685cc5ca92bb7c919de2c237f3226edf60e پس از مشاهده‌ی این تفاوت و پیش از اجرای خودِ حساسیت ثبت شد. تحلیل را تاییدی معرفی نمی‌کنیم.

روش و کنترل‌های آزمایش

برای هر جلسه، متن هر دو نقش user_agent و ai_agent به ترتیب اصلی نوبت‌ها خوانده و با واژه‌ساز Unicode کوچک‌نویسی شد. نویسنده‌ی علّی مرحله‌ی هشتم بدون تنظیم مجدد اجرا شد: مقایسه‌ی نوبت تازه با سه نوبت پیشین به کمک ۱ − Jaccard، حداقل ۶۴ واژه برای باز شدن شرط نویی، آستانه‌ی ۰٫۸۵ و حداکثر ۱۶۰ واژه برای قطعه‌ی چندنوبتی. قطعه‌ی بسته‌شده با آمدن نوبت‌های بعدی عوض نمی‌شود. نویسنده به پرسش، شناسه‌ی شاهد، عملیات حافظه و پرچم‌های share_memory دسترسی ندارد.

کنترل تصادفی برای هر جلسه و هر بذر ۰ تا ۴، از میان تمام تقسیم‌های پیوسته و معتبر با دقیقا همان شمار قطعه‌ی نویسنده نمونه‌گیری یکنواخت می‌کند. شمار قطعه و طول تمام نوبت‌های جلسه به کنترل داده می‌شود؛ بنابراین این کنترل پس‌نگر است و نباید آن را الگوریتم برخط هم‌ارز دانست. همه‌ی قطعه‌ها تمام متن را دقیقا یک بار می‌پوشانند. مقایسه‌گر سوم، هر جلسه‌ی کامل به‌صورت یک سند است؛ این مقایسه‌گر شمار سند یکسان ندارد.

در هر گروه، BM25 مرحله‌ی پانزدهم با پارامترهای k1=1.2 و b=0.75 بر سندهای همان روش اجرا شد. در نمره‌ی برابر، جلسه‌ی جدیدتر و سپس قطعه‌ی زودتر در همان جلسه مقدم است. فقط رشته‌ی پرسش برای رتبه‌بندی به کار رفت. همه‌ی سندها رتبه‌بندی شدند؛ سندهای بی‌واژه کنار رفتند و سند کامل در صورت جا شدن به سقف افزوده شد، وگرنه پیمایش ادامه یافت. سند با نمره‌ی صفر ممکن است در جای خالی بودجه انتخاب شود؛ این قرارداد در تمام روش‌ها یکسان است. معیار اصلی، حضور حداقل یک جلسه‌ی شاهد فعال در مجموعه‌ی انتخاب‌شده با سقف ۱۰۲۴ واژه است. ۵۱۲ و ۲۰۴۸ واژه، شاهد منسوخ و مقایسه با جلسه‌ی کامل معیارهای فرعی‌اند. بازه‌ی توصیفی با ۲۰۰۰ نمونه‌گیری از ۳۰ گروه شخصیت و دوره و بذر ۱۶ ساخته شد.

نتیجه‌ی اصلی در ۱۰۲۴ واژه

روش	پرسش با جلسه‌ی شاهد فعال از ۳۹۸	میانگین واژه	میانگین قطعه‌ی انتخاب‌شده	میانگین جلسه‌ی متمایز
نویسنده‌ی برخط	۲۹۱	۱۰۲۳٫۲	۱۵٫۲۸	۱۴٫۱۶
کنترل‌های هم‌شمار، دامنه‌ی پنج بذر	۲۷۲ تا ۲۸۵	۱۰۲۳٫۱ تا ۱۰۲۳٫۲	۱۳٫۹۶ تا ۱۴٫۱۳	۱۲٫۹۴ تا ۱۳٫۱۲
جلسه‌ی کامل، سنجه‌ی فرعی	۱۸۸	۹۹۰٫۸	۳٫۸۱	۳٫۸۱

پنج شمار موفقیت کنترل به ترتیب بذر ۰ تا ۴: ۲۸۱، ۲۸۵، ۲۸۱، ۲۷۲ و ۲۷۵. میانگین آن‌ها ۲۷۸٫۸ است؛ اختلاف ۱۲٫۲ پرسش از ۳۹۸ یا ۳٫۰۷ واحد درصد به دست می‌آید. «۱۲٫۲ پرسش» میانگین پنج کنترل است و شمار واقعی پرسش منفرد نیست. بازه‌ی بازنمونه‌گیری توصیفی ۱٫۲۲ تا ۴٫۹۱ واحد درصد بود؛ چون داده از پیش مشاهده شده و کنترل‌ها بذرهای همان تاریخچه‌اند، آن را آزمون تاییدی یا p نمی‌نامیم. روش جلسه‌ی کامل ۱۸۸ مورد یافت و با مرحله‌ی پانزدهم در همین نمای متن و بودجه دقیقا منطبق شد. به دلیل تفاوت شدید دانه‌بندی، اختلاف ۲۹۱ و ۱۸۸ را اثر خالص جای مرز نمی‌دانیم.

سقف واژه	نویسنده، شاهد فعال	میانگین پنج کنترل	جلسه‌ی کامل
۵۱۲	۲۵۲	۲۴۷٫۶	۱۳۴
۱۰۲۴	۲۹۱	۲۷۸٫۸	۱۸۸
۲۰۴۸	۳۱۱	۳۰۷٫۴	۲۳۴

با بودجه‌ی ۲۰۴۸، فاصله به ۰٫۹۰ واحد درصد کاهش یافت. در سقف ۱۰۲۴، جلسه‌ی شاهد منسوخ برای نویسنده در ۳۰۸ پرسش از ۳۹۶ و برای پنج کنترل به ترتیب در ۳۰۶، ۲۹۶، ۲۹۸، ۳۰۹ و ۳۰۹ پرسش یافت شد. این بازیابی برای بازشناسی تعارض بالقوه مفید است و خطای «فراموش نکردن» یا پاسخ نادرست محسوب نمی‌شود.

ناهمگنی و تحلیل حساسیت پس از نتیجه

در ۲۶۰ پرسش که شناسه‌های شاهد فعال و منسوخ هم‌پوشانی ندارند، اختلاف نویسنده با میانگین کنترل‌ها فقط ۰٫۹۲ واحد درصد بود؛ در ۱۳۸ پرسش دارای هم‌پوشانی ۷٫۱۰ واحد درصد بود. اختلاف در ۲۰۰ پرسش توصیه‌ای ۵٫۹۰، در ۴۴ پرسش یادآوری ۵٫۰۰ و در ۱۵۴ پرسش استدلالی ۱٫۱۷- واحد درصد بود. این زیرگروه‌ها از پیش برای استنباط تاییدی ثبت نشده‌اند. اگر یک شناسه در هر دو برچسب باشد، یافتن آن را نمی‌توان مستقلا یافتن شاهد معتبر یا رد شاهد منسوخ تعبیر کرد.

با وجود برابر بودن شمار قطعه‌ی ساخته‌شده در هر جلسه، نویسنده تحت سقف واژه قطعه‌های بیشتری انتخاب کرد. حساسیت ثبت‌شده‌ی پس از نتیجه، برای هر پرسش K_common را کمترین تعداد قطعه‌ی انتخاب‌شده میان شش روش می‌گیرد و فقط همان تعداد قطعه‌ی نخستِ هر روش را نگه می‌دارد. این مقایسه تعداد قطعه‌ی انتخاب‌شده را برابر می‌کند؛ مصرف واقعی واژه و شمار جلسه‌ی متمایز هنوز برابر نمی‌شود. K_common برای پرسش‌های واجد شرایط از ۹ تا ۱۸، با میانه‌ی ۱۲ بود.

روش در حساسیت پس از نتیجه	شاهد فعال از ۳۹۸	میانگین واژه‌ی مصرفی	میانگین جلسه‌ی متمایز
نویسنده	۲۸۱	۸۹۲٫۲	۱۲٫۳۵
پنج کنترل، دامنه	۲۶۷ تا ۲۸۱	۹۵۶٫۳ تا ۹۶۸٫۷	۱۲٫۲۵ تا ۱۲٫۳۵

کنترل‌ها در این قرارداد به‌ترتیب بذر ۲۷۶، ۲۸۱، ۲۷۵، ۲۶۷ و ۲۷۵ پرسش موفق داشتند؛ میانگین ۲۷۴٫۸ بود. اختلاف نویسنده با میانگین کنترل‌ها به ۶٫۲ از ۳۹۸ پرسش یا ۱٫۵۶ واحد درصد کاهش یافت. در ۲۶۰ پرسشِ بدون هم‌پوشانی شناسه‌ی شاهد فعال و منسوخ، اختلاف ۰٫۳۱- واحد درصد شد. واژه‌ی مصرفی نویسنده در این حساسیت به‌طور میانگین ۸۹۲ در برابر ۹۵۶ تا ۹۶۹ واژه‌ی کنترل‌هاست؛ بنابراین حتی این بررسی نیز اثر خالص «جای مرز» را شناسایی نمی‌کند. چون بعد از دیدن اختلاف اصلی طراحی شد، کاهش اختلاف یک تشخیص اکتشافی است، نه آزمون رسمی میانجی‌گری.

اعتبارسنجی و حد ادعا

در ۳۰ گروه، نویسنده ۱۱۴٬۰۲۰ قطعه از ۲۷٬۶۱۴ جلسه ساخت: ۸۵٬۸۷۳ بسته شدن با شرط نویی، ۵۳۳ مورد با سقف اندازه و ۲۷٬۶۱۴ مورد در پایان جلسه. برای هر پنج بذر، شمار قطعه در هر جلسه و مجموع واژه‌ی منبع با نویسنده برابر ماند. هیچ قطعه‌ی چندنوبتی از سقف ۱۶۰ واژه فراتر نرفت. جدول نتیجه شامل ۱۲٬۶۰۰ ردیف پرسش، روش و بودجه است. اعتبارسنج همه‌ی میانگین‌ها، حضور ۶۰۰ کلید یکتا، ۳۹۸ پرسش واجد شاهد فعال، رعایت بودجه، ثبات منبع و انطباق سنجه‌ی جلسه‌ی کامل با مرحله‌ی پانزدهم را دوباره بررسی کرد. خروجی‌ها متن گفت‌وگو، پرسش و جواب ندارند.

این طرح اندازه‌ی قطعه‌های ساخته‌شده را ثابت نکرده است؛ تنها شمار آن‌ها در هر جلسه برابر است. تفاوت اندازه، بسامد واژگان در سندها، تعداد قطعه‌ی انتخاب‌شده، شمار جلسه‌ی متمایز و پر شدن تقریبا کامل سقف واژه می‌توانند نتیجه را تغییر دهند. برچسب Memora در سطح جلسه است؛ یک قطعه از جلسه‌ی مرجع لزوما حامل نوبت شاهد نیست. مرحله‌ی پانزدهم در همین داده اجرا شده بود، پس هیچ مجموعه‌ی مستقل تازه برای تعمیم نداریم. پاسخ‌گویی مدل، معیار FAMA، مرز ادراک انسانی، EEG و معنای فلسفی در این مرحله سنجیده نشده‌اند.

نتیجه و گام پژوهشی بعد

نویسنده‌ی ازپیش‌ثابت‌شده در سقف ۱۰۲۴ واژه بیشتر از پنج کنترل هم‌شمار به جلسه‌های دارای شاهد رسید؛ این یافته‌ی محدود، قابل بازتولید و اکتشافی است. با برابر کردن شمار قطعه‌ی انتخاب‌شده، اختلاف تقریبا نصف شد و در پرسش‌های بدون هم‌پوشانی برچسب اندکی منفی شد. بنابراین شواهد فعلی برای «برتری معنایی مرز» کافی نیستند. گام بعد باید برچسب شاهد در سطح نوبت یا قطعه و بودجه‌ی برابر با

تعداد فرصت‌های بازیابی هم‌تراز داشته باشد؛ آن‌گاه می‌توان سنجید آیا نزدیک شدن مرز به تغییر رویداد به یافتن خودِ شاهد کمک می‌کند یا خیر.

بازتولید

منبع رسمی را در مسیر مجاور ریپو دریافت و به commit ثابت بالا منتقل کنید. فرمان‌های کامل در بخش مرحله‌ی شانزدهم README آمده‌اند. اسکریپت اصلی، سنجش حساسیت و اعتبارسنجی با نام‌های run_phase16_boundaries.py، run_phase16_equal_selected.py و validate_phase16.py در پوشه‌ی scripts قرار دارند؛ آزمون‌های ساختگی در tests/test_phase16_boundaries.py هستند. برنامه‌ها فایل نتیجه‌ی موجود را به‌طور پیش‌فرض بازنویسی نمی‌کنند. متن خام Memora در این ریپو بارگذاری نشده است.

سپاسگزاری

از دکتر آرش فکری، بنیان‌گذار FARDIAT، مجتمع فوق تخصصی مغز و شناخت، استاد من در حوزه‌ی علوم اعصاب شناختی و تاییدکننده‌ی پروپوزال، سپاسگزارم. از استاد نوری، استاد دانشگاهی درس پروژه، برای حمایت از ایده‌های نو و پیشبرد دقیق پژوهش سپاسگزارم.

منابع

[۱] Uddin et al. (2026). From Recall to Forgetting: Benchmarking Long-Term Memory for Personalized Agents. Findings of ACL. source

[۲] Hu et al. (2026). Memory Matters More: Event-Centric Memory as a Logic Map for Agent Searching and Reasoning. Findings of ACL. source

[۳] Lu et al. (2026). Structured Episodic Event Memory. ACL Long Papers. source

[۴] Memora official repository, pinned source revision. source