

مرحله پنجم: ممیزی ساختاری و پایداری بازیابی

شواهد

وضعیت این مرحله: تحلیل توصیفی پس از آزمون. نتیجه‌ی اصلی مرحله‌ی چهارم، روش‌ها، سقف‌ها و تقسیم‌گفت‌وگوها تغییر نکرده‌اند. این فایل یک گزارش پیشرفت پژوهشی است؛ گزارش نهایی پروژه در مرحله‌ی بعد نوشته می‌شود.

پرسش تخصصی این مرحله

در ارزیابی اصلی، روش مرزبندی واژگانی در سقف ۱۰۲۴ واژه ۴۶۷ پرسش و روش قطعه‌ی ثابت ۴۶۰ پرسش از ۵۹۹ پرسش را با همه‌ی شاهدها بازیابی کردند. آیا شکست‌ها از محدودیت فیزیکی قطعه‌های کامل ناشی می‌شوند، یا شاهدها در سقف جا می‌شوند اما الگوریتم رتبه‌بندی و انتخاب آنها را هم‌زمان برنمی‌گزیند؟ پاسخ به این پرسش برای تفسیر اختلاف کوچک روش‌ها لازم است؛ شمار موفقیت به تنهایی علت شکست را روشن نمی‌کند.

تعریف ممیزی و مرز استنباط

برای هر پرسش، قطعه‌های حامل همه‌ی شناسه‌های شاهد را پیدا کردیم. gold_segment_word_cost مجموع واژه‌های قطعه‌های یکتای حامل شاهد است. اگر این مجموع بیش از ۱۰۲۴ باشد، بازیابی کامل با قطعه‌های کامل و همین سقف، حتی با انتخاب ایده‌آل، ناممکن است؛ برچسب structural_budget می‌گیرد. اگر مجموع در سقف جا شود اما خروجی واقعی همه‌ی شاهدها را نیاورد، برچسب feasible_missed می‌گیرد. حالت دوم می‌تواند از ترکیب رتبه‌بندی، اندازه‌ی قطعه‌ها و روش انتخاب حریصانه ناشی شود؛ نمی‌توان آن را فقط به یک علت نسبت داد.

اسکرپت ممیزی، روش‌های تثبیت‌شده را در سقف اصلی برای هر پرسش دوباره محاسبه کرد. تمام ۱۷۹۷ ردیف (۵۹۹ پرسش در سه روش) با نتیجه‌ی ثبت‌شده‌ی مرحله‌ی چهارم یکسان بود. این بازحساب، ممیزی پس از آزمون است و آزمایش مستقل یا تنظیم دوباره‌ی روش نیست. گزارش هیچ متن گفت‌وگو، متن پرسش، پاسخ یا فهرست شناسه‌های شاهد را منتشر نمی‌کند.

یافته‌ی اول: محدودیت ساختاری و شکست با شاهدهای جاشدنی

روش	موفق از ۵۹۹	ناممکن ساختاری	شکست با شاهد جاشدنی	سقف ساختاری	چندشاهدی با چند قطعه، از ۹۰
قطعه‌ی ثابت	۴۶۰	۰	۱۳۹	۵۹۹	۷۲
مرز واژگانی	۴۶۷	۰	۱۳۲	۵۹۹	۷۲
جلسه‌ی کامل	۳۹۹	۴۰	۱۶۰	۵۵۹	۶۵

در سقف ۱۰۲۴ واژه، قطعه‌های لازم برای همه‌ی شاهدها در هر ۵۹۹ پرسش برای دو روش ثابت و واژگانی در بودجه جا می‌شوند. در نتیجه، هیچ شکست این دو روش «ناممکن به دلیل اندازه‌ی مجموع قطعه‌های شاهد» نیست. برای روش جلسه، این مانع در ۴۰ پرسش رخ می‌دهد؛ حتی اگر رتبه‌بند دقیقاً جلسه‌های شاهد را در بالاترین جایگاه قرار دهد، با این سقف نمی‌تواند آن ۴۰ پرسش را

کامل بازیابی کند. با این حال، ۱۶۰ شکست دیگر جلسه ساختاری نیستند. عدد ۵۵۹ سقف نظری ناشی از همین محدودیت است، نه عملکرد یک روش آزموده‌شده‌ی تازه.

برای ۹۰ پرسش دارای بیش از یک نوبت شاهد، ثابت و واژگانی هر کدام در ۷۲ مورد شاهد‌ها را در بیش از یک قطعه قرار می‌دهند؛ این دو مجموعه‌ی ۷۲ تایی لزوماً یکسان نیستند. جلسه در ۶۵ مورد شاهد‌ها را در چند قطعه دارد. بنابراین یکپارچه‌تر بودن شاهد‌ها در جلسه به تنهایی موفقیت بهتر را تضمین نمی‌کند؛ هزینه‌ی بزرگ جلسه در سقف واژه نیز موثر است.

یافته‌ی دوم: چرا دو روش اصلی اختلاف دارند

در سقف اصلی، ۲۶ پرسش را فقط روش واژگانی و ۱۹ پرسش را فقط روش ثابت موفق بازیابی کرد. در هر ۴۵ مورد اختلاف، قطعه‌های حامل شاهد برای روش بازنده در بودجه جا می‌شدند. پس اختلاف این دو روش در موارد مشاهده‌شده، ناشی از ناممکن بودن ساختاری نیست؛ مرزها، آمار رتبه‌بند و ترتیب بسته‌بندی قطعه‌ها با هم تغییر می‌کنند. این ممیزی سهم علی جداگانه‌ی هر عامل را تعیین نمی‌کند.

یافته‌ی سوم: حساسیت به گفت‌وگو و سقف واژه

میانگین بدون وزن اختلاف هفت گفت‌وگو در مرحله‌ی چهارم حدود ۰٫۹۶ واحد درصد به سود روش واژگانی بود. با کنار گذاشتن یک گفت‌وگو در هر نوبت، میانگین شش گفت‌وگوی باقی‌مانده در بازه‌ی ۰٫۱۴ تا ۱٫۷۸ واحد درصد قرار می‌گیرد. همه‌ی هفت بازحساب مثبت‌اند، اما سه گفت‌وگو در مقایسه‌ی مستقیم به سود روش ثابت و سه گفت‌وگو به سود روش واژگانی بودند. بازه‌ی بالا فاصله‌ی اطمینان نیست و توان تعمیم به گفت‌وگوهای جدید را نشان نمی‌دهد.

گفت‌وگوی کنارگذاشته‌شده	میانگین شش اختلاف باقی‌مانده، واحد درصد
conv-30	۰٫۶۱۴+
conv-41	۰٫۱۳۹+
conv-42	۰٫۳۲۶+
conv-44	۱٫۱۲۰+
conv-47	۱٫۴۵۳+
conv-48	۱٫۲۸۸+
conv-49	۱٫۷۷۷+

افزایش سقف واژه برای یک پرسش الزاماً نتیجه‌ی یکنواخت ندارد، چون انتخاب حریصانه‌ی قطعه‌های کامل ممکن است مجموعه‌ی انتخابی را عوض کند. در گذار ۵۱۲ به ۱۰۲۴، موفقیت به شکست برای روش ثابت در ۱ پرسش، برای واژگانی در ۲ پرسش و برای جلسه در ۱۵ پرسش رخ داد. در گذار ۱۰۲۴ به ۲۰۴۸، برای هیچ‌کدام چنین بازگشتی ثبت نشد. این اعداد از نتیجه‌ی ثابت مرحله‌ی چهارم شمارش شده‌اند.

کنترل‌ها و نتیجه‌ی قابل دفاع

برنامه‌ی ممیزی قبل از تولید این خروجی در کامیت مستقل phase5-audit-plan ثبت شده، ولی پس از دیدن نتیجه‌ی مرحله‌ی چهارم طراحی شده است. SHA-256 فایل داده، طرح ممیزی و نتیجه‌ی قبلی در خروجی ثبت شده‌اند. آزمون‌ها و مقابله‌ی ردیف‌ها نشان می‌دهند خروجی جدید با تنظیم و نتیجه‌ی اصلی سازگار است. هیچ API پولی، GPU یا نمونه‌گیری انسانی لازم نبود. این مرحله توضیح می‌دهد چرا جلسه‌ی کامل بخشی از عملکرد خود را به علت اندازه‌ی قطعه از دست می‌دهد و چرا تفاوت کوچک دو روش اصلی را نمی‌توان به یک علت ساده فروکاست. نتیجه‌ی اصلی همچنان پابرجاست: داده‌ی حاضر برتری پایدار روش واژگانی بر قطعه‌ی ثابت را ثابت نمی‌کند. اقدام بعدی، توسعه‌ی مستندات و بررسی مستقل کیفیت شواهد و سپس نگارش گزارش نهایی با قالب استاد است؛ این کارها نتیجه‌ی اجراشده‌ی مرحله‌ی پنجم نیستند.

کاربرد و محدودیت تفسیر

برای سامانه‌ای که بخش‌های مکالمه را زیر سقف مشخصی به بازیاب می‌دهد، این ممیزی میان دو حالت عملی تمایز می‌گذارد: قطعه‌های شاهد اساساً در سقف جا نمی‌شوند، یا در سقف جا می‌شوند ولی انتخاب نشده‌اند. در حالت نخست، تغییر رتبه‌بند به تنهایی نمی‌تواند محدودیت قطعه‌ی کامل را برطرف کند. در حالت دوم، آزمودن رتبه‌بند یا شیوه‌ی انتخاب می‌تواند یک مسیر پژوهشی باشد؛ داده‌ی این مرحله میزان بهبود احتمالی آن مسیر را اندازه‌گیری نمی‌کند.

معیار پروژه حضور همه‌ی شناسه‌های نوبت شاهد در متن بازیابی شده است. این معیار صحت پاسخ تولیدی، کیفیت معنایی برچسب‌های شاهد، زمان اجرای روش‌ها و رفتار روی مجموعه‌داده‌ی دیگر را نمی‌سنجد. سقف ساختاری ۵۵۹ برای جلسه نیز تنها یک حد بالای مشروط به همین قطعه‌بندی، شواهد و سقف واژه است. این محدودیت‌ها در تفسیر کاربرد روش باید همراه نتیجه بیان شوند.

بازتولید

پس از دریافت نسخه‌ی منجمد LoCoMo طبق scripts/fetch_data.py، این دستورها از ریشه‌ی مخزن اجرا شوند:

```
python -m unittest discover -s tests -v
python scripts/validate_held_out.py
python scripts/validate_phase5_audit.py
```

فایل results/phase5_diagnostics.json حاوی خلاصه و شناسه‌ی ۴۵ مورد اختلاف، بدون متن داده‌ی خام است. برای

بازحساب ممیزی، دستور python scripts/run_phase5_audit.py باید با گزینه‌ی --output و یک مسیر خروجی تازه

اجرا شود؛ فایل ثبت‌شده بازنویسی نمی‌شود. داده‌ی LoCoMo در مخزن منتشر نشده است و منبع و مجوز ۴.۰ CC BY-NC در

README آمده‌اند.