گزارش پژوهشی مرحله‌ی ششم مرزبندی معنایی اپیزودها و بازیابی شواهد

تاریخ: ۱۲ اکتبر ۲۰۲۶. وضعیت: آزمایش محاسباتی انجام شده و نتیجه‌ی آن اکتشافی است. این گزارش امتداد پژوهش قبلی است، نه جایگزین نتیجه‌ی ثبت‌شده‌ی مراحل چهارم و پنجم و نه گزارش نهایی پایان‌نامه.

چکیده و نتیجه‌ی اصلی

پرسش مرحله‌ی ششم این بود که آیا مرز میان بخش‌های یک جلسه‌ی گفت‌وگو، وقتی به‌جای تغییر مستقیم واژه‌ها بر پایه‌ی نزدیکی محتوای نهفته تخمین زده شود، به بازیابی همه‌ی نوبت‌های شاهد کمک می‌کند؟ روش تازه با تحلیل معنایی نهفته یا LSA، بدون API و روی CPU، از متن نوبت‌های سه گفت‌وگوی توسعه آموخته شد. سپس با همان محدودیت ۶۴/۱۲۸/۱۶۰ واژه، پنجره‌ی سه‌نوبتی، رتبه‌بند BM25 و سقف بازیابی روش واژگانی قبلی روی هفت گفت‌وگوی LoCoMo اجرا شد.

در سقف اصلی ۱۰۲۴ واژه، روش معنایی ۴۶۸ پرسش، مرز واژگانی منجمد ۴۶۷ پرسش، قطعه‌ی ثابت ۴۶۰ پرسش و جلسه‌ی کامل ۳۹۹ پرسش از ۵۹۹ پرسش را با همه‌ی شاهدهای علامت‌خورده بازیابی کردند. اختلاف یک پرسش به سود **LSA**، برتری پایدار یا فهم معنایی ایجنت را نشان نمی‌دهد. چهار گفت‌وگو به سود روش واژگانی و سه گفت‌وگو به سود LSA بودند؛ در بودجه‌های ۵۱۲ و ۲۰۴۸ نیز LSA از روش واژگانی عقب افتاد. ارزش این مرحله در آزمون کنترل‌شده‌ی ایده و مشخص‌کردن مرز ادعای آن است.

اهمیت مسئله و جایگاه در ادبیات

جلسه واحد زمانی ثبت گفت‌وگو است؛ اپیزود واحدی پیشنهادی برای محتوای پیوسته‌ی یک رویداد است. یک جلسه می‌تواند شامل چند هدف، تصمیم یا تغییر وضعیت باشد. نظریه‌ی مرزبندی رویداد نشان می‌دهد تغییرهای مدل موقعیت و گاه هدف یا رابطه‌ی علّی در تشخیص مرز اثر دارند [۱، ۲]. با این حال، بردار آماری متن لزوما تغییر هدف را نمی‌فهمد. استدلال اتاق چینی سرل نیز یادآور می‌شود که موفقیت یک پردازش نمادین یا آماری معادل قصدیت و فهم به معنای فلسفی نیست [۳].

کارهایی مانند SeCom بخش‌بندی موضوعی گفت‌وگو را با فشرده‌سازی و بازیابی ترکیب کرده‌اند [۴]. ES-Mem مرزهای موضوع و تغییر نیت را همراه حافظه‌ی چندلایه بررسی می‌کند [۵] و HingeMem تغییر فرد، زمان، مکان و موضوع را برای نوشتن حافظه به کار می‌برد [۶]. بنابراین ادعای «اولین حافظه‌ی اپیزودیک» قابل دفاع نیست. پرسش محدود این پروژه چنین است: آیا فقط جایگزینی نمایش واژگانی مرز با یک نمایش توزیعی سبک، زیر قرارداد بازیابی ثابت، ارزش افزوده دارد؟ این پرسش برای طراحی حافظه‌ی کم‌هزینه‌ی ایجنت کاربرد دارد؛ اگر روش ساده کافی نباشد، افزودن اجزای پیچیده باید با شاهد مستقل و تحلیل هزینه توجیه شود.

در کتاب‌های شناختی پیوست‌شده، فصل حافظه‌ی اپیزودیک Computational Cognitive Neuroscience و فصل یادگیری و حافظه‌ی بلندمدت Fundamentals of Cognition برای روشن‌کردن تفاوت حافظه‌ی تجربه‌ی شخصی انسان و ذخیره‌ی قطعه‌های متن بررسی شدند. آنها شواهد مستقیم برای عملکرد الگوریتم ما نیستند. کتاب‌های EEG، فیزیولوژی و مدار عصبی نیز در این مرحله به‌عنوان نتیجه‌ی تجربی یا نشانگر عصبی وارد نشده‌اند.

پرسش، فرضیه و واحد سنجش

فرضیه‌ی جهت‌دار این بود که نرخ بازیابی کامل شاهدها با مرز LSA بیشتر از مرز واژگانی منجمد شود. فرض صفر، نبود اختلاف میانگین زوجی در سطح گفت‌وگو است. واحد محاسبه‌ی نتیجه‌ی هر پرسش «حضور همه‌ی شناسه‌های نوبت شاهد در قطعه‌های بازیابی‌شده» بود؛ واحد مقایسه‌ی اصلی، میانگین بدون وزن اختلاف هفت گفت‌وگو است. ۵۹۹ پرسش را مشاهده‌ی مستقل برای آزمون معنی‌داری فرض نکردیم. کیفیت پاسخ تولیدی، فهم ذهنی، مرز انسانی و عملکرد حافظه‌ی برخط سنجیده نشده‌اند.

پروتکل configs/phase6_semantic_plan.json و طرح توضیحی docs/phase6_plan.md روی شاخه‌ی گیت‌هاب پیش از اجرای محاسبه‌ی مرحله‌ی ششم ثبت شدند. کد و خروجی توسعه نیز پیش از اجرای هفت گفت‌وگو منتشر شد. این تقدم زمانی فقط جلوی تنظیم تازه بر پایه‌ی نتیجه‌ی LSA را می‌گیرد: نتایج همین هفت گفت‌وگو در مراحل چهارم و پنجم دیده شده بودند، پس اجرای کنونی آزمون مستقل دست‌نخورده نیست.

داده، روش و کنترل نشت

نسخه‌ی منجمد LoCoMo با SHA-256 برابر ۷۹fa87e90f04081343b8c8debecb80a9a6842b76a7aa537dc9fdf651ea698ff4 به کار رفت. مانیفست مرحله‌ی اول، ۲۷۴ پرسش توسعه در سه گفت‌وگو و ۵۹۹ پرسش ارزیابی در هفت گفت‌وگو دارد [۷]. داده‌ی خام با مجوز CC BY-NC ۴.۰ در این مخزن بازنشر نشده است. متن پرسش، پاسخ، شناسه‌ی شاهد، observation، event_summary و session_summary وارد آموزش یا تعیین مرز نشدند. پرسش فقط پس از ساخت قطعه‌ها به رتبه‌بند داده شد و شناسه‌ی شاهد فقط در امتیازدهی و ممیزی هزینه استفاده شد.

مدل LSA از TF-IDF واژه‌های منفرد و تجزیه‌ی SVD با ۶۴ بعد و بذر ۱۷ ساخته شد [۸، ۹]. در سه گفت‌وگوی توسعه، ۱۶۶۷ نوبت متنی و ۲۸۷۴ واژه‌ی متمایز وارد مدل شدند. بردار هر نوبت نرمال و فاصله‌ی کسینوسی میان میانگین بردارهای سه نوبت پیش و پس از مرز نامزد محاسبه شد. انتخاب حریصانه‌ی مرز، قیدهای اندازه، متن ورودی BM25 و بسته‌بندی قطعه‌ی کامل دقیقا با فاز منجمد یکسان ماندند. مدل از نمونه‌ی ارزیابی، حتی بدون برچسب، آموزش ندید. متن‌های بلند جلسه نیز به یک بردار بریده‌شده فروکاسته نشدند؛ بردارها در سطح نوبت محاسبه شدند.

این روش «تقریب آماری نزدیکی محتوا» است. مقدار ۰٫۳۰۰۵ سهم واریانس توضیح‌داده‌شده‌ی SVD، معیار فهم یا کیفیت مرز نیست. در هفت گفت‌وگوی ارزیابی، حدود ۷٫۴۱ درصد از ۹۶۸۰۶ توکن متن بیرون از واژگان آموخته‌شده بودند. از ۴۲۱۵ نوبت، یک نوبت بدون توکن بود و هیچ نوبت غیرخالی به‌طور کامل بیرون از واژگان نبود. این آمار پوشش واژگان است، نه دقت تشخیص تغییر هدف یا علت.

کنترل توسعه و نتیجه‌ی اصلی

در توسعه، LSA در سقف ۱۰۲۴ واژه به‌ترتیب ۶۵ از ۸۳، ۸۶ از ۱۰۲ و ۷۰ از ۸۹ پرسش را بازیابی کرد؛ روش واژگانی پیشین در همان گفت‌وگوها به‌ترتیب ۶۵، ۸۵ و ۶۸ مورد داشت. پس از دیدن این اعداد هیچ پارامتر روش تازه تغییر نکرد. داده‌ی توسعه هم برای ساخت واژگان بدون برچسب به کار رفته بود؛ اختلاف آن برای ادعای تعمیم مستقل مناسب نیست.

بودجه‌ی واژه	**LSA** از ۵۹۹	مرز واژگانی از ۵۹۹	قطعه‌ی ثابت از ۵۹۹	جلسه از ۵۹۹
۵۱۲	۴۱۷	۴۲۱	۴۲۷	۲۵۹

بودجه‌ی واژه	LSA از ۵۹۹	مرز واژگانی از ۵۹۹	قطعه‌ی ثابت از ۵۹۹	جلسه از ۵۹۹
۱۰۲۴، معیار اصلی	۴۶۸	۴۶۷	۴۶۰	۳۹۹
۲۰۴۸	۴۹۹	۵۰۱	۴۹۸	۴۸۳

میانگین بدون وزن موفقیت هفت گفت‌وگو در سقف اصلی برای LSA حدود ۷۷٫۶۶ درصد و برای روش واژگانی ۷۷٫۶۰ درصد بود. میانگین اختلاف زوجی ۰٫۰۶۲ واحد درصد به سود LSA است؛ چهار اختلاف گفت‌وگویی منفی و سه اختلاف مثبت‌اند. مقدار مرجع آزمون دقیق تغییر علامت دوسویه ۰٫۹۶۸۷۵ است و با توجه به اکتشافی‌بودن طرح، نباید تفسیر تاییدی از آن کرد. با حذف یک گفت‌وگو در هر بار، میانگین شش اختلاف باقی‌مانده از حدود منفی ۰٫۷۶ تا مثبت ۰٫۷۱ واحد درصد تغییر می‌کند؛ علامت جمع‌بندی به انتخاب گفت‌وگو حساس است.

گفت‌وگو	LSA موفق	واژگانی موفق	اختلاف نرخ، واحد درصد
conv-30	۴۶ از ۶۶	۴۷ از ۶۶	منفی ۱٫۵۲
conv-41	۷۳ از ۱۰۲	۷۶ از ۱۰۲	منفی ۲٫۹۴
conv-42	۸۲ از ۱۰۵	۸۶ از ۱۰۵	منفی ۳٫۸۱
conv-44	۳۸ از ۵۱	۳۹ از ۵۱	منفی ۱٫۹۶
conv-47	۸۳ از ۱۰۰	۷۸ از ۱۰۰	مثبت ۵٫۰۰
conv-48	۸۳ از ۹۹	۸۰ از ۹۹	مثبت ۳٫۰۳
conv-49	۶۳ از ۷۶	۶۱ از ۷۶	مثبت ۲٫۶۳

تحلیل اختلاف‌ها و ساختار اپیزود

در سقف اصلی، ۴۴۹ پرسش را هر دو روش و ۱۱۳ پرسش را هیچ‌کدام موفق بازیابی نکردند؛ ۱۹ پرسش فقط با LSA و ۱۸ پرسش فقط با روش واژگانی موفق بودند. پس اختلاف کل یک پرسش حاصل ۳۷ جابه‌جایی موردی است، نه توافق کامل دو روش. برای روش LSA، در همه‌ی ۵۹۹ پرسش قطعه‌های حامل شاهد زیر سقف ۱۰۲۴ واژه جا می‌شدند. ۱۳۱ شکست آن از نوع «شاهد جاشدنی ولی بازیابی‌نشده» است؛ این برچسب سهم مرز، آمار BM25 و انتخاب حریصانه را از هم جدا نمی‌کند.

در ۹۰ پرسش دارای چند نوبت شاهد، LSA در ۷۳ مورد و روش واژگانی در ۷۲ مورد شاهدها را در بیش از یک قطعه گذاشتند. زیرگروه چندشاهدی در سقف اصلی ۳۵ موفقیت برای LSA و ۳۲ موفقیت برای روش واژگانی دارد، ولی زیرگروه تک‌شاهدی به‌ترتیب ۴۳۳ و ۴۳۵ است. این شکاف‌های کوچک با جابه‌جایی چند پرسش سازگارند و اثبات مزیت برای پرسش چندمرحله‌ای نیستند.

LSA مجموعا ۸۶۹ قطعه و روش واژگانی ۸۶۷ قطعه ساخت. از ۶۷۳ مرز داخلی واژگانی و ۶۷۵ مرز داخلی LSA، ۳۷۸ مرز دقیقا مشترک بودند. بنابراین تغییر بازنمایی، مرزها را به‌طور محسوسی جابه‌جا کرد، ولی این جابه‌جایی در معیار اصلی به بهبود پایدار تبدیل نشد. همپوشانی مرزها معیار صحت شناختی نیست؛ LoCoMo برای هر نوبت برچسب طلایی مرز انسانی ندارد و event_summary نیز جای آن را نمی‌گیرد.

در اجرا با Python ۳.۱۲.۱۴، NumPy ۲.۳.۵، SciPy ۱.۱۷.۰ و scikit-learn ۱.۸.۰ و یک رشته‌ی BLAS، برازش مدل حدود ۰٫۱۲ ثانیه، قطعه‌بندی هفت گفت‌وگو حدود ۰٫۲۵ ثانیه و رتبه‌بندی و ارزیابی آنها حدود ۱٫۰۰ ثانیه طول کشید. این اعداد اندازه‌گیری همین محیط‌اند، نه بنچمارک سخت‌افزاری استاندارد. هزینه‌ی اصلی این نسخه دانلود یا فراخوانی مدل بیرونی نیست؛ همان وابستگی‌های محلی و اجرای CPU است.

تفسیر علمی و محدودیت‌ها

LSA، هم‌رخدادی واژه‌ها را در یک فضای کم‌بعد بازنمایی می‌کند؛ از این ویژگی نمی‌توان نتیجه گرفت تغییر نیت، شخصیت، زمان، مکان یا رابطه‌ی علّی را درست تشخیص می‌دهد. ممکن است دو قطعه درباره‌ی یک موضوع باشند ولی وضعیت تصمیم متضاد شود، یا موضوع ظاهری عوض شود اما رویداد واحد ادامه یابد. همچنین LSA از همان واژه‌های متن می‌آموزد و آزمون ما مقایسه‌ی کامل «معنای انسانی» با «واژه» نیست. تعداد گفت‌وگوهای ارزیابی هفت است؛ داده‌ی آن پس از مراحل پیشین دیده شده و روش‌ها زیر همان معیار استخراج شاهد، نه پاسخ نهایی ایجنت، مقایسه می‌شوند.

منبع اطلاعات در زمان ساخت قطعه، تمام مکالمه‌ی ثبت‌شده بود و هر مرز از پنجره‌ی نوبت‌های بعدی نیز استفاده می‌کرد. بنابراین این آزمایش نمایه‌سازی بازنگرانه را می‌سنجد، نه نوشتن حافظه در لحظه‌ی ورود هر نوبت. ثبات فرمول BM25 رتبه‌های یکسان به بار نمی‌آورد، زیرا با تغییر مرز، طول قطعه و فراوانی واژه‌ها در نمایه تغییر می‌کند. ادعای اثر علّی خالص مرز، یا انتقال مستقیم نتیجه به حافظه‌ی انسانی و سیگنال عصبی، از این طرح برنمی‌آید.

نتیجه و مسیر بعدی پایان‌نامه

نتیجه‌ی قابل دفاع چنین است: مرزبندی **LSA** از نظر اجرا و بازتولید برای یک پروژه‌ی تک‌نفره ممکن است، اما با این داده و قرارداد، شاهدی برای برتری پایدار آن بر مرزبندی واژگانی پیدا نشد. افزوده‌ی علمی مرحله‌ی ششم، روشن‌کردن تفاوت جلسه و اپیزود، سنجش یک جانشین معنایی سبک، و نشان‌دادن فاصله‌ی میان تغییر مرز و بهبود واقعی بازیابی زیر بودجه‌ی یکسان است. این نتیجه از ارزش پرسش کم نمی‌کند؛ نشان می‌دهد برای آزمودن تغییر هدف و وضعیت رویداد به تعریف و ارزیابی ویژگی‌های صریح‌تر نیاز داریم.

گام پژوهشی بعدی، در صورت وجود زمان و داده‌ی مستقل، تعریف جداگانه‌ی نشانه‌ی تغییر هدف یا وضعیت و سپس مقایسه‌ی تک‌مولفه‌ای آن با این روش‌های منجمد است. برای ادعای تاییدی باید مجموعه‌داده‌ی بیرونی با شواهد قابل تطبیق به کار رود. گزارش نهایی پایان‌نامه باید مسئله، اهمیت و کاربرد، پیشینه، روش، همه‌ی نتایج مثبت و منفی، تهدیدهای اعتبار، و امکان بازتولید را با همین تمایزها ارائه کند؛ هنوز ادعای «ایجنت دارای ادراک اپیزودیک انسانی» نخواهد داشت.

بازتولید و پیوند خروجی‌ها

داده‌ی دارای هش منجمد طبق scripts/fetch_data.py دریافت می‌شود. روی Python ۳.۱۲ با نسخه‌های requirements-phase6.txt، نخست آزمون‌ها، سپس اعتبارسنجی نتیجه‌ها و در صورت نیاز اجرای مجدد با مسیر خروجی تازه انجام می‌شود. scripts/validate_phase6.py، scripts/run_phase6_semantic.py و scripts/run_phase6_analysis.py مسیرهای محاسباتی‌اند. فایل‌های results/phase6_held_out_lsa.json، results/phase6_development_lsa.json و results/phase6_diagnostics.json خروجی‌های بدون متن مکالمه‌اند. مراحل یک تا پنج بدون تغییر باقی مانده‌اند.

منابع

[۱] Zacks et al. (2007), Event Perception: A Mind/Brain Perspective. source

[۲] Zacks and Swallow (2007), Event Segmentation. source

[۳] Searle (1980), Minds, Brains, and Programs. source

[۴] Pan et al. (2025), SeCom: On Memory Construction and Retrieval for Personalized Conversational Agents. source

[۵] Zou et al. (2026), ES-Mem: Event Segmentation-Based Memory for Long-Term Dialogue Agents. source

[۶] Zhong et al. (2026), HingeMem: Boundary Guided Long-Term Memory with Query Adaptive Retrieval for Scalable Dialogues. source

[۷] Maharana et al. (2024), Evaluating Very Long-Term Conversational Memory of LLM Agents, ACL. source

[۸] Landauer and Dumais (1997), A Solution to Plato's Problem: The Latent Semantic Analysis Theory of Acquisition, Induction, and Representation of Knowledge. source

[۹] scikit-learn, TruncatedSVD documentation. source