گزارش پژوهشی مرحله‌ی هفتم آزمون بیرونی مرزبندی گفت‌وگو

تاریخ: ۱۲ اکتبر ۲۰۲۶. وضعیت: آزمون محاسباتی بیرونی انجام شده است؛ این گزارش مرحله‌ای است و پایان‌نامه‌ی نهایی نیست. حوزه‌ی سنجش: بازیابی نوبت‌های شاهد، نه درستی پاسخ تولیدی یا ادراک انسانی رویداد.

چکیده و پاسخ پژوهش

مرحله‌ی ششم نشان داد جایگزینی امتیاز مرز واژگانی با LSA در LoCoMo به برتری پایدار منجر نشد. شکاف بعدی این بود که آیا همان نتیجه، با انتقال بدون تنظیم به گفت‌وگوهایی بیرون از LoCoMo، برقرار می‌ماند. چهار قطعه‌بندی منجمد را روی ۴۷۰ پرسش پاسخ‌پذیر از نسخه‌ی پاک‌سازی‌شده‌ی LongMemEval-S اجرا کردیم. در بودجه‌ی اصلی ۱۰۲۴ واژه، LSA و مرز واژگانی هر کدام ۳۲۰ از ۴۷۰ پرسش را با همه‌ی نوبت‌های علامت‌خورده بازیابی کردند؛ قطعه‌ی ثابت ۳۲۳ و جلسه‌ی کامل ۳۹ پرسش را. از ۴۷۰ پرسش، ۳۱۹ مورد با هر دو مرزبند موفق، ۱۴۹ مورد با هر دو ناموفق، یک مورد فقط با LSA و یک مورد فقط با روش واژگانی موفق بود. شاهدی برای برتری انتقال‌پذیر **LSA** دیده نشد. این نتیجه فقط به قرارداد بازیابی و برچسب‌های موجود مربوط است.

اهمیت، شکاف و کاربرد

مرز جلسه، مرز ادراکی رویداد نیست: در یک جلسه ممکن است موضوع، هدف و وضعیت چند بار عوض شود. اگر قطعه‌بندی محتوایی در بازیابی شاهد زیر سقف حافظه بهتر عمل کند، برای طراحی حافظه‌ی متنی کم‌هزینه‌ی ایجنت سودمند است. اگر روش پیچیده‌تر سودی نداشته باشد، افزودن هزینه‌ی یادگیری و نگهداری مدل به این دلیل قابل توجیه نیست. پژوهش‌های پیشین، از جمله SeCom، حافظه‌ی سطح قطعه را در سامانه‌های گفت‌وگو بررسی کرده‌اند [۱]. سهم محدود این پروژه آزمون کنترل‌شده‌ی انتقال بیرونی یک مرزبند سبک است، نه ادعای نخستین سامانه‌ی حافظه‌ی اپیزودیک.

توصیف شناختی حافظه‌ی اپیزودیک در Fundamentals of Cognition بر محتوای چه، کجا و کی و ماهیت بازسازنده‌ی یادآوری تأکید دارد [۲]. فصل حافظه‌ی اپیزودیک Computational Cognitive Neuroscience نیز به نقش سازوکارهای رمزگذاری و بازیابی می‌پردازد [۳]. این متون چارچوب تمایز مفهومی‌اند؛ شمار نوبت‌های بازیابی‌شده، شاهد عصبی یا آزمون آگاهی و قصدیت نیست.

پیش‌ثبت، داده و ممیزی برچسب

طرح روش و نسخه‌ی منبع با SHA-256 روی شاخه‌ی پژوهشی، پیش از امتیازدهی روش‌ها، منتشر شدند. دو اصلاحیه‌ی ساختار داده نیز پیش از محاسبه‌ی نتیجه‌ی بازیابی ثبت شدند و طرح اولیه باقی مانده است. فایل رسمی LongMemEval-S از انتشار ۹۸d7416c24c778c2fee6e6f3006e7a073259d48f با SHA-256 برابر d6f21ea9d60a0d56f34a05b609c79c88a451d2ae03597821ea3d5a9678c3a442 به کار رفت [۴، ۵]. داده‌ی خام در Git قرار نگرفت.

از ۵۰۰ رکورد، ۴۷۰ پرسش پاسخ‌پذیر و ۳۰ پرسش با پسوند _abs بودند. راهنمای رسمی این ۳۰ مورد را از سنجش بازیابی کنار می‌گذارد [۴]. با این حال در فایل خام، هر ۳۰ مورد فهرست جلسه‌ی شاهد دارند و ۹ موردشان حتی نوبت علامت‌خورده دارند؛ این

تناقض در اصلاحیه‌ی دوم و نتیجه ثبت شد. در ۴۷۰ پرسش قابل سنجش، ۸۸۶ نوبت دارای has_answer:true بود. در ۳۲ پرسش، جلسه‌های دارای چنین نوبتی همه‌ی answer_session_ids رسمی را پوشش نمی‌دهند؛ هیچ نوبت علامت‌خورده‌ای بیرون از فهرست رسمی نبود. شناسه‌ی جلسه در ۱۲ پرسش پاسخ‌پذیر و یک مورد _abs تکرار شد. معیار اصلی بر شناسه‌ی موقعیتی یکتای هر نوبت استوار است و از تکرار رشته‌ی شناسه آسیب نمی‌بیند؛ سنجه‌ی فرعی جلسه‌ای در این موارد مبهم است.

روش و واحد تحلیل

مدل LSA تنها از متن نوبت‌های سه گفت‌وگوی توسعه‌ی LoCoMo، با تنظیمات منجمد مرحله‌ی ششم، آموزش دید. هیچ متن، پرسش یا برچسب LongMemEval در برازش TF-IDF/SVD وارد نشد. برای هر رکورد بیرونی، فقط content نوبت‌ها به چهار روش داده شد؛ نقش، تاریخ، پاسخ، has_answer و شناسه‌های شاهد از ورودی قطعه‌بندی و نمایه‌سازی حذف شدند. پرسش فقط هنگام رتبه‌بندی BM25 وارد شد؛ شاهدها صرفا پس از انتخاب قطعه‌ها برای امتیازدهی خوانده شدند.

روش‌ها عبارت بودند از قطعه‌ی ثابت ۱۲۸ واژه‌ای، مرز واژگانی، مرز LSA و جلسه‌ی کامل. دو مرزبند با پنجره‌ی سه‌نوبتی و حداقل، اندازه‌ی ترجیحی و حداکثر ۶۴، ۱۲۸ و ۱۶۰ واژه کار کردند. نوبت تکیِ بزرگ‌تر از سقف، بدون بریدن حفظ شد. همان کد BM25 و انتخاب حریصانه‌ی قطعه‌ی کامل زیر سقف ۵۱۲، ۱۰۲۴ و ۲۰۴۸ واژه اجرا شد. معیار اصلی، حضور همه‌ی نوبت‌های علامت‌خورده در قطعه‌های بازیابی‌شده‌ی هر پرسش است؛ پرسش، واحد گزارش است ولی تاریخچه‌های ساخته‌شده ممکن است محتوای تکراری داشته باشند و مشاهده‌های آماری مستقل فرض نمی‌شوند. کیفیت پاسخ تولیدی ارزیابی نشده است.

نتایج در بودجه‌های ثابت

بودجه‌ی واژه	**LSA** از ۴۷۰	مرز واژگانی از ۴۷۰	قطعه‌ی ثابت از ۴۷۰	جلسه‌ی کامل از ۴۷۰
۵۱۲	۲۸۴	۲۸۴	۲۸۴	۱۳
۱۰۲۴، معیار اصلی	۳۲۰	۳۲۰	۳۲۳	۳۹
۲۰۴۸	۳۵۴	۳۵۳	۳۵۴	۷۹

نرخ معیار اصلی برای LSA و مرز واژگانی هر کدام ۶۸٫۰۹ درصد و برای قطعه‌ی ثابت ۶۸٫۷۲ درصد است. اختلاف LSA و واژگانی در ۱۰۲۴ صفر است؛ در ۵۱۲ نیز برابر و در ۲۰۴۸ فقط یک پرسش به سود LSA است. تفاوت LSA و قطعه‌ی ثابت در بودجه‌ی اصلی سه پرسش به زیان LSA است. این اعداد تفاوت‌های کوچک توصیفی‌اند و آزمون معنی‌داریِ تاییدی یا انتخاب مدل تازه از آن‌ها ارائه نمی‌شود.

در حساسیت فرعی حضور همه‌ی شناسه‌های جلسه‌ی شاهد، در بودجه‌ی اصلی به‌ترتیب LSA تعداد ۳۷۰، واژگانی ۳۷۱، ثابت ۳۷۴ و جلسه‌ی کامل ۳۹ پرسش را پوشش دادند. این معیار با «همه‌ی نوبت‌های شاهد» یکی نیست: ورود هر نوبت از یک جلسه می‌تواند شناسه‌ی آن جلسه را حاضر کند، حتی اگر نوبت علامت‌خورده نیامده باشد. در ۴۵۸ پرسش فاقد شناسه‌ی جلسه‌ی تکراری، شمار پوشش جلسه‌ای به‌ترتیب ۳۶۰، ۳۶۱ و ۳۶۴ برای LSA، واژگانی و ثابت بود. این تحلیل فرعی نتیجه‌ی اصلی را عوض نمی‌کند.

نوع پرسش	شمار	**LSA**	مرز واژگانی	قطعه‌ی ثابت
به‌روزرسانی دانش	۷۲	۶۰	۶۱	۶۱
چندجلسه‌ای	۱۲۱	۴۹	۴۸	۵۲

نوع پرسش	شمار	**LSA**	مرز واژگانی	قطعه‌ی ثابت
دستیار در یک جلسه	۵۶	۵۲	۵۲	۵۲
ترجیح در یک جلسه	۳۰	۱۲	۱۲	۱۲
کاربر در یک جلسه	۶۴	۶۰	۶۰	۶۰
استدلال زمانی	۱۲۷	۸۷	۸۷	۸۶

این ردیف‌ها پس از مشاهده‌ی نتیجه تفسیر می‌شوند و نباید برای ادعای اختصاصی درباره‌ی نوع پرسش استفاده شوند.

چرا تغییر مرز اثر اندکی داشت

ممیزی توصیفیِ پس از نتیجه، بدون خواندن برچسب‌ها، روی ۲۳۱۶۰۶ نوبت پاسخ‌پذیر انجام شد. ۹۲۵۹۵ نوبت، حدود ۴۰ درصد، بیش از ۱۶۰ واژه داشتند؛ هر یک طبق قرارداد باید یک قطعه‌ی مستقل بزرگ‌تر از سقف روش باشند. از ۲۰۸۸۷۴ قطعه‌ی مرز واژگانی، ۱۹۳۶۵۶ قطعه تک‌نوبتی بودند، یعنی حدود ۹۲٫۷ درصد. روش LSA نیز ۱۹۳۷۹۷ قطعه‌ی تک‌نوبتی از ۲۰۸۹۱۱ قطعه ساخت. ۲۰۶۲۹۲ نقطه‌ی پایان قطعه در دو روش مشترک بود؛ تنها ۶ پرسش پارتیشن کاملا یکسان داشتند، اما اختلاف قطعه‌ها به نسبت کل نقاط پایان اندک بود. این ارقام توضیحی محتمل برای نتیجه‌ی نزدیک‌اند: بسیاری از فرصت‌های انتخاب مرز به دلیل اندازه‌ی خود نوبت‌ها محدود شده‌اند؛ اثر علّی خالص طول نوبت به‌طور جداگانه آزموده نشده است.

برای جلسه‌ی کامل، در بودجه‌ی ۱۰۲۴ واژه در ۴۳۱ از ۴۷۰ پرسش، مجموع هزینه‌ی جلسه‌های حامل نوبت شاهد بیش از سقف بود. بنابراین نرخ ۳۹ از ۴۷۰ عمدتا به قرارداد «قطعه‌ی کامل بدون بریدن» و طول جلسه مربوط است؛ آن را شکست ذاتی حافظه‌ی جلسه‌ای یا کیفیت پایین فهم معنا نمی‌نامیم. در LSA و روش واژگانی، در بودجه‌ی اصلی هیچ پرسشی محدودیت ساختاریِ جمع هزینه‌ی قطعه‌های شاهد نداشت؛ شکست‌هایشان عمدتا در رتبه‌بندی یا بسته‌بندیِ قطعه‌ها رخ داد. فقط ۸۲۱ نوبت از ۲۳۱۶۰۶ نوبت در واژگان مدل LSA هیچ واژه‌ای نداشتند؛ این آمار پوشش واژگان است، نه سنجه‌ی فهم.

تفسیر اعتبار و جایگاه نتیجه

این مرحله نسبت به LoCoMo مجموعه‌داده‌ی بیرونی دارد، اما کار تاییدی کامل نیست. تنظیمات با نتایج پیشین LoCoMo انتخاب یا از پیش تعیین شده‌اند؛ اجرای LongMemEval برای این پروژه اولین بار است. هر پرسش تاریخچه‌ی ساخته‌شده‌ی خود را دارد و مواد زمینه‌ای می‌توانند تکرار شوند؛ ۴۷۰ پرسش را نمونه‌ی مستقل برای محاسبه‌ی قطعیت فرض نمی‌کنیم. تفاوت واحد برچسب و ساختار طول نوبت در دو مجموعه، مقایسه‌ی مستقیم ۴۶۸ از ۵۹۹ LoCoMo با ۳۲۰ از ۴۷۰ اینجا را بی‌اعتبار می‌کند. ناسازگاری ۳۲ برچسب نوبتی/جلسه‌ای و شناسه‌های تکراری باید در گزارش پایان‌نامه آشکار بماند.

نتیجه‌ی محدود ولی کاربردی چنین است: انتقال بدون تنظیم LSA به LongMemEval-S در این قراردادِ بازیابی، برتری بر مرز واژگانی یا قطعه‌ی ثابت نشان نداد. از این نمی‌توان نتیجه گرفت مرز رویداد، تغییر هدف یا بازنمایی معنایی در حافظه‌ی ایجنت بی‌فایده است. در این داده، نوبت‌های بلند و قید قطعه‌ی کامل بخش زیادی از دامنه‌ی تغییر مرز را می‌بندند. آزمون بعدیِ معنادار باید ابتدا هدف عملیاتی مستقلی برای کیفیت مرز یا ثبت برخط و داده‌ی مناسب آن تعریف کند؛ افزودن مدل پیچیده‌تر به همین جدول بدون حل این مسئله، پاسخ پرسش شناختی را روشن نمی‌کند.

بازتولید و هزینه

این اجرا روی CPU و بدون API یا GPU انجام شد. برازش محلی LSA حدود ۰٫۱۴ ثانیه و پردازش ۵۰۰ رکورد حدود ۱۴۱ ثانیه در همین محیط طول کشید؛ زمان‌ها بنچمارک سخت‌افزاری استاندارد نیستند. داده‌ی خام رسمی با LoCoMo منجمد مرحله‌ی اول و نصب نسخه‌های requirements-phase6.txt، آزمون‌ها، scripts/validate_phase7.py و scripts/fetch_phase7_data.py و کنترل هش، بیرون از Git در /data/raw دریافت می‌شود. پس از تهیه‌ی اجرای دوباره‌ی scripts/run_phase7_external.py با مسیر خروجی تازه را اجرا کنید. نتیجه‌ی ریزپرسش‌ها به‌صورت فشرده در results/phase7_external.json.gz و خلاصه‌ی خوانا در results/phase7_summary.json است. ممیزی پسینی مرزها در scripts/run_phase7_boundary_audit.py و خروجی آن در results/phase7_boundary_audit.json ثبت شد. فایل‌های مرحله‌های یک تا شش بازنویسی نشده‌اند. این گزارش و اسکریپت سازنده‌ی Word، مسیر مرور استاد و تهیه‌ی پایان‌نامه‌ی نهایی را روشن می‌کنند.

منابع

[۱] Pan et al. (2025), SeCom: On Memory Construction and Retrieval for Personalized Conversational Agents. source

[۲] Eysenck and Brysbaert (2018), Fundamentals of Cognition, 3rd ed., chapter on long-term learning and memory. Routledge.

[۳] O’Reilly, Munakata, Frank and Hazy (2020), Computational Cognitive Neuroscience, 4th ed., chapter 8, Episodic Memory. source

[۴] Wu et al. (2025), LongMemEval: Benchmarking Chat Assistants on Long-Term Interactive Memory, ICLR. source

[۵] LongMemEval official repository and dataset format. source

[۶] Maharana et al. (2024), Evaluating Very Long-Term Conversational Memory of LLM Agents, ACL. source