گزارش پژوهشی مرحله‌ی هشتم نویسنده‌ی علّی حافظه‌ی گفت‌وگو

تاریخ: ۱۳ اکتبر ۲۰۲۶. وضعیت: آزمایش محاسباتی مرحله‌ای انجام شده است؛ این گزارش پایان‌نامه‌ی نهایی نیست. دامنه: ثبت قطعه هنگام ورود نوبت و بازیابی همه‌ی نوبت‌های شاهد پس از پایان تاریخچه.

چکیده

مرزبند رویداد مرحله‌ی سوم برای تعیین مرز به متن آینده دسترسی داشت. برای سنجش امکان ثبت حافظه در زمان ورود گفت‌وگو، یک نویسنده‌ی علّی و قطعه‌های بسته‌ی تغییرناپذیر ساختیم و آن را زیر بودجه‌ی ثابت با مرزبند پس‌نگر و قطعه‌ی ثابت مقایسه کردیم. در ۵۹۹ پرسش LoCoMo از هفت گفت‌وگوی ارزیابی، در سقف ۱۰۲۴ واژه، نویسنده‌ی علّی همه‌ی شاهدها را برای ۴۶۳ پرسش پیدا کرد؛ روش پس‌نگر برای ۴۶۷ و قطعه‌ی ثابت برای ۴۶۰ پرسش. در LongMemEval-S روی ۴۷۰ پرسش پاسخ‌پذیر، نویسنده‌ی علّی و پس‌نگر هر دو ۳۲۰ پرسش را پوشش دادند و قطعه‌ی ثابت ۳۲۳ پرسش را. روش علّی از نظر دسترسی به داده عملیاتی شد، اما برتری بازیابی نشان نداد و در LoCoMo قطعه‌های بیشتری ساخت. این سنجه حضور شاهد را می‌سنجد، نه کیفیت پاسخ، مرزهای رویداد انسانی یا معنا به تعبیر سرل.

اهمیت و شکاف پژوهش

در نظریه‌ی بخش‌بندی رویداد، مرزهای فعالیت جاری با سازمان‌دهی ادراک و حافظه ارتباط دارند [۱]. در سامانه‌های حافظه‌ی گفت‌وگو نیز باید زمان نمایه‌سازی، بازیابی و خواندن شواهد را از هم جدا کرد [۲]. LoCoMo گفت‌وگوهای بلند و پرسش‌های دارای شاهد را برای ارزیابی حافظه‌ی بلندمدت فراهم می‌کند [۳]. مسئله‌ی مشخص این پروژه آن بود که مرزبند قبلی با پنجره‌ی متن پس از نقطه‌ی مرز و آمار کل جلسه ساخته می‌شد؛ بنابراین نتیجه‌ی بازیابی آن به‌تنهایی نمی‌گفت آیا همان کار را هنگام دریافت نوبت می‌توان انجام داد. این مرحله شکاف اجرایی میان ارزیابی قطعه‌بندی آفلاین و ساخت حافظه‌ی قابل ثبت در جریان گفت‌وگو را آزمایش می‌کند. این ادعا، کشف نبودِ چنین روش‌هایی در کل ادبیات نیست.

کاربرد مستقیم پژوهش، روشن شدن هزینه‌ی یک نویسنده‌ی ساده و بدون API است: اگر قطعه در لحظه‌ی ورود نوبت بسته شود، یک نفر می‌تواند آن را روی CPU و با تاریخچه‌ی موجود اجرا کند. هر ادعای قوی‌تر درباره‌ی «تغییر موضوع» یا «فهم معنا» نیازمند برچسب مستقل مرز رویداد یا آزمون پاسخ است و از همین شاخص شاهد نتیجه نمی‌شود.

داده و طرح ثبت‌شده

قرارداد دقیق روش در configs/phase8_causal_plan.json و توضیح فارسی آن در docs/phase8_plan.md پیش از اجرای امتیازدهی مرحله‌ی هشتم در شاخه‌ی پژوهشی ثبت شد. هر دو مجموعه‌داده و نتیجه‌های قبلی آن‌ها در مرحله‌های چهار تا هفت دیده شده بودند؛ واژه‌ی «ثبت» به معنی مجموعه‌ی آزمون دست‌نخورده یا آزمون تاییدی نیست. هفت گفت‌وگوی LoCoMo شامل ۵۹۹ پرسش واجد شرایط و سه گفت‌وگوی توسعه شامل ۲۷۴ پرسش است؛ قواعد گزینش و هش داده از مرحله‌ی نخست حفظ شدند. بررسی بیرونی از نسخه‌ی پاک‌سازی‌شده‌ی رسمی LongMemEval-S با ۵۰۰ رکورد استفاده کرد؛ ۳۰ مورد پرهیز از پاسخ با پسوند _abs از معیار شاهد حذف و ۴۷۰ مورد پاسخ‌پذیر طبق اصلاحیه‌های مرحله‌ی هفتم ارزیابی شدند [۲، ۴]. هش SHA-256 نسخه‌ی بیرونی

d6f21ea9d60a0d56f34a05b609c79c88a451d2ae03597821ea3d5a9678c3a442 بود. فایل محلی ناقص در شروع اجرا با آزمون هش رد شد؛ نسخه‌ی صحیح دوباره دریافت و پیش از تحلیل تایید شد. داده‌ی خام در Git منتشر نشده است.

نویسنده‌ی علّی و قرارداد مقایسه

برای نوبت تازه‌ی t، متن آن به واژه‌های کوچک‌شده با عبارت منظم یونی‌کد شکسته می‌شود. نویی واژگانی برابر ۱ − Jaccard میان مجموعه‌ی واژه‌های نوبت فعلی و اجتماع واژه‌های حداکثر سه نوبت پیشین همان جلسه است. اگر قطعه‌ی باز دست‌کم ۶۴ واژه داشته باشد و نویی به ۰٫۸۵ برسد، قطعه پیش از افزودن نوبت تازه بسته می‌شود. اگر افزودن نوبت از ۱۶۰ واژه عبور کند نیز قطعه بسته می‌شود؛ تقدم با قید اندازه است. نوبت تکی بلندتر از ۱۶۰ واژه بریده نمی‌شود. انتهای جلسه قطعه‌ی باز را می‌بندد. قطعه‌ی بسته بازنویسی نمی‌شود؛ مرز قبلی هنگام رسیدن نوبت جدید شناخته می‌شود و هیچ نوبت بعد از **t** برای تصمیم آن استفاده نمی‌شود. آستانه برای این آزمون ثابت بود و بر پایه‌ی موفقیت پرسش‌ها تنظیم نشد.

پرسش، پاسخ، شناسه‌ی شاهد، خلاصه، تاریخ و نقش در نویسنده وارد نمی‌شوند. سه مقایسه‌گر عبارت‌اند از مرزبند واژگانی پس‌نگر منجمد مرحله‌ی سوم با تنظیمات ۶۴/۱۲۸/۱۶۰ و پنجره‌ی سه‌نوبتی، قطعه‌ی ثابت ۱۲۸ واژه‌ایِ هم‌تراز با نوبت، و جلسه‌ی کامل. برای هر روش همان رتبه‌بند BM25 و انتخاب حریصانه‌ی قطعه‌ی کامل در بودجه‌ی ۵۱۲، ۱۰۲۴ یا ۲۰۴۸ واژه اجرا شد. معیار اصلی حضور تمام شناسه‌های نوبت شاهد در قطعه‌های انتخاب‌شده زیر سقف ۱۰۲۴ واژه است. شاخص بر اساس پرسش گزارش می‌شود؛ تفاوت گفت‌وگوها جداگانه نمایش داده می‌شود. نویسنده برخط است، ولی پرسش‌ها فقط پس از پایان تاریخچه به نمایه‌ی نهایی داده شدند؛ این اجرای پاسخ‌گویی هنگام جریان گفت‌وگو نیست.

نتایج LoCoMo

بودجه‌ی واژه	نویسنده‌ی علّی از ۵۹۹	مرز پس‌نگر از ۵۹۹	قطعه‌ی ثابت از ۵۹۹	جلسه‌ی کامل از ۵۹۹
۵۱۲	۴۲۰	۴۲۱	۴۲۷	۲۵۹
۱۰۲۴، معیار اصلی	۴۶۳	۴۶۷	۴۶۰	۳۹۹
۲۰۴۸	۴۹۱	۵۰۱	۴۹۸	۴۸۳

در بودجه‌ی اصلی، ۴۳۶ پرسش با هر دو مرزبند علّی و پس‌نگر موفق، ۱۰۵ پرسش با هر دو ناموفق، ۲۷ پرسش فقط با علّی و ۳۱ پرسش فقط با پس‌نگر موفق بود. اختلاف خالص چهار پرسش به سود روش پس‌نگر است، اما جابه‌جایی ۵۸ نتیجه‌ی پرسش نشان می‌دهد روش‌ها مرز و رتبه‌های متفاوتی می‌سازند. در مقایسه با قطعه‌ی ثابت، ۳۳ پرسش فقط با علّی و ۳۰ پرسش فقط با ثابت موفق بود. اختلاف کوچک شمار کل، دلیل بر یکسان بودن رفتار روش‌ها نیست.

گفت‌وگو	نویسنده‌ی علّی	مرز پس‌نگر	قطعه‌ی ثابت	جلسه‌ی کامل
conv-30	۵۰	۴۷	۴۵	۴۶
conv-41	۷۱	۷۶	۷۰	۵۶
conv-42	۸۳	۸۶	۸۱	۷۰

گفت‌وگو	نویسنده‌ی علّی	مرز پس‌نگر	قطعه‌ی ثابت	جلسه‌ی کامل
conv-44	۳۸	۳۹	۳۹	۳۷
conv-47	۷۸	۷۸	۸۰	۷۶
conv-48	۸۳	۸۰	۸۱	۶۹
conv-49	۶۰	۶۱	۶۴	۴۵

جمع پرسش‌های موفق به گفت‌وگو وابسته است؛ جدول برای دیدن جهت تفاوت‌هاست و نرخ‌های بدون مخرج جداگانه نباید به عنوان مقایسه‌ی دشواری گفت‌وگوها خوانده شوند. روی ۴۲۱۵ نوبت این هفت گفت‌وگو، نویسنده‌ی علّی ۱۲۰۹ قطعه ساخت، در برابر ۸۶۷ قطعه‌ی پس‌نگر و ۹۲۷ قطعه‌ی ثابت. از ۱۲۰۹ بستن قطعه، ۹۴۴ مورد با شرط نویی، ۷۱ مورد با سقف اندازه و ۱۹۴ مورد با انتهای جلسه بود. ۳۷ قطعه‌ی علّی تک‌نوبتی شدند. بنابراین هزینه‌ی شمار مدخل‌های نمایه نسبت به پس‌نگر حدود ۳۹٫۴ درصد بیشتر است، هرچند متن مبنا و سقف واژه‌ی بازیابی یکسان ماند. این هزینه در حافظه و زمان نمایه‌سازی دقیق اندازه‌گیری نشده است.

انتقال توصیفی به LongMemEval-S

بودجه‌ی واژه	نویسنده‌ی علّی از ۴۷۰	مرز پس‌نگر از ۴۷۰	قطعه‌ی ثابت از ۴۷۰	جلسه‌ی کامل از ۴۷۰
۵۱۲	۲۸۵	۲۸۴	۲۸۴	۱۳
۱۰۲۴، معیار اصلی	۳۲۰	۳۲۰	۳۲۳	۳۹
۲۰۴۸	۳۵۳	۳۵۳	۳۵۴	۷۹

در سقف اصلی، ۳۱۸ پرسش با هر دو مرزبند موفق، ۱۴۸ پرسش با هر دو ناموفق، دو پرسش فقط با علّی و دو پرسش فقط با پس‌نگر موفق بود. نویسنده‌ی علّی ۲۱۰۷۰۶ قطعه ساخت؛ مرز واژگانی مرحله‌ی هفتم ۲۰۸۸۷۴ قطعه داشت. از قطعه‌های علّی، ۱۹۴۵۳۹ قطعه تک‌نوبتی و ۹۲۵۹۵ مورد از آن‌ها نوبت تکیِ بلندتر از ۱۶۰ واژه بودند. پس بسیاری از انتخاب‌های مرز در این مجموعه با اندازه‌ی خود نوبت محدود شده‌اند. روی LongMemEval-S این اعداد نرخ رسمی پاسخ درست نیستند و مشکل ناسازگاری ۳۲ مورد برچسب جلسه/نوبت و شناسه‌های جلسه‌ی تکراری در مرحله‌ی هفتم همچنان برقرار است. ۴۳۱ پرسش جلسه‌ی کامل در سقف ۱۰۲۴ به دلیل هزینه‌ی قطعه‌های حامل شاهد، از نظر ساختاری نمی‌توانستند همه‌ی شاهدها را در بودجه جا دهند.

ممیزی، تفسیر و محدودیت

آزمون‌ها نشان دادند افزودن نوبت‌های آینده، قطعه‌ی قبلا بسته‌شده را تغییر نمی‌دهد؛ اجرای دوباره‌ی هر پیشوند همان قطعه‌های بسته را می‌سازد؛ و افزودن فیلدهای پاسخ و شاهد به داده‌ی ورودی خروجی نویسنده را عوض نمی‌کند. اعتبارسنج مرحله‌ی هشتم، پوشش ترتیبی و یکتای نوبت‌ها، هزینه‌ی قطعه‌ی بازیابی‌شده زیر بودجه، هش طرح و داده، و برابری دقیق ردیف‌های مقایسه‌گر با نتیجه‌های ذخیره‌شده‌ی مرحله‌های چهار و هفت را کنترل کرد. نتیجه‌های کامل ریزپرسش‌ها بدون متن خام در results/phase8_causal.json.gz و چکیده‌ی قابل خواندن در results/phase8_summary.json قرار دارند.

نتیجه‌ی معتبر این است که می‌توان قطعه‌ها را با تصمیم مبتنی بر گذشته و نوبت فعلی، بدون مدل سنگین و بدون بازنویسی قطعه‌ی بسته تولید کرد. در این قرارداد خاص، مزیت خالص بازیابی نسبت به روش پس‌نگر مشاهده نشد؛ در LoCoMo چهار پرسش کمتر و در LongMemEval-S برابر بود. افزایش شمار قطعه‌ها در LoCoMo، هزینه‌ی بالقوه‌ی نگهداری نمایه است. آستانه‌ی جاکارد، نشانگر ساده‌ی تغییر واژگان است؛ تغییر هدف، زمینه‌ی معنایی یا مرز ادراک‌شده‌ی انسانی را تضمین نمی‌کند. پرسش‌های مجموعه‌ها قبلا در پروژه دیده شده بودند؛ تحلیل اکتشافی است. LongMemEval برای هر پرسش تاریخچه‌ی ساخته‌شده‌ی خود را دارد و پرسش‌ها را مشاهده‌های مستقل آماری فرض نمی‌کنیم. هیچ پاسخ تولیدی، کیفیت خلاصه، فراموشی بلندمدت در اجرا، یا کارکرد ذهن و مغز اندازه‌گیری نشد.

مرحله‌ی بعد برای داوری درباره‌ی ایده‌ی «اپیزود معنایی» باید برچسب مستقل مرزها، معیار کیفیت بسته‌شدن حافظه در زمان واقعی، یا آزمون پاسخ پرسش با حافظه‌ی به‌روزرسانی‌شونده فراهم کند. با قید تک‌نفره و کم‌هزینه، مسیر بعدی می‌تواند آزمون پایداری با جابه‌جایی کنترل‌شده‌ی ترتیب نوبت‌ها و مقایسه‌ی هزینه‌ی نمایه در همان داده‌ها باشد؛ این آزمون به نمونه‌گیری تازه یا API نیاز ندارد، ولی جای داوری مستقل مرزهای انسانی را نمی‌گیرد. تا زمانی که داده‌ی مناسب برای آن فراهم نشود، ادعای اثبات معنای فلسفی یا برتری ادراک اپیزودیک از این داده‌ها مجاز نیست.

بازتولید

پس از تهیه‌ی LoCoMo منجمد با scripts/fetch_data.py و LongMemEval-S با scripts/fetch_phase7_data.py و نصب وابستگی‌های requirements-phase6.txt، آزمون‌ها و scripts/validate_phase8.py را اجرا کنید. برای اجرای دوباره، دستور python scripts/run_phase8_causal.py --output /tmp/phase8-recheck.json یک مسیر تازه می‌خواهد و فایل ثبت‌شده را بازنویسی نمی‌کند. سپس python scripts/package_phase8.py فقط برای بسته‌بندی نتیجه‌ی اصلی به کار می‌رود. اجرای محلی محاسبه‌ی LoCoMo حدود ۱۵ ثانیه و بخش بیرونی حدود ۲۳ ثانیه طول کشید؛ این زمان‌ها وابسته به همین محیط و شامل تمام کار روش‌ها هستند، نه بنچمارک مصرف حافظه یا انرژی. روش از مدل زبانی، GPU و سرویس پولی استفاده نکرد.

منابع

[۱] Zacks and Swallow (2007), Event Segmentation, Current Directions in Psychological Science 16(2), 80–84. source

[۲] Wu et al. (2025), LongMemEval: Benchmarking Chat Assistants on Long-Term Interactive Memory, ICLR. source

[۳] Maharana et al. (2024), Evaluating Very Long-Term Conversational Memory of LLM Agents, ACL. source

[۴] LongMemEval official repository and cleaned source reference. source