گزارش پژوهشی مرحله‌ی نهم کنترل تصادفی مرزها با شمار قطعه‌ی برابر

تاریخ: ۱۳ اکتبر ۲۰۲۶. وضعیت: تحلیل اکتشافی انجام شده؛ پایان‌نامه‌ی نهایی نیست. دامنه: بازیابی همه‌ی نوبت‌های شاهد از گفت‌وگوی کامل، با کنترل شمار قطعه و بودجه‌ی واژه.

چکیده

در مرحله‌ی هشتم، نویسنده‌ی علّی حافظه روی هفت گفت‌وگوی LoCoMo، ۱۲۰۹ قطعه ساخت و در بودجه‌ی ۱۰۲۴ واژه همه‌ی شواهد ۴۶۳ پرسش از ۵۹۹ پرسش را بازیابی کرد. برای بررسی اینکه جای مرزها چه نقشی دارد، در این مرحله برای هر جلسه ۲۰ مرزبندی تصادفی مستقل با دقیقا همان شمار قطعه و سقف اندازه‌ی یکسان ساختیم. از میان همه‌ی پارتیشن‌های معتبر هر جلسه به‌طور یکنواخت نمونه گرفتیم و رتبه‌بند و بودجه را ثابت نگه داشتیم. میانه‌ی موفقیت کنترل‌ها در معیار اصلی ۴۵۳٫۵ پرسش، دامنه‌ی آن ۴۴۴ تا ۴۷۱ و شمار کنترل‌های برابر یا بهتر از نویسنده ۴ مورد از ۲۰ مورد بود. پس در این داده، جای مرزهای نویسنده اغلب از جای تصادفی بهتر بود؛ با این حال چند کنترل بهتر شدند، اندازه‌ی قطعه و تساوی رتبه ممکن است اثر داشته باشند، و این آزمون هیچ برچسب مستقلی برای مرز رویداد یا سنجه‌ی فهم معنا ندارد. نتیجه فقط درباره‌ی پوشش شواهد با این قرارداد بازیابی است.

اهمیت و ضرورت پژوهش

نظریه‌ی بخش‌بندی رویداد، تغییر در جریان فعالیت را با سازمان‌دهی ادراک و حافظه مرتبط می‌کند [۱]. در حافظه‌ی گفت‌وگوی بلند، LoCoMo پرسش‌هایی با نوبت‌های شاهد فراهم می‌کند [۲]. اما نتیجه‌ی مرحله‌ی هشتم، که شمار قطعه‌های نویسنده‌ی علّی از مرزبند پس‌نگر بیشتر بود، به‌تنهایی نشان نمی‌داد تفاوت بازیابی از جای مرز می‌آید یا فقط از افزایش شمار قطعه‌ها. شکاف مشخص همین پروژه، نبودِ کنترل شمار قطعه برای داوری درباره‌ی مرزبندی نویسنده بود؛ این مرحله یک کنترل حداقلی، شفاف و کم‌هزینه برای آن می‌سازد. ادعای شناسایی شکاف در همه‌ی پژوهش‌های این حوزه مطرح نیست.

کاربرد عملی نتیجه، انتخاب محتاطانه‌ی راهبرد ثبت حافظه برای سامانه‌ای است که باید با CPU و بدون API پولی پیش برود. اگر مرزهای پیشنهادی نسبت به جای مرزهای تصادفی با شمار برابر سودی نداشته باشند، افزودن پیچیدگی مرزبندی توجیه تجربی ضعیف‌تری دارد. اگر بهتر باشند، تازه باید سنجه‌ی مستقل رویداد و کیفیت پاسخ بررسی شود؛ پوشش شاهد معادل ادراک اپیزودیک یا معنای فلسفی مورد نظر سرل نیست.

طرح و روش

قرارداد محاسبات در configs/phase9_boundary_plan.json و توضیح فارسی در docs/phase9_plan.md در شاخه‌ی پژوهشی پیش از امتیازدهی مرحله‌ی نهم ثبت شد. نتیجه‌های همین LoCoMo در مرحله‌های پیشین دیده شده بودند. بنابراین تقسیم موسوم به held_out نسبت به این فرضیه دست‌نخورده نیست؛ ثبت پیشین، تحلیل را تاییدی یا آزمون تعمیم نمی‌کند.

برای هر جلسه، شمار قطعه‌های نویسنده‌ی علّی مرحله‌ی هشتم را ثابت گرفتیم. همه‌ی راه‌های تقسیم متوالی نوبت‌ها به همان شمار قطعه که سقف ۱۶۰ واژه را رعایت می‌کنند با برنامه‌ریزی پویا شمارش شدند. نوبت تکی بلندتر از سقف بدون بریدن مجاز است؛ قطعه‌ی چندنوبتی بلندتر مجاز نیست. انتخاب هر پارتیشن با شمار راه‌های تکمیل باقی‌مانده وزن‌دهی شد تا همه‌ی پارتیشن‌های معتبر با احتمال یکسان انتخاب شوند. بذرهای ۰ تا ۱۹ و شناسه‌ی گفت‌وگو و جلسه، مولد قطعی هر تکرار را تعیین کردند. تصمیم مرز تصادفی فقط طول نوبت‌ها و تعداد قطعه‌ی نویسنده را می‌بیند؛ متن پرسش و برچسب شاهد در ساخت قطعه وارد نمی‌شوند. تعداد مرجع خود حاصل اجرای نویسنده روی متن است، پس کنترل تنها جای مرز را شرطی بر آن شمار تصادفی می‌کند، نه تمام اطلاعات واژگانی را.

نویسنده‌ی علّی در لحظه‌ی ورود نوبت قطعه می‌بندد، ولی این کنترل شمار نهایی قطعه‌ها را پس از اتمام جلسه می‌داند و برخط نیست. پس این آزمایش تشخیصیِ پس‌نگر است و پیشنهاد استقرار یک نویسنده‌ی تصادفی آنلاین نیست. برای هر قطعه متن نوبت‌های آن به همان توکن‌های رتبه‌بند قبلی تبدیل شد. BM25، گزینش حریصانه‌ی قطعه‌ی کامل، سه بودجه‌ی ۵۱۲، ۱۰۲۴ و ۲۰۴۸ واژه و معیار حضور همه‌ی شناسه‌های شاهد ثابت ماندند. واحد گزارش، پرسش است؛ پرسش‌های یک گفت‌وگو مستقل فرض نمی‌شوند. معیار اصلی از پیش ۵۹۹ پرسش ارزیابی LoCoMo در ۱۰۲۴ واژه بود؛ ۲۷۴ پرسش توسعه و بودجه‌های دیگر تحلیل حساسیت‌اند.

برابری شمار قطعه به‌صورت جداگانه در هر جلسه برقرار است، نه فقط در کل مجموعه. این طراحی طول تک‌تک قطعه‌ها، شمار قطعه‌های تک‌نوبتی، جای شاهد نسبت به قطعه، یا ترتیب شکستن تساوی امتیاز BM25 را برابر نمی‌کند. بنابراین اختلاف مشاهده‌شده اثر خالص معنا یا اثر خالص مکان مرز را جدا نمی‌سازد.

نتیجه‌ی اصلی و حساسیت بودجه

بخش و بودجه‌ی واژه	نویسنده‌ی علّی	میانه‌ی ۲۰ کنترل	دامنه‌ی کنترل	کنترل برابر یا بهتر
ارزیابی، ۵۱۲	۴۲۰ از ۵۹۹	۴۱۴٫۵	۴۰۳ تا ۴۳۹	۵ از ۲۰
ارزیابی، ۱۰۲۴	۴۶۳ از ۵۹۹	۴۵۳٫۵	۴۴۴ تا ۴۷۱	۴ از ۲۰
ارزیابی، ۲۰۴۸	۴۹۱ از ۵۹۹	۴۸۸	۴۷۴ تا ۵۰۱	۷ از ۲۰
توسعه، ۵۱۲	۲۰۱ از ۲۷۴	۱۹۴٫۵	۱۸۷ تا ۲۰۳	۲ از ۲۰
توسعه، ۱۰۲۴	۲۱۹ از ۲۷۴	۲۱۴	۲۰۴ تا ۲۲۰	۱ از ۲۰
توسعه، ۲۰۴۸	۲۳۵ از ۲۷۴	۲۲۸٫۵	۲۱۶ تا ۲۳۶	۴ از ۲۰

اختلاف نویسنده با میانه‌ی کنترل در معیار اصلی ۹٫۵ پرسش، معادل تقریبا ۱٫۶ واحد درصد از ۵۹۹ پرسش است. «۴ از ۲۰» سهم توصیفی اجراهای تصادفی با موفقیت برابر یا بیشتر است، مقدار **p** یا احتمال تایید فرضیه نیست. این ۲۰ اجرا روی همان داده و با همان نویسنده انجام شده‌اند؛ بیشتر کردن بذرها هم گفت‌وگو یا برچسب مستقل تازه فراهم نمی‌کند. در ۲۰۴۸ واژه، برتری ظاهری کوچک‌تر شد و هفت کنترل برابر یا بهتر بودند.

ناهمگنی گفت‌وگوها

گفت‌وگوی ارزیابی	نویسنده، ۱۰۲۴ واژه	میانه‌ی کنترل	دامنه‌ی کنترل
conv-30	۵۰	۴۸٫۵	۴۵ تا ۵۲
conv-41	۷۱	۷۱	۶۷ تا ۷۴
conv-42	۸۳	۸۱	۷۶ تا ۸۶
conv-44	۳۸	۳۹	۳۶ تا ۴۲
conv-47	۷۸	۷۵	۷۱ تا ۸۴
conv-48	۸۳	۷۸٫۵	۷۱ تا ۸۵
conv-49	۶۰	۶۳	۵۹ تا ۶۶

در conv-44 و conv-49، نویسنده حتی از میانه‌ی کنترل پایین‌تر است؛ در conv-41 برابر است. جمع میانه‌های گفت‌وگوها لزوما با میانه‌ی مجموع‌های هر بذر برابر نیست. این جدول جهت تغییر را روشن می‌کند، اما مخرج پرسش‌های هر گفت‌وگو یکسان نیست و از آن نباید درباره‌ی دشواری نسبی گفت‌وگوها نتیجه گرفت. شمار قطعه‌ی کنترل در هفت گفت‌وگوی ارزیابی، در هر تکرار دقیقا ۱۲۰۹ بود. این برابری منشأ اختلاف شمار قطعه میان مرحله‌ی هشتم و مقایسه‌گر پس‌نگر را از مقایسه‌ی کنونی برمی‌دارد؛ هزینه‌ی واقعی نمایه و زمان اجرا هنوز اندازه‌گیری نشده‌اند.

ممیزی و مرز نتیجه‌گیری

اعتبارسنج، هش طرح و داده، برابری دقیق نتیجه‌ی نویسنده با خروجی مرحله‌ی هشتم، ماتریس کامل ۵۲۳۸۰ ردیف پرسش × بذر × بودجه، نبود تکرار شناسه‌ها، سقف واژه‌ی بازیابی، حفظ همه‌ی نوبت‌ها و شمار قطعه و مجموع واژه‌ها را وارسی کرد. آزمون‌های مستقل، یکتایی و پوشش پارتیشن، نوبت بلند، قطعی بودن بذر و بی‌اثری فیلدهای پاسخ و شاهد بر ساخت کنترل را می‌سنجند. خروجی کامل فشرده و چکیده، بدون متن خام گفت‌وگو، ذخیره شده‌اند.

انتخاب یکنواخت از پارتیشن‌های معتبر با شمار ثابت، یکنواختی مستقل هر نقطه‌ی برش نیست. تنوع قطعه‌ها زیر قید ۱۶۰ واژه محدود می‌شود و برخی نوبت‌ها به علت اندازه‌ی خود، انتخاب مرزهای نزدیک را اجبار می‌کنند. برابری تعداد قطعه نیز توزیع طول و پیامد تغییر رتبه‌ی BM25 را کنترل نکرده است. معیار فقط در دسترس بودن تمام شاهدهای برچسب‌خورده را می‌سنجد؛ پاسخ تولید نشده و صحت پاسخ، کیفیت خلاصه‌ی حافظه، مرز رویداد ادراک‌شده‌ی انسان، فهم زمینه و فهم معنا ارزیابی نشده‌اند. نتیجه‌ی LongMemEval-S مرحله‌ی هشتم در این مرحله دوباره آزمایش نشده است. هفت گفت‌وگوی ارزیابی قبلا دیده شده‌اند و نتیجه‌ی حاضر توصیفی و اکتشافی است.

گام پژوهشی بعد

برای جدا کردن بهتر نقش جای مرز از طول قطعه، می‌توان کنترل مکملی با طول‌های تقریبا همسان و از پیش ثبت‌شده ساخت؛ این قید فضای پارتیشن را محدود و تفسیر آن را تغییر می‌دهد. برای آزمون ادعای «اپیزود معنایی»، اول باید برچسب مرز مستقل از

الگوریتم یا یک معیار پاسخ‌گویی و ثبت حافظه در زمان واقعی تعریف شود. هیچ‌کدام از این‌ها با همین شمار پوشش شاهد اثبات نمی‌شود. این تصمیم باید پیش از اجرای آزمایش بعدی روشن و در طرح جداگانه ثبت شود.

بازتولید

داده‌ی LoCoMo با python scripts/fetch_data.py و هش مندرج در configs/protocol.json آماده می‌شود. با نتیجه‌ی فشرده‌ی مرحله‌ی هشتم و وابستگی‌های همان مرحله، python -m unittest discover -s tests -v و python scripts/validate_phase9.py را اجرا کنید. برای بازاجرای کنترل‌ها از مسیر تازه استفاده کنید: python scripts/run_phase9_controls.py --output /tmp/phase9-recheck.json. فایل اصلی ثبت‌شده را بازنویسی نکنید. scripts/package_phase9.py بسته‌ی رسمی را می‌سازد. کد روی CPU و بدون مدل بیرونی یا API پولی اجرا شد. هش دقیق طرح، داده و خروجی پیشین در results/phase9_summary.json آمده است.

سپاسگزاری و خاستگاه آموزشی



از دکتر آرش فکری، بنیان‌گذار **FARDIAT**، مجتمع فوق تخصصی مغز و شناخت و استاد من در این حوزه، برای آموزش‌های مغز و شناخت و Cognitive Neuroscience سپاسگزارم. ایده‌ی پیوند بخش‌بندی رویداد با حافظه‌ی گفت‌وگو از این آموزش‌ها شکل گرفت و ایشان پروپوزال این پروژه را نیز بررسی و تایید کردند. از استاد نوری، استاد دانشگاهی من در درس پروژه، برای حمایت از ایده‌های نو و همراهی در مسیر اجرای پژوهش سپاسگزارم. نشان فردیت، با فایل تصویری ارائه‌شده از سوی پژوهشگر، در نسخه‌ی قابل چاپ آمده است.

منابع

[۱] Zacks and Swallow (2007), Event Segmentation, Current Directions in Psychological Science 16(2), 80–84. source

[۲] Maharana et al. (2024), Evaluating Very Long-Term Conversational Memory of LLM Agents, ACL. source

[۳] LoCoMo official dataset and license. source